



分类号: _____
密 级: _____
UDC: _____

贵州财经大学

硕士学位论文

论文题目: 基于差分隐私的图数据发布隐私
保护模型研究

专业名称: 计算机科学与技术

研究方向: 计算机网络与信息安全

学生姓名: 傅培旺

学 号: 20211108111015

导师姓名: 丁红发

导师职称: 副教授

定稿时间: 2024 年 5 月 28 日

中国·贵阳

摘要

当前, 社交网络、位置服务和物联网等应用场景产生的海量分布式图结构数据(图数据), 已经被广泛地应用于现实生活与科学研究当中。作为图数据的重要统计指标, 度分布直方图、三角计数及聚类系数属于图数据统计分析及挖掘的重要对象之一。若直接发布此类统计指标将导致图数据中的隐私信息泄露, 因此在发布之前需对其进行合理的隐私保护。差分隐私(Differential Privacy)模型作为一种新型的隐私保护技术, 因其具备可证明强度的隐私保护能力及无需敌手背景知识的特性而备受关注, 并被广泛应用于图数据统计分析和发布研究当中。然而, 传统基于中心化差分隐私的图数据统计发布模型无法有效避免第三方威胁, 致使用户数据存在直接暴露的风险。因此, 现有研究更多基于分布式场景, 通过引入本地差分隐私(Local Differential Privacy, LDP)机制对分布式用户持有的子图数据进行保护, 从而实现强隐私保护。

令人遗憾的是, 尽管本地差分隐私能够忽略第三方威胁带来的挑战, 但其严格的隐私定义以及图数据的强关联性和结构特性使得保护后的数据效用十分不理想, 且往往只能实现单一统计指标发布。同时, 若需要进一步提升隐私保护强度, 采用点本地差分隐私机制保护数据, 将会面临更为严峻的效用问题。

在此基础之上, 一种被称之为混洗差分隐私(Shuffled Differential Privacy, SDP)的新型差分隐私机制被拓展提出, 其通过在分布式用户与数据收集者间引入混洗器对扰动数据进行混洗从而提升隐私收益, 进而平衡中心化差分隐私及本地差分隐私间的矛盾。因此, 本文首先通过引入混洗差分隐私机制, 解决图数据度分布直方图及聚类系数发布场景下中心化差分隐私和本地差分隐私存在的安全威胁和数据效用问题; 其次, 针对本地差分隐私存在的单一发布及隐私需求不一等挑战, 结合边本地差分隐私和点本地差分隐私机制, 设计一种自适应隐私强度的多样化统计指标发布算法。主要成果如下:

(1)在编码-混洗-分析框架下提出一种混洗差分隐私保护的度分布直方图发布算法(Graph-SDP)。首先, 设计混洗差分隐私图数据度分布直方图隐私保护框架, 采取交互式用户分组、混洗器及方波本地加噪扰动机制降低编码器对分布式用户本地差分隐私加噪的噪声影响, 并利用极大似然估计在分析器端对加噪后的度分布直方图进行数据矫正, 从而提高数据效用; 其次, 提出具体的分布式用户分组、混洗差分隐私加噪和数据矫正算法, 并证明其满足 (ϵ, σ) -混洗差分隐私。实验和对比结果表明, 在 L_1 距离、H 距离和均方误差(Mean Squared Error, MSE)多个指标度量下的数据效用比已有算法提升了 26%以上, 且具有较低的时间开销和稳定的数据效用表现, 适用不同规模的图数据度分布直方图发布共享应用。

(2)设计一轮交互模型下基于混洗差分隐私保护的聚类系数发布算法(GCC-SDP)。首先, GCC-SDP 通过混洗差分隐私机制和随机响应机制收集所有边的契形列表(2-跳邻居信息)以及邻接位向量,用以估计各用户的局部三角形计数;其次,通过拉普拉斯机制收集所有用户的本地度值;最后,数据收集者根据估计的三角形计数及噪声度值估计全局聚类系数,并将其发布。本文提供了GCC-SDP 的具体步骤,理论证明了所提算法 GCC-SDP 在各类差分隐私约束下的隐私保障上限,并且发布的结果是无偏的。同时,通过在真实数据集和生成数据集上进行实验对比, GCC-SDP 的发布精度相较于其他本地差分隐私的方案,在 MSE 和平均绝对误差(Mean Absolute Error, MAE)两个指标上最高可提升 66.5% 和 51%。

(3)设计基于本地差分隐私的分布式图统计指标发布算法(GS-LDP),同时实现度分布、三角计数序列和聚类系数 3 个不同统计指标发布,并适应不同有效性和隐私保护的需求。首先,采用分组机制及对称一元编码机制,设计具备高强度隐私保护的基于 Node-LDP 的度分布发布算法;其次,基于所提度分布发布算法获取阈值,引入剪枝算法缓解随机加噪的噪声边过多问题,并分别提出基于 Node-LDP 和 Edge-LDP 的三角计数序列发布算法;再次,在前述三角计数序列发布算法基础上引入拉普拉斯机制,从而分别提出基于 Node-LDP 和 Edge-LDP 的聚类系数发布算法,进而实现不同保护强度及数据效用需求下的分布式图数据多指标发布;最后,实验和对比结果表明,所提算法能同时提高隐私保护强度和数据效用,比现有单一或多统计指标发布算法更具优势。

关键词: 图结构数据; 差分隐私; 隐私保护技术; 图统计; 数据效用;

ABSTRACT

In nowadays, application scenarios such as social networks, location services, and the Internet of Things have generated massive amounts of distributed graph structured data (graph data). These graph data have been widely applied in real life and scientific research. As the important statistical information of graph data, the degree distribution histogram, triangle counts and clustering coefficient of graph data are one of the important objects of graph data analysis and mining. If the above information is directly published, the privacy information in the graph data will be leaked, so it is necessary to protect its privacy before publishing. Differential privacy (DP) model, as a new type of privacy protection technology, which has attracted much attention because of its provable privacy protection ability and no need for adversary background knowledge. Furthermore, it also has been widely used in graph data statistics analyzing and publishing research. However, traditional centralized differential privacy (CDP)-based graph data statistics publishing models cannot effectively mitigate third-party threats. This increases the risk of directly exposing user data. Therefore, existing studies focus more on distributed scenarios, where a local differential privacy (LDP) mechanism is introduced to protect the subgraph data held by distributed users, to achieve strong privacy protection.

Unfortunately, although local differential privacy can address the challenges posed by third-party threats, its strict privacy definition, as well as the strong correlation and structural characteristics of the graph data, result in pretty unsatisfactory utility of the protected data. Often, only a single statistical indicator can be published. At the same time, if it is necessary to further enhance the intensity of privacy protection and adopt the Node-LDP mechanism to protect data, it will face more severe utility problems.

On this basis, a new differential privacy mechanism named shuffled differential privacy (SDP) is proposed. SDP improves privacy benefits by introducing a shuffler to shuffle disturbed data between distributed users and data collectors. Then, SDP can further balance the contradiction between centralized differential privacy and local differential privacy. For this reason, this paper firstly introduces the SDP mechanism to solve the security threats and data utility problems associated with both CDP and LDP in scenarios involving the publication of the histogram of graph data degree distribution and clustering coefficient. Secondly, considering the difficulties

associated with single publication and varying privacy requirements in local differential privacy, this paper combines Edge-LDP and Node-LDP mechanisms to develop an adaptive privacy intensity publishing algorithm, which can cater to diversified statistical indicators. The main results are as follows:

(1) Propose a histogram publishing algorithm of degree distribution via shuffled differential privacy (Graph-SDP) under the framework of Encode-Shuffle-Analyze. Firstly, a privacy preserving framework for histogram publishing of degree distribution is designed based on shuffled differential privacy. In this framework, the noisy impact that encoder brings to distributed users is reduced by employing interactive user grouping, shuffler and square wave noise mechanism, while adding noise via local differential privacy; the noisy histogram of degree distribution is reconciled via the maximum likelihood estimation at the analyzer end, and thus the utility of published data is improved. Secondly, specific algorithms are proposed aiming to concreting distributed user grouping, adding shuffled differential privacy noise and reconciling the noisy data respectively. Furthermore, it is proved that these algorithms meet the requirement of (ϵ, σ) -SDP. Experiments and comparisons illustrate that the proposed algorithms can preserve the privacy of distributed users, and the data utility is improved more than 26% with metrics in terms of L_1 distance, H distance and MSE while comparing with the existing related algorithms. The proposed algorithms also perform with a low overhead and stable data utility, and are suitable for publishing and sharing histogram of degree distribution for different scale of graph data.

(2) Design a clustering coefficient publishing algorithm (GCC-SDP) via shuffled differential privacy, under a round of interaction model. First, GCC-SDP gathers the local wedge lists of all edges and adjacency bit vectors through SDP and random response for calculating noisy local triangle counts. Secondly, it gathers local degree values of all users via the Laplace mechanism. Finally, the data collector estimates the global clustering coefficient of global graph data based on the estimated triangle counts and noisy degree values, and publishes it. This paper provides specific steps of GCC-SDP and demonstrates through theoretical analysis that GCC-SDP conforms to various DPs, with unbiased results. At the same time, through experiments over real and generated datasets, the published utilities of GCC-SDP can be increased by up to 66.5% and 51% in MSE and MAE compared to LDP-based schemes at most.

(3) Design a statistics collecting algorithm named GS-LDP of distributed graph

via LDP. This algorithm can publish three different statistics, i.e., degree distribution, triangle count sequence and clustering coefficient, simultaneously. And it can adapt to different effectiveness and privacy preserving requirements. First, a degree distribution publishing algorithm with Node-LDP is designed, by using the grouping mechanism and symmetric unary coding mechanism. This algorithm can achieve high strength privacy protection. Second, obtaining the threshold value with the algorithm mentioned above, then alleviating the problem of excessive noisy edges in random noise through introducing a prune algorithm, the triangle count sequence publishing algorithms with Node-LDP and with Edge-LDP are proposed respectively. Third, based on the aforementioned algorithms, clustering coefficient publishing algorithms with Node-LDP and with Edge-LDP are proposed respectively, by introducing the Laplace mechanism. And these algorithms achieve multi-metrics publishing of distributed graph-structure for different privacy and utility requirements. At last, experimental and comparative results show that, the proposed algorithms can strengthen both privacy and data utility, and perform significantly better than existing single or multiple statistics publishing algorithms.

Keywords: Graph-structure data, Differential privacy, Privacy-preserving techniques, Graph statistics, Data utility

目 录

第 1 章 绪论.....	3
1.1 研究背景及意义.....	3
1.2 国内外研究现状.....	5
1.2.1 集中式场景下基于 DP 的图数据发布研究现状	5
1.2.2 分布式场景下基于 DP 的图数据发布研究现状	6
1.2.3 SDP 研究现状	7
1.3 研究内容及创新点.....	8
1.4 章节安排.....	10
第 2 章 理论知识	11
2.1 符号定义.....	11
2.2 差分隐私.....	13
2.2.1 差分隐私	13
2.2.2 本地差分隐私.....	14
2.2.3 混洗差分隐私.....	15
2.3 噪声机制及理论.....	15
2.4 差分隐私的组合性质.....	17
2.5 本章小结.....	17
第 3 章 混洗差分隐私保护的度分布直方图发布算法	19
3.1 混洗差分隐私保护的度分布直方图发布算法	19
3.1.1 图数据度分布直方图发布的混洗差分隐私保护框架	19
3.1.2 各用户组的用户数量计算算法.....	22
3.1.3 各组用户的隐私预算及加噪跳转半径计算算法	23
3.1.4 混洗差分隐私保护的图数据度分布加噪算法	28
3.1.5 混洗差分隐私保护的图数据度分布校正算法	30
3.2 实验与分析.....	34
3.2.1 实验设置.....	34
3.2.2 效用分析.....	35
3.2.3 用户分组影响分析.....	37
3.2.4 参数影响分析.....	38
3.3 本章小结.....	40
第 4 章 基于混洗差分隐私的聚类系数发布算法	41
4.1 GCC-SDP 框架.....	41
4.2 GCC-SDP 实施.....	43
4.2.1 报告邻接向量和契形列表.....	43

4.2.2 报告度值.....	50
4.2.3 聚合校正.....	51
4.3 GCC-SDP 算法.....	55
4.3.1 用户端算法.....	55
4.3.2 数据收集者算法.....	56
4.4 隐私与效用分析.....	58
4.5 实验分析.....	58
4.5.1 实验设置.....	59
4.5.2 效用分析.....	59
4.5.3 隐私预算分配率对效用的影响.....	63
4.5.4 隐私泄露率对效用的影响.....	65
4.6 本章小结.....	65
第 5 章 基于本地差分隐私的分布式图统计发布算法.....	66
5.1 基于本地差分隐私的图统计发布框架.....	66
5.2 基于 Node-LDP 的度分布发布算法.....	69
5.2.1 用户分组影响分析.....	69
5.2.2 度分布发布算法的隐私效用分析.....	70
5.3 三角计数序列发布算法.....	72
5.3.1 基于 Node-LDP 的三角计数序列发布算法.....	73
5.3.2 基于 Edge-LDP 的三角计数序列发布算法.....	76
5.3.3 三角计数序列发布算法隐私效用分析.....	78
5.4 聚类系数发布算法.....	82
5.4.1 基于 Node-LDP 的聚类系数发布算法.....	82
5.4.2 基于 Edge-LDP 的聚类系数发布算法.....	84
5.4.3 聚类系数发布算法隐私效用分析.....	85
5.5 实验分析.....	88
5.5.1 实验设置.....	88
5.5.2 算法对比与分析.....	89
5.5.3 度分布发布效用对比与分析.....	92
5.5.4 三角计数序列效用对比与分析.....	93
5.5.5 聚类系数效用对比与分析.....	95
5.5.6 通信代价分析.....	97
5.5.7 其他参数影响.....	99
5.6 本章小结.....	102
第 6 章 总结与展望.....	104
6.1 研究工作总结.....	104
6.2 不足和展望.....	105
参考文献.....	106

第 1 章 绪论

1.1 研究背景及意义

互联网、移动互联网和物联网(Internet of Things, IoT)等新兴技术的高速发展,产生了社交网络、移动位置信息、电信通信网络、生物蛋白、社交物联网等海量图结构数据^[1-3](在下文中简称为图数据),并深刻影响了人们的生活和工作。图数据相较关系型、文本和图像等类型的数据,能天然表示不同实体间的复杂关系,在分析挖掘复杂关联关系时具有突出的优势,因而基于图数据的图计算在广告营销、反垃圾邮件、反电信诈骗、生物信息学等领域有广泛的应用。同时,图数据处理还被美国国家科学研究委员会称为 21 世纪大数据处理的主要方法之一^[4],进一步地引发了学术界和产业界对图数据的广泛关注。此外,随着近年来图神经网络的突出进展^[5-6],更是为图数据处理及应用带来了新的机遇。

各类图数据的广泛应用,使得图数据共享发布的需求变得尤为迫切。然而,社交网络、邮件网络、位置信息网络以及社交物联网等图数据中包含大量的个人隐私、属性隐私和关系隐私^[7-8],在共享发布此类图数据时极易造成隐私信息泄露。尤其是近年来,Facebook 数据泄漏、滴滴网络安全审查等多起图数据安全事件的发生,愈发引起了人们对图上数据安全的广泛关注和担忧。依据《数据安全法》和《个人信息保护法》等法律法规要求,在对包含隐私信息的图数据进行共享发布时必须落实合规的隐私保护措施。因此,设计安全有效的图数据共享发布算法,成为产业界和学术界关注的热点^[8]。

目前,针对数据开放共享应用的数据隐私保护发布模型包含有匿名^[9-11]和差分隐私(Differential Privacy, DP)^[12-23]两类。随着图数据的大规模应用,这两类算法被改进、扩展至图数据领域,并产生了诸多变形,如匿名算法有 k -度匿名^[9]、 k -邻居匿名^[10]、 k -同构匿名^[11]等;DP 有边-DP(Edge-DP)和点-DP(Node-DP)^[19-22]。这些不同的隐私保护算法能够针对图数据的不同隐私进行有效的保护,其中 DP 因其具备可证明强度的隐私保护能力而备受关注^[22]。但是,传统的 DP 保护算法主要聚焦于集中式的图数据发布场景,无法适应分布式数据发布场景和数据收集者不可信场景^[24]。尤其是在社交网络、IoT 网络、位置服务网络等分布式图数据场景中,每个图数据节点仅拥有与其自身相邻的一阶邻居子图^[25-26];还有些场景中,不同主体拥有整个图数据的一部分子图^[27-30],因各自互不信任不愿意将原始子图直接共享给其他主体。上述场景中图数据发布需要针对分布式环境和数据收集者不可信设计出安全有效的图数据共享发布方案。

为解决该问题,面向分布式图数据发布的本地差分隐私(Local Differential

Privacy, LDP)^[13-17,24-33]被提出,并扩展提出了基于混洗的差分隐私(Shuffled Differential Privacy, SDP)^[34-40],兼顾了图数据隐私和分布式用户身份隐私保护。然而,在实际分布式应用场景中,分析图数据连通度、聚类及查找关键节点等数据挖掘工作需要度分布直方图、子图统计、聚类系数等图数据统计信息^[26,33]。但这些统计信息与图数据节点用户拥有的子图数据高度关联,且包含大量用户轨迹、关联关系等隐私信息,在采集、共享或发布时极易泄露隐私信息^[26,33]。

如图 1.1 所示为分布式图数据统计信息发布场景中所存在的威胁模型。具体而言,在共享发布分布式图数据统计信息时,数据收集者希望通过获取分布式用户的子图信息来发布有效的图数据统计信息,以供数据需求者进行分析。然而,在该过程中,恶意的攻击者可能试图从用户子图信息或其他局部统计数据(如:度值、2-star 计数)中获得完整的图数据或统计信息;尤其是在发布具备高维性和强关联性的图数据统计指标(如聚类系数、三角计数序列)时,分布式用户报告的数据中包含大量的边缘信息,或将引发更大的隐私泄露风险。当分布式节点用户报告其子图或其他统计信息时,可能存在以下两种类型的隐私泄露风险:

1. 攻击者通过信道攻击截取分布式用户报告的信息,直接窃取隐私数据;
2. 攻击者与数据收集器合谋,获取子图信息或图数据统计信息。

攻击者可能是恶意的第三方,也可能是分布式用户其中之一。进一步地,在攻击隐私信息之前,攻击者还可能已经掌握部分个人用户的局部子图信息。在此基础上,如果没有隐私防御或防御太弱,图数据包含的隐私信息(如关系隐私、结构隐私等)将会被泄露。因此,对高度关联的分布式图数据的各种统计指标进行隐私保护共享发布,且不泄露用户身份隐私以及用户间的关系隐私,或将成为以图数据为驱动的信息服务领域中尤为迫切的挑战之一。




图 1.1 分布式图数据发布过程中存在的威胁模型

同时,在真实图数据应用中,往往需要同时发布多种图数据统计指标,其中各统计指标结构特性各不相同,且各用户的隐私偏好不一^[41-42],需要平衡分布式图数据上各节点的隐私需求以及数据效用间的冲突,同时优化隐私保护机制,尽可能降低扰动加噪对数据效用的影响。此外,直接应用现有的算法来组合完成多统计指标的隐私保护发布,一方面会增加分布式用户与数据收集者间的通信开销,另一方面会增加存储和计算开销,再一方面各个算法的隐私保护强度不一,难以实现统一的隐私保护效果,且无法满足各节点的个性化隐私保护偏好需求。对此,若利用经典 DP 方案对分布式图数据的所有结构统计信息进行保护并发布,容易造成额外的计算开销,更甚者会加剧图数据隐私的泄露风险。为此,有针对性的研究分布式图数据统计信息的差分隐私保护模型与算法成为一种必然。

1.2 国内外研究现状

自 DP 被应用于图数据隐私保护以来,取得了重要的进展,在图数据发布场景中得到了广泛的推广。尤其是在图统计数据发布方面,如度分布直方图发布^[6,19-20,22,43-45]、三角计数发布^[26-28,33]、聚类系数发布^[25,32]、生成图发布^[24,29-30]以及属性图发布^[31,46]等,均不同程度地拓展了基于集中式 DP 和分布式 DP 的隐私保护发布模型。本节主要围绕集中式场景下以及分布式场景下基于 DP 的图数据发布研究进行相关工作分析,并进一步拓展 SDP 的研究现状。

1.2.1 集中式场景下基于 DP 的图数据发布研究现状

DP 最早由 Dwork^[12]提出,主要应用于集中式场景下关系型数据库的统计信息隐私保护。直至 2009 年, Hay 等人^[19]首次利用 DP 提出一种后置噪声优化算法,进而实现图数据度分布直方图安全发布。同时, Hay 等人结合 DP 和图数据的结构化性质,提出了 DP 在图数据领域的两种变体,分别为 Edge-DP 和 Node-DP。至此, DP 便被广泛应用于图数据的隐私保护研究当中。

Kasiviswanathan 等人^[43]结合 Node-DP 隐私机制,提出一种去除原始图中度大于 θ 的顶点的投影方法,实现低敏感度的度分布直方图算法。然而,由于误删了许多非必要的信息,使得该方法会造成大量有效信息的损失。为了解决此问题, Day 等人^[20]提出一种加边机制 π_θ 对原始图进行投影,删除原始图中所有边后按稳定排序进行加边,进而在投影图的基础上统计度分布并添加噪声后发布。但是,该方法存在着度排序的不稳定性,使得不能最大程度的保留原始图的有效信息。对此,张宇轩等人^[22]提出一种基于度排序的边移除(Sequence Edge-Removal, SER)投影方法发布度分布直方图,通过设置节点度的上限,依据度大小顺序进行删边,

在降低敏感度的同时,尽可能保留原始图的更多边信息。Sala 等人^[47]提出使用图数据的 dK-2 序列来实现图数据生成。具体而言,首先针对每条边,提出两端节点度,构成 dK-2 序列。然后依据序列中较大的对序列进行排序,并将其划分成子序列,最后对各个子序列中的节点度的元组添加拉普拉斯噪声,并依据扰动后的序列生成图并将其进行发布。Karwa 等人^[48]针对子图统计等问题提出了局部敏感度的概念。只考虑边的增删对当前数据集的影响而非任意数据集的影响从而降低敏感度,并进一步提出平滑敏感度及柯西机制实现 Edge-DP 下的三角形计数的发布。除上述常见的统计数据外,Li 等人^[49]和 Li 等人^[50]引入拉普拉斯机制,提出 k 权重合并方法和个性化隐私分配方法,设计图数据边权重序列、 m 跳内的公开结点数量序列以及中介中心度的高效发布算法。

上述为部分集中式场景下基于中心化 DP(Centralized Differential Privacy, CDP)的图数据发布及应用的相关研究,其中所普遍存在的问题便是存储场景均假设在可信的第三方。然而,第三方是否真正可信依旧是发布数据隐私性的最大威胁,因此上述技术的安全性将存在较大的质疑。

1.2.2 分布式场景下基于 DP 的图数据发布研究现状

由于在位置服务网络、社交物联网等真实图数据应用场景中,往往不存在可信第三方,数据一般是被分布式持有在不同的用户或设备上。在此类场景中,各用户相互不信任,均不愿把自己的子图数据直接共享给彼此或数据收集者。因此,LDP^[24-33]被拓展应用于图数据隐私保护发布研究中。

早期,LDP 的提出是为了适应分布式场景的隐私保护,避免第三方直接窃取用户数据^[16]。直至 2017 年,Zhan 等人^[24]提出将 LDP 应用于图数据隐私保护发布,并提出了边-LDP(Edge-LDP)和点-LDP(Node-LDP)概念。其通过在分布式端迭代收集用户节点度值并采用 k -means 算法聚合获取生成图;但由于该方案仅通过度值进行聚类,所得到的生成图缺少大量原始图中的结构特性。为了提高数据效用,Ye 等人^[25]通过引入随机响应(Random Response, RR)机制^[51]扰动用户的子图邻接向量,并采用拉普拉斯机制采集用户度值,提出一种基于 LDP 的图聚类系数和模块化发布框架。而后,Imola 等人^[26]引入 2 轮交互模型,将加噪后的子图邻接向量合成噪声图后发送给用户,由各用户分别估计三角计数后将整体三角计数结果进行报告,并最终由数据收集者统一发布全局计数信息。然而,Ye 等人^[25]和 Imola 等人^[26]的方法都会产生大量噪声边,从而影响最终发布结果的精度。为了解决该问题,Hou 等人^[41]通过设计一种基于最优长度度向量编码模型对图数据进行分散聚类,但该方法仅适用于图数据聚类。为了获得更好的数据效用,Sun 等人^[27]和 Liu 等人^[28]通过减弱分布式图数据的隐私保护假设,允许各用户和

邻居交换各自的邻居信息（即各用户持有的二阶子图信息），分别设计了隐私保护的分布式图数据子图计数算法。此外，针对二元属性图数据的隐私保护，Wei 等人^[31]提出一种随机跳转（random jump, RJ）的分布式属性图数据度分布发布算法，并将 RR 机制应用于发布用户的二元属性，在此基础上，通过抽样方法构建整体的二元属性图数据用以数据分析。

进一步地，考虑到数据规模的增长及隐私保护需求的增强，Edge-LDP 的隐私保护强度难以满足同时保护多条边的隐私需求。因此，为了提高对图数据的隐私保护水平，Fu 等人^[42]提出基于 Node-LDP 的两阶段图数据聚类框架，通过剪影系数测量模型进行节点聚合，并利用自适应加噪来提高聚类结果的效用。Liu 等人^[45]结合点 Node-LDP 和密码投影方法提出一种最优图投影参数选择方法，并基于此提出 Node-LDP 下的度分布发布算法，但度值的敏感度过大，使得度分布发布结果效用不高。

由此可见，尽管 LDP 可避免第三方威胁，但其严格的隐私定义和图数据的结构关联性也使得最终发布数据效用过低，并且所提算法往往只能满足单一图数据统计的发布。同时，若需要进一步提升隐私保护强度，采用 Node-LDP，将会带来更为严峻的效用问题。

1.2.3 SDP 研究现状

SDP^[35-40]能有效平衡 CDP 及 LDP 的缺点，其核心为 ESA(Encoder-Shuffler-Analyzer)框架^[34,40]，由编码器(Encoder)、混洗器(Shuffler)及分析器(Analyzer)组成。该模型通过混洗器将分布式用户输入的带噪数据进行混洗，切断数据与发送者的关联，以在实现数据 DP 保护的同时隐藏用户身份隐私。

Balle 等人^[36]讨论了混洗机制所带来的隐私收益，并理论证明了使用隐私预算为 ϵ 的广义随机响应(Generalized Random Response, GRR)机制扰动分布式用户数据，再经过混洗，隐私保护程度可提升至 $\sqrt{14\ln(2/\sigma)(e^\epsilon + d - 1)/(n-1)}$ ，其中为 GRR 机制的扰动域大小。该理论被称之为隐私放大，是 ESA 框架下混洗操作对隐私效果增强的理论分析。但当 d 过大时，该机制仍会影响发布数据的有效性。在此基础之上，Wang 等人^[37]分别基于优化一元编码(Optimal Unary Encoding, OUE)和优化本地哈希(Optimal Local Hash, OLH)和 SDP 提出了 SOUE(Shuffled OUE)与 SOLH(Shuffled OLH)，用以发布分布式用户数据，一定程度上提高了发布后的数据效用，但若原始数据值域过大，数据效用和开销仍会受到影响。为了进一步降低原始数据值对数据效用的影响，Li 等人^[38]在 SDP 的基础上，分布式用户向混洗器发送 s 条假数据和 1 条加噪数据，并结合隐私放大理论提高数据效用，增加了通信开销。Cheu 等人^[52]提出了布尔随机响应机制的隐私放大定理，

并给出了对应随机响应机制隐私放大后的上界。在 Cheu 等的基础之上, Feldman 等人^[53]提出了随机响应机制隐私放大后的最优上界。

当前, SDP 模型已被应用于直方图发布^[54]、联邦学习中的表格数据^[55]、梯度^[56-57]以及多维数据的收集^[28]工作当中。张啸剑等人^[54]结合本地哈希编码技术所设计的混洗应答机制 SRR(Shuffled Randomized Response), 提出了一种基于 SDP 的直方图发布算法, 能够以线性分解的方式扰动用户数据以及摆脱数据值域大小的影响。Meehan 等人^[55]从公共辅助信息构建一个图, 并使用该图确定混淆数据的排列, 以减少再识别风险。刘艺菲等人^[58]提出了一种基于 SDP 的多维类别数据频率收集框架, 设计了基于单混洗器以及多混洗器的数据发布方案, 并提出了一种基于取值域填补的单混洗器数据发布方案。除上述数据发布和采集场景以外, Imola 等人^[59]提出了首个基于 SDP 的图数据全局三角计数发布算法。该算法引入一种用户对楔形洗牌采样方法, 实现全局三角计数的高精度发布。

综上, SDP 模型的提出, 在避免集中式场景下第三方威胁的同时, 也能一定程度地缓解分布式场景存在的效用问题。不幸的是, 诸如图数据三角计数序列、聚类系数等需要发布所有分布式用户局部信息进行计算的高维数据, 在引入 SDP 模型时极易被切断数据关联性, 且会造成实际 ϵ 被无限放大等问题。因此, 如何基于 SDP 实现图数据各类统计数据的高效发布, 且报告隐私上限, 仍亟待切实可行的技术解决方案。

1.3 研究内容及创新点

物联网、大数据及云计算等技术的快速发展使得海量数据发布、存储和处理变得便捷。而在不同类型的数据发布和共享中, 社交网络、社交物联网等产生的图数据可以表示不同实体间的复杂关系, 较关系、文本和图像等类型的数据在分析主体间复杂关联关系方面更具优势。然而, 图数据的节点和边表示的身份隐私、关系隐私和属性隐私相互关联, 尤其是在发布或共享分布式用户持有的图数据子集时, 具有更大的隐私泄露风险和保护难度。

传统基于 DP 的图数据发布算法无法有效避免第三方威胁以及数据效用过低等问题。同时, 现有的分布式图数据隐私保护方案大多基于 Edge-LDP 设计, 无法实现同时保护多条边隐私信息的强隐私保护, 且往往只能实现单一统计指标发布。针对此类问题, 本文首先基于 SDP 和方波(Square wave)^[60]扰动机制设计一种混洗差分隐私保护的度分布直方图发布算法, 以提升图数据度分布直方图发布的数据效用; 其次, 基于 SDP 和随机响应报告契形的思想, 提出一种基于混洗差分隐私的图数据聚类系数发布算法, 以提升聚类系数发布效用; 最后, 结合 Node-LDP 和 Edge-LDP, 面向分布式图数据统计发布隐私保护需求, 引入分组

对称一元编码(Symmetric Unary Encoding, SUE)、RR 及拉普拉斯机制, 并提出一种优化图噪声量的剪枝算法, 进而设计具备强隐私保护能力和高数据效用的多样化图统计指标发布算法。本文的研究内容及创新点可归纳如下:

(1)针对基于 CDP 和 LDP 的图数据度分布直方图发布算法无法有效平衡发布数据的隐私保护程度及其可用性, 且不能有效保护用户的身份隐私等问题, 设计混洗差分隐私保护的图数据度分布直方图发布算法。首先, 设计混洗差分隐私图数据度分布直方图隐私保护框架, 采取交互式用户分组、混洗器及方波本地加噪扰动机制降低编码器对分布式用户本地差分隐私加噪的噪声影响, 并利用极大似然估计在分析器端对加噪后的度分布直方图进行数据矫正, 从而提高数据效用; 其次, 提出具体的分布式用户分组、混洗差分隐私加噪和数据矫正算法, 理论验证算法提供的隐私保障及最终结果的无偏性; 最后, 与相关算法进行实验对比, 所提算法可提升 26%以上的效用。

(2)针对基于 CDP 和 LDP 的图数据聚类系数发布算法无法有效避免第三方威胁及数据效用问题, 以及混洗差分隐私难以发布高维图统计指标等挑战, 设计一种基于混洗差分隐私的图数据聚类系数发布算法。首先, 所有分布式用户分别通过 SDP、RR 和拉普拉斯机制向数据收集者报告每条边的楔形列表(2 跳路径信息)、邻接向量和度值。其次, 数据收集者结合收集到的噪声楔形列表、噪声邻接位向量和噪声度值, 估计并发布图数据的全局聚类系数。再次, 从理论上讨论了所提算法在不同 DP 下提供的隐私保护上界, 以及估计的聚类系数是无偏的。最后, 通过对真实数据集和生成数据集的实验, 与基于 LDP 的方案相比, GCC-SDP 的效用可分别提高 66.5%和 51%。

(3)面向分布式图数据隐私保护的 Node-LDP 和 Edge-LDP 模型无法有效处理隐私保护效果和数据有效性之间的冲突关系, 及常规算法仅能实现单一统计指标发布等挑战, 设计一种基于本地差分隐私的多统计指标发布算法。首先, 引入分组机制和 SUE, 提出一种满足 Node-LDP 的图数据度分布发布算法, 通过限制 SUE 扰动域上限的方式降低发布过程中的噪声输入, 实现 Node-LDP 保护的同时实施高效用的分布式图数据度分布发布; 其次, 基于所提出的度分布发布算法, 利用剪枝(Prune)算法对用户持有的子图进行剪枝, 通过设置度值阈值来对一阶邻居子图的邻居位向量进行剪切投影, 从而限制随机过程中所产生的噪声边的量, 通过大幅度降低无效噪声提高数据效用; 再次, 引入拉普拉斯机制、随机响应机制和 2 轮交互模型, 提出满足 Node-LDP 和 Edge-LDP 的三角计数序列发布算法及满足 Node-LDP 和 Edge-LDP 的聚类系数发布算法, 通过自适应隐私设置来调节满足 Node-LDP 和 Edge-LDP 以适应用户的个性化隐私偏好, 实现不同隐私保护强度和数据效用需求的分布式图数据多统计指标发布。

本文选取 Stanford Large Network Dataset Collection 网站上的多个公开真实数据集，与相关算法实验对比，并进一步分析各算法参数对实际效用的影响，以确保所提算法的优势。

1.4 章节安排

第一章：绪论部分集中阐述本文的研究背景及意义，并深度分析了国内外研究现状，阐释了当前基于差分隐私的图数据发布研究进展及潜在问题，进而指出研究内容及创新点。

第二章：理论知识部分主要介绍图数据基本定义及差分隐私相关理论知识，为后续章节的使用起到铺垫作用，其中包括差分隐私、本地差分隐私、混洗差分隐私、加噪机制等相关内容。

第三章：介绍混洗差分隐私保护的度分布直方图发布算法。该章首先介绍所提算法基本框架；其次，逐一介绍各个步骤细节以及对应算法，并给出相关理论；最后，选取对比算法及数据集，对本文算法效用进行实验分析。

第四章：介绍基于混洗差分隐私的聚类系数发布算法。该章首先介绍所提算法基本框架；其次，逐一介绍各个步骤细节及相关知识；再次，介绍整体算法以及算法整体提供的隐私及效用证明；最后，选取对比算法及数据集，对本文算法效用进行实验分析。

第五章：介绍基于本地差分隐私的分布式图统计发布算法。该章首先介绍所提算法的整体框架；其次，分别介绍各个统计指标发布算法及隐私效用分析；最后，与不同统计指标算法进行实验对比，分析所提算法效用优势。

第六章：总结与展望部分侧重于总结本文所做的工作内容，归纳所提算法取得的成果。同时，展望未来的研究工作，得出需进一步完善、优化的地方。

第2章 理论知识

本章将着重对文章中所涉及的基础定义及理论知识进行描述,为后续章节中的运用打下坚实基础。由于本文围绕基于差分隐私的图数据发布,构建基于混洗差分隐私和本地差分隐私的图数据发布方案,因此理论知识包括图数据和差分隐私的符号基础定义、差分隐私定义、本地差分隐私定义、混洗差分隐私定义、图上本地差分隐私理论、本地差分隐私加噪机制及差分隐私组合性质。

2.1 符号定义

本文所提方案均基于简单无向图 $G=(V,E)$,其中顶点集由 V 表示,边集由 E 表示,顶点集中的顶点数 $n=|V|$ 代表当前图 G 中的总用户数量。本文假设图 G 是分布式的,各用户在本地持有以自身为中心的星图,可称为一跳邻居子图。如图 2.1 所示,图 2.1(a)为一个全局图 G ,图 2.1(b)则为图 G 中用户 1(顶点 1)持有的分布式星图。用户可将其星图对应的邻接关系抽象为 1 个 n 维的邻接向量 $\mathbf{B}_i=(b_1,b_2,...,b_n)$,其中任意 $b_j \in \{0,1\}$ 为 $\mathbf{B}_i$ 中的第 j 位,代表用户 i 与用户 j 之间的关联关系, $b_j=1$ 表示用户 i 与用户 j 之间存在边,否则不存在边。 $\mathbf{M}=(\mathbf{B}_1,\mathbf{B}_2,...,\mathbf{B}_n)$ 为图 G 的邻接矩阵,由 G 中所有用户的邻接向量组成,代表全局用户的邻接信息。

$$d_i = \sum_{j=1}^n B_{ij} \text{ (或 } d_i = \sum_{j=1}^n b_j, b_j \in \mathbf{B}_i \text{)} \text{ 为用户 } i \text{ 的度值,代表用户 } i \text{ 的邻居数量,}$$

例如图 2.1 中,用户 1 的度为 5。 T_i 代表用户 i 所关联的三角计数,又称用户 i 的局部三角计数,即用户 i 关联的闭合三角形 $i-j-k-i$ 的个数。如图 2.1(c)所示,闭合三角形 1-5-3-1 属于用户 1、用户 3 以及用户 5 关联的三角形。 CC_i 代表用户 i 的局部聚类系数,可通过用户局部三角计数和度值进行计算,即

$$CC_i = \frac{2T_i}{d_i(d_i-1)},$$

其中 $T=(T_1,T_2,...,T_n)$ 和 $CC=(CC_1,CC_2,...,CC_n)$ 分别代表图 G 的三角计数序列及全局聚类系数。 ε 为差分隐私的隐私预算,用于控制噪声输入及保护强度。 ε 越小,保护强度越高,噪声量越大。




图 2.1 图数据示例

同时，本文通过 $W_{i,j} = (e_1, e_2, \dots, e_{n-2}) = (0, 1)^{n-2}$ 表示任意边 (i, j) 的契形列表，其中 $e_k \in \{0, 1\}$ 表示契形 w_{i-k-j} 是否存在，即二跳路径 $i-k-j$ 或 $j-k-i$ 是否存在。换言之，边 (k, i) 和边 (k, j) 均存在时，表示存在契形 w_{i-k-j} ， e_k 记为 1；否则存在契形 w_{i-k-j} ， e_k 记为 0。如图 2.2 所示，表示边 (i, j) 对应契形列表 $W_{i,j}$ 的采集过程，由图 G 中除用户 i 和用户 j 以外的其余 $n-2$ 个用户进行报告。若存在契形 w_{i-k-j} 报告 1，否则报告 0。 $W_{i,j}$ 中 1 的个数表示用户 i 和用户 j 之间的共同邻居的个数。 $W_i = (W_{i,1}, W_{i,2}, \dots, W_{i,n-1})$ 表示用户 i 所有边的契形列表， $W = (W_1, W_2, \dots, W_n)$ 表示图 G 中所有边的契形列表。




图 2.2 边契形列表示例图

为了便于阅读，表 2.1 中列出本文常用符号及其描述：

Table 1 Symbols

表 2.1 符号及其描述

符号	描述
ε	隐私预算
G	简单无向图
d_i	用户 i 的度值

B_i	用户 i 的一阶邻接向量
T_i	用户局部三角计数
CC_i	用户局部聚类系数
$n = V $	图 G 中总用户数量
T	图 G 中的三角计数序列
CC	图 G 的全局聚类系数
M	图 G 的邻接矩阵
W_{i-k-j}	二跳路径 $i-k-j$ 构成的契形
$W_{i,j}$	边 (i,j) 的契形列表
W_i	用户 i 所有边的契形列表
W	图 G 中所有边的契形列表

2.2 差分隐私

2.2.1 差分隐私

定义 2.1((ϵ, σ)-DP^[12]): 给定 n 个用户和随机算法 $\mathcal{A}$ ，若算法 $\mathcal{A}$ 作用在任意两个相邻数据集 D 和 D' 上，得到相同的输出结果 $y \in \text{range}(\mathcal{A})$ ，有

$$\frac{\Pr[\mathcal{A}(D) = y] - \sigma}{\Pr[\mathcal{A}(D') = y]} \leq e^\epsilon,$$

则算法 $\mathcal{A}$ 满足 (ϵ, σ) -DP。其中， $\epsilon \in \mathbf{R}^+$ 为 DP 的隐私预算， $\sigma \in (0, 1]$ 为隐私泄露概率，若 $\sigma = 0$ 时，则称为是纯的 DP，即 ϵ -DP。

定义 2.2((ϵ, σ)-Edge-DP^[19]): 给定 n 个用户和随机算法 $\mathcal{A}$ ，若算法 $\mathcal{A}$ 作用在任意两个相邻图 G 和 G' (二者仅一条边不同) 时，得到相同的输出结果 $y \in \text{range}(\mathcal{A})$ ，有

$$\frac{\Pr[\mathcal{A}(G) = y] - \sigma}{\Pr[\mathcal{A}(G') = y]} \leq e^\epsilon,$$

则算法 $\mathcal{A}$ 满足 (ϵ, σ) -Edge-DP。其中， $\epsilon \in \mathbf{R}^+$ 为隐私预算， $\sigma \in (0, 1]$ 为隐私泄露概率。

定义 2.3((ϵ, σ)-Node-DP^[19]): 给定 n 个用户和随机算法 $\mathcal{A}$ ，若算法 $\mathcal{A}$ 作用在任意两个相邻图 G 和 G' (二者相差一个顶点以及与顶点关联的边) 时，得到相同的输出结果 $y \in \text{range}(\mathcal{A})$ ，有

$$\frac{Pr[\mathcal{A}(G)=y]-\sigma}{Pr[\mathcal{A}(G')=y]} \leq e^\epsilon,$$

则算法 $\mathcal{A}$ 满足 (ϵ, σ) -Node-DP。其中, $\epsilon \in \mathbf{R}^+$ 为隐私预算, $\sigma \in (0,1]$ 为隐私泄露概率。

2.2.2 本地差分隐私

定义 2.4(ϵ -LDP^[16]): 给定 n 个用户和随机算法 $\mathcal{A}$, 若算法 $\mathcal{A}$ 作用在任意 2 条记录 t 和 t' 上得到相同的输出结果 t^* , 有

$$\frac{Pr[\mathcal{A}(t)=t^*]}{Pr[\mathcal{A}(t')=t^*]} \leq e^\epsilon,$$

则算法 $\mathcal{A}$ 满足 ϵ -LDP。其中, $t^* \in range(\mathcal{A})$ 为算法 $\mathcal{A}$ 的输出。

定义 2.5(ϵ -Edge-LDP^[24]): 当随机算法 $\mathcal{A}$ 作用在任意 2 个仅在 1 位上不同的邻接向量 $\mathbf{B}_i = (0,1)^n$ 和 $\mathbf{B}'_i = (0,1)^n$ 上时, 若算法 $\mathcal{A}$ 满足 ϵ -Edge-LDP, 则有

$$\frac{Pr[\mathcal{A}(\mathbf{B}_i)=\mathbf{S}]}{Pr[\mathcal{A}(\mathbf{B}'_i)=\mathbf{S}]} \leq e^\epsilon,$$

其中 $\mathbf{S} = (0,1)^n \in range(\mathcal{A})$, 即算法 $\mathcal{A}$ 的输出。

定义 2.6(ϵ -Node-LDP^[24]): 当随机算法 $\mathcal{A}$ 作用在任意 2 个邻接向量 $\mathbf{B}_i = (0,1)^n$ 和 $\mathbf{B}'_i = (0,1)^n$ 上时, 若算法 $\mathcal{A}$ 满足 ϵ -Node-LDP, 则有

$$\frac{Pr[\mathcal{A}(\mathbf{B}_i)=\mathbf{S}]}{Pr[\mathcal{A}(\mathbf{B}'_i)=\mathbf{S}]} \leq e^\epsilon,$$

其中 $\mathbf{S} = (0,1)^n \in range(\mathcal{A})$, 即算法 $\mathcal{A}$ 的输出。

在分布式图数据应用场景下, ϵ -LDP 仅满足发布数据的隐私性, 并不考虑数据间的关联性, 如顶点之间关联的边。在此基础之上, ϵ -Edge-LDP 和 ϵ -Node-LDP 可进一步考虑数据间的关联性, 需要在发布过程中保护用户间的边信息(关联信息); 不同的是, ϵ -Edge-LDP 是 ϵ -Node-LDP 的松弛, 它将任意 2 个邻接向量的邻接定义限制在 1 位(即 1 条边)。在此背景下, 设 Q_1, Q_2, Q_3 和 U_1, U_2, U_3 分别代表满足 ϵ -Node-LDP, ϵ -Edge-LDP 和 ϵ -LDP 时的隐私保护强度和效用精度。根据上述描述, 可得出结论, 在分布式图数据应用场景下, 隐私约束性(即隐私保护强度)上

$$Q_1 > Q_2 > Q_3;$$

反之, 在最终效用精度上

$$U_1 < U_2 < U_3.$$

2.2.3 混洗差分隐私

定义 2.7((ϵ, σ)-SDP^[58]): 任意分布式用户 i 在本地端对其所持有的数据 v_i (其中 $v_i \in D = \{1, 2, \dots, d\}$) 使用满足 ϵ_1 的本地差分隐私算法 $\mathcal{RR}$ 扰动, 即 $\mathcal{RR}(v_i) = y_i$, $Z = \{y_1, y_2, \dots, y_n\}$ 为 n 个用户的扰动结果, y_i 则表示为第 i 个用户的扰动后的结果。假设 $\mathcal{S}$ 为洗牌机制, 即 $\mathcal{S}: Y^n \rightarrow Y^n$ 表示洗牌器对 n 个用户的输出数据进行混洗打乱, 消除数据与用户间的关联。

设协议 $\mathcal{P} = \mathcal{RR} \circ \mathcal{S}$ 为上述扰动及混洗的结合, 若协议 $\mathcal{P}$ 满足 (ϵ, σ) -SDP, 则仅当对任意两个相邻数据集 D 和 D^* , 其任意输出集 $y' \subset Y^n$, 有

$$\frac{\Pr[\mathcal{P}(D) \in y']}{\Pr[\mathcal{P}(D^*) \in y']} \leq e^\epsilon.$$

定义 2.8(二项机制^[36-37]): 在混洗差分隐私模型中, 通过将 $\text{Bin}(n, q)$ 的噪声独立添加到直方图的每个分量中, 二项机制满足 (ϵ, σ) -DP, 其中

$$\epsilon = \sqrt{14 \ln \left(\frac{2}{\sigma} \right) / (nq)}.$$

定义 2.9(隐私放大理论^[53]): 给定 n 个用户和隐私预算 ϵ_L , $x_i \in X$ 为第 i 个用户的输入数据, 其中 $i \in \{1, 2, \dots, n\}$ 。设 $\mathcal{R}: X^n \rightarrow Y^n$ 为一个能提供 ϵ_L -LDP 的本地化随机器, 即 $\mathcal{R}(x_i) = y_i$; 设 $\mathcal{S}$ 为洗牌机制, 即 $\mathcal{S}: Y^n \rightarrow Y^n$ 表示洗牌器对 n 个用户的输出数据进行混洗打乱, 消除数据与用户间的关联。设协议 $\mathcal{P} = \mathcal{R} \circ \mathcal{S}$ 为上述扰动及混洗的结合, 若协议 $\mathcal{P}$ 满足 (ϵ, σ) -DP, 有

$$\epsilon = f(n, \epsilon_L, \sigma) = \log \left\{ 1 + \frac{e^{\epsilon_L} - 1}{e^{\epsilon_L} + 1} \left[\frac{8\sqrt{e^{\epsilon_L} \log(4/\sigma)}}{\sqrt{n}} + \frac{8e^{\epsilon_L}}{n} \right] \right\},$$

其中 $\sigma \in (0, 1]$, $\epsilon_L \leq \log \left\lceil \frac{n}{16 \log(2/\sigma)} \right\rceil$ 。

2.3 噪声机制及理论

定义 2.10(ϵ -RR^[51]): 设算法 $\mathcal{RR}$ 为 ϵ -RR, 用户通过算法 $\mathcal{RR}$ 扰动数据的过程为: 对任意二进制数据 $x \in \{0, 1\}$, 用户以 p 的概率发送真实值 x , 以 q 的概率发送 $1-x$, 即

$$\Pr[\mathcal{RR}(x) = y] = \begin{cases} p = \frac{e^\epsilon}{e^\epsilon + 1}, & \text{if } y = x, \\ q = \frac{1}{e^\epsilon + 1}, & \text{otherwise,} \end{cases}$$

满足以上条件，则 ε -RR 满足 ε -LDP，其中 $x, y \in \{0, 1\}$ 分别为输入数据和输出数据。

定义 2.11(SW 机制^[60]): 用户对输入域为 $D = \{0, 1, \dots, d-1\}$ 中的数据进行随机化，输出域为 $D' = \{-R, 1-R, \dots, 0, 1, \dots, d, d+1, \dots, d+R-1\}$ 。对任意的输入值 $x \in D$ ，若 SW 满足 ε -LDP，有

$$Pr[SW(x) = x'] = \begin{cases} p = \frac{e^\varepsilon}{(2R+1)e^\varepsilon + d - 1}, & \text{if } |x - x'| \leq R, \\ q = \frac{1}{(2R+1)e^\varepsilon + d - 1}, & \text{otherwise,} \end{cases}$$

其中 $x' \in D'$ ， R 称为加噪跳转半径， $|D| = d$ ， $|D'| = d + 2R$ 。

定义 2.12(ε -SUE^[15]): 用户通过 ε -SUE 扰动数据的过程为：对任意 o 维的实值数据 $x \in \{1, 2, \dots, o\}$ 。首先，用户将其编码为 1 个 o 维的二元向量，即 $Encode(x) = (0, \dots, 0, 1, 0, \dots, 0)$ ，其中除第 x 位为 1 外，其余位全为 0。随后，用户对编码数据进行逐位扰动($\varepsilon/2$ -RR)，即

$$Pr[Encode'(x)_i = 1] = \begin{cases} p, & \text{if } Encode(x)_i = 1, \\ q, & \text{if } Encode(x)_i = 0, \end{cases}$$

该过程满足 ε -LDP。其中， $p = \frac{e^{\varepsilon/2}}{e^{\varepsilon/2} + 1}$ ， $q = 1 - p$ 。

定义 2.13(全局敏感度，GS^[7]): 对于任意 1 个实际值的查询函数 $f: D \rightarrow \mathbb{R}$ ，其全局敏感度定义为

$$GS_f = \max_{D, D'} \|f(D) - f(D')\|_1,$$

其中 D 和 D' 表示为相邻数据集。

定义 2.14(Laplace 机制^[22]): 对于给定的数据集 D 和实值查询函数 f ， GS_f 是 f 在数据集 D 上的全局敏感度，则随机算法 $\mathcal{M}: \mathcal{M}(D) = f(D) + X$ 满足 ε -DP。其中 $X \sim Lap(GS_f/\varepsilon)$ 是服从尺度参数为 GS_f/ε 的 Laplace 分布噪声。

值得注意的是，在 LDP 视角上，相邻数据集 D 和 D' 被转换成了相邻的邻接向量 $\mathbf{B}_i$ 和 $\mathbf{B}'_i$ 。例如，在 Edge-LDP 场景下报告度值 d_i ，删除任意 1 条边仅影响 $\mathbf{B}_i$ 中的 1 个比特位，因此敏感度为 1，即向 d_i 中添加 $Lap(1/\varepsilon)$ 的噪声便可满足 ε -Edge-LDP。

定理 2.1. 若通过 ε -RR 扰动 1 个 n 维的邻接向量 $\mathbf{B}_i = (0, 1)^n$ ，其满足 ε -Edge-LDP^[24]。

定理 2.2. 若通过 ε -RR 扰动 1 个 n 维的邻接向量 $\mathbf{B}_i = (0, 1)^n$ ，其满足 $n\varepsilon$ -Node-LDP。

证明： 设随机算法 $\mathcal{A}$ 为 ε -RR， $Pr[\mathcal{A}(x)=y]$ 表示为 $x \in \{0,1\}$ 随机翻转为 $y \in \{0,1\}$ 的概率。其中， $\mathbf{B}_i = (b_1, b_2, \dots, b_n)$ 和 $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_n)$ ($b_i, b'_i \in \{0,1\}$) 为 2 个相邻的邻接向量。不失一般性，假设 $\mathbf{B}_i, \mathbf{B}'_i$ 中每一位对应值都不一样，因此给定算法 $\mathcal{A}$ 的任意输出 $\mathbf{S} = (s_1, s_2, \dots, s_n), s_i \in \{0,1\}$ ，则有

$$\begin{aligned} & \frac{Pr[\mathcal{A}(\mathbf{B}_i) = \mathbf{S}]}{Pr[\mathcal{A}(\mathbf{B}'_i) = \mathbf{S}]} \\ &= \frac{Pr[\mathcal{A}(b_1) = s_1] Pr[\mathcal{A}(b_2) = s_2] \dots Pr[\mathcal{A}(b_n) = s_n]}{Pr[\mathcal{A}(b'_1) = s_1] Pr[\mathcal{A}(b'_2) = s_2] \dots Pr[\mathcal{A}(b'_n) = s_n]} \\ &< \frac{p^n}{q^n} = e^{n\varepsilon}。 \end{aligned}$$

因此，算法 $\mathcal{A}$ (ε -RR) 满足 $n\varepsilon$ -Node-LDP。

证毕。

根据定理 2.1 和定理 2.2 可知，在同 ε 情况下对 n 维的邻接向量进行扰动时，满足 ε -Node-LDP 和 ε -Edge-LDP 分别需要通过 ε/n -RR 和 ε -RR 进行扰动。显然，相同隐私预算的情况下，满足 Node-LDP 时所需注入的噪声量要远高于 Edge-LDP。同理，安全级别上 Node-LDP 也要远优于 Edge-LDP。

2.4 差分隐私的组合性质

LDP 和 SDP 相较于 DP 的区别在于前二者将隐私保护处理过程从数据收集者端移至用户端，三者的核心仍旧是通过噪声机制将数据扰动加噪，从而达到隐私保护效果。同时，LDP 和 SDP 的后处理过程并不会影响最终的隐私保证，因此 LDP 和 SDP 也满足差分隐私的组合性质^[61]。

引理 2.1(序列组合性)^[62]：给定任意 n 个随机算法 $\{\mathcal{A}_i\}_{1 \leq i \leq n}$ 。其中，任意算法

$\mathcal{A}_i$ 满足 ε_i -DP，则按指定顺序组合后的算法 $\{\mathcal{A}_i\}_{1 \leq i \leq n}$ 满足 $\sum_{i=1}^n \varepsilon_i$ -DP。

引理 2.2(并行组合性)^[62]：给定任意 n 个随机算法 $\{\mathcal{A}_i\}_{1 \leq i \leq n}$ 。其中，任意算法

$\mathcal{A}_i$ 满足 ε_i -DP，同时 n 个算法所作用的数据集不相交，则由上述算法所构成的算法 $(\mathcal{A}_1(D_1), \mathcal{A}_2(D_2), \dots, \mathcal{A}_n(D_n))$ 满足 $\max_{1 \leq i \leq n} \{\varepsilon_i\}$ -DP。

2.5 本章小结

本章围绕基于差分隐私的图数据发布进行理论知识介绍，首先，给出图数据的基础符号定义；其次，给出差分隐私、本地差分隐私及混洗差分隐私的理论机

制；再次，描述常用的分布式扰动机制，并针对图上本地差分隐私所满足的隐私保障进行相应的分析；最后，给出差分隐私的组合性质，为后续方案满足的理论证明进行铺垫。

第3章 混洗差分隐私保护的度分布直方图发布算法

在图数据度分布直方图发布过程中，CDP 需要可信第三方作为数据收集者，安全隐患较大；LDP 需要每个用户均向发布数据中添加随机噪声，使得数据效用不高。此外，在社交网络、IoT 网络和位置服务网络等分布式图数据度分布发布场景应用时，上述两种方法都无法保护分布式用户的身份隐私。

因此，为解决图数据度分布直方图发布场景下 CDP 和 LDP 存在的安全问题和数据效用问题，本章提出一种面向分布式场景的混洗差分图数据度分布直方图发布算法(Graph-SDP)。首先，结合混洗差分和对称加密提出一种新型图数据度分布直方图隐私保护框架；其次，设计分布式节点度的随机响应机制和分组扰动混洗机制，实现保护用户身份隐私的同时减少噪声量；再次，基于期望最大(Expectation-Maximum, EM)算法对混洗后的度分布数据进行分组修正，提高最终图数据度分布的数据效用；最后，基于大规模数据集进行实验，与相关算法进行对比，表明所提算法具有隐私保护和数据效用双重优势。

3.1 混洗差分隐私保护的度分布直方图发布算法

本节面向分布式图数据的度分布直方图发布，提出混洗差分隐私保护框架，阐述核心部分所改进的分组加噪编码器、分组混洗器和 EM 估计算法校正的分析器，并给出混洗差分算法和具体分析与证明。

场景假设是在分布式端收集各用户度值 d_i 以发布度分布直方图，而分布式端各用户所持有的度值在一般情况下仅用户自身知晓。因此对分析器端而言，最大度值甚至可能接近 n ，过大的值域将严重影响发布数据的效用，因此本文提出将用户进行分组，进一步保证发布数据的精确性。

3.1.1 图数据度分布直方图发布的混洗差分隐私保护框架

图 3.1 揭示了围绕图数据度分布直方图所提出的混洗差分隐私保护模型，主要包含改进的编码器、混洗器和分析器。主要思想是：首先，分布式用户拥有完整图数据某一节点的一跳邻居子图，所有用户通过编码器分组将各用户拥有的节点度值进行本地差分隐私扰动，再经过混洗器对用户输入数据分组洗牌，切断分布式用户与输入数据间的关联，隐藏用户身份隐私；其次，分析器估值校正所有用户发布的度分布直方图数据；最后，发布隐私保护后的图数据度分布直方图。

在该模型中，所有用户根据自身持有图数据节点的度值 d_i 和分组距离 d ，将

自身划分到对应的分组 Group j 中，编码器根据分组数量 $S+1$ 生成 $S+1$ 个子编码器(其中 $j \in \{0,1,...,S\}$)，每个子编码器对相应分组的度数据进行隐私预算为 ε_j 的 SW 机制差分隐私加噪；混洗器生成 $S+1$ 个子混洗器，分别对 $S+1$ 个分组内加噪后的节点度值进行混洗，保护分布式用户的身份隐私；分析器对各混洗器混洗后的节点度值数据进行汇总，形成加噪和用户身份隐私保护后的分组度分布直方图数据，然后利用 EM 算法对各组度分布直方图数据进行校正，聚合得到最终发布的图数据度分布直方图。




图 3.1 图数据度分布直方图的混洗差分隐私保护框架

图 3.1 所示的图数据度分布直方图发布的混洗差分隐私保护框架需要根据图数据的实际情况适当选择用户子图节点度分组的组距 d 和隐私预算 ε 。为有效降低差分隐私的噪音量，需要用户从分析器端获取子图节点度值的分组组距、隐私预算以及分组后各组用户数量。本章设计了两轮交互机制来实现这一目标，具体流程包含 10 个交互迭代步骤，如图 2 所示。

第一轮交互，主要在保障用户身份隐私的同时获取各组用户数量以计算各组实际扰动所需的隐私预算 ε_j ，包含步骤①-⑤。第①步，分析器根据当前图数据分布式规模及经验向用户发送对称加密算法密钥、组距 d 及隐私预算 ε 、 σ 等参数；第②步，用户结合组距 d 及自身度 d_i 计算对应的组号 g_i ，其中($g_i = \lfloor d_i/d \rfloor$ ， $i \in \{1,2,...,n\}$)；第③步，用户通过对称密钥将组号 g_i 加密并发送至混洗器；第④步，混洗器对所有用户的密文数据进行混洗后发送至分析端；第⑤步，分析器解

密用户密文，统计分组数量 $S+1$ (其中 $S = \max_{1 \leq i \leq n} (g_i)$)，后续依次统计各组用户数量 $\{n_0, n_1, \dots, n_S\}$ 并发送至各用户。

第二轮交互，主要确定各组子图节点度扰动所需的参数 ε_j 及 R_j ，并进行 ε_j -本地差分隐私扰动、子图节点度值混洗和加噪后的度分布直方图校正，包括步骤⑥-⑩。第⑥步，用户从分析器获取当前组的用户数量 n_j ，(其中 n_j 为第 j 组的用户数量，即 $g_i = j$ 的数量， $j \in \{0, 1, \dots, S\}$)；第⑦步，用户结合所获取的参数 ε 、 σ 、 d 及 n_j 计算实际扰动所需的隐私预算 ε_j 及加噪跳转半径 R_j ；第⑧步，各组用户通过编码器对度值 d_{j_s} 进行 ε_j -SW 扰动，得到加噪后的度值数据 d'_{j_s} ，并将噪声数据发送至对应组号的混洗器(其中 d_{j_s} 为第 j 组中用户 s 的度， d'_{j_s} 为第 j 组中用户 s 的噪声度($s \in \{1, 2, \dots, n_j\}$)；第⑨步，混洗器分别混洗各组噪声数据并发送至分析器；第⑩步，分析器统筹各组度数据的噪声分布并通过 EM 算法校正各组的度分布，随后分析器聚合具备混洗差分隐私保护的度分布直方图 F' 。




图 3.2 图数据度分布直方图的混洗差分隐私保护流程

基于图 3.2 所示的图数据度分布直方图的混洗差分隐私保护流程中，用户、编码器和分析器在不同的步骤中需要计算不同的参数，并进行混洗差分隐私加噪、加噪数据矫正等操作。

为便于理解，本节将具体算法分为 4 个小节，3.1.2 节介绍各组用户数量的计算算法(第⑤步)，该步骤主要用于获取各组数量从而计算隐私放大后的参数；3.1.3 节阐述最优隐私预算及加噪跳转半径的计算算法(第⑦步)；3.1.4 节及 3.1.5 节分别阐述混洗差分隐私保护的图数据度分布加噪算法及矫正算法(第⑧及第⑩步)。其中，3.1.4 节的加噪算法及 3.1.5 节的矫正算法为 Graph-SDP 的核心算法。

3.1.2 各用户组的用户数量计算算法

在 Graph-SDP 算法中，后续加噪参数计算过程需知晓各组用户数量，然而各分布式用户无法直接获取其所在分组的用户数量。因此，各分布式用户首先获取分析器广播的加密算法密钥和组距 d ；其次，各用户需要利用自身的子图节点度 d_i ，结合组距 d 计算其对应的组号 $g_i = \lfloor d_i/d \rfloor$ ，并进一步通过混洗器与分析器进行交互发送自身加密过后的用户组号 $enc(g_i)$ ；最后，分析器解密所有密文数据进行统计，获取各个组的用户数量。具体交互计算过程如算法 3.1 所示。

算法 3.1 各用户组的用户数量计算算法

输入：各个组的扰动范围(组距) d

输出：各组用户数 $\mathbf{N} = \{n_0, n_1, \dots, n_S\}$

用户端：

1. for i in $\{1, 2, \dots, n\}$ do // n 为整个 $G=(V, E)$ 中的用户数量， $n=|V|$
2. $g_i = \lfloor d_i/d \rfloor$ // 组号从 0 开始
3. $C_i = enc(g_i)$ // 将组号加密
4. Send C_i to Shuffler
5. end

混洗器：

6. $(C'_1, C'_2, \dots, C'_n) = Shuffle(C_1, C_2, \dots, C_n)$ // Shuffler 打乱所有密文数据

分析器：

7. for i in $\{1, 2, \dots, n\}$ do
8. $g'_i = decrypt(C'_i)$
9. end
10. Calculate maximum group number by $\{g'_1, g'_2, \dots, g'_n\}$:

$$S = \max_{1 \leq i \leq n} (g'_i)$$

// 组号从 0 开始，最大的 g'_i 则为最后一组组号 S ，分组数量为 $S+1$

11. for j in $\{0, 1, \dots, S\}$ do

12. $num_j = \sum_1^n (\text{if } g'_i = j)$

13. end

14. $\mathbf{N} = \{n_0, n_1, \dots, n_S\}$

15. Return $\mathbf{N}$

算法 3.1 中，步骤 1 至 6 操作由用户端和混洗器完成。首先，用户端完成自身所在用户组组号的计算，并对组号进行加密，发送给混洗器；其次，混洗器将所有用户加密后的组号进行混洗，随后发送至分析器。步骤 7 至 15 操作由分析器完成，分析器对收到的所有加密组号进行解密，并对各相同明文组号的数量，即各用户分组的用户数量进行汇总。值得注意的是，分析器仅需通过对密文数据进行解密，并统计各组号的数量，因此此处混洗操作仅提供匿名作用。

在算法 3.1 中，每个用户仅需调用一次对称加密机制(如 AES 算法)将自己计算的组号进行加密，用户时间复杂度和空间复杂度均为 $O(1)$ 。混洗器打乱 n 个用户输入数据顺序整体所需的时间复杂度为 $O(1)$ ，空间复杂度为 $O(n)$ 。对于混洗器发送的 n 个用户的组号，数据收集者需要统计总共有多少组并计算各组内用户数量，因此在分析器端，分析器统计过程所需的时间复杂度为 $O(n)$ ，空间复杂度为 $O(S)$ (S 为分组数量)。

3.1.3 各组用户的隐私预算及加噪跳转半径计算算法

在 3.1.1 节图 3.2 所示的⑦步中，需计算各组用户扰动所需的隐私预算 ε_j 及加噪跳转半径 R_j (对任意组 j 中的任意两个用户 i 和 t ，有 $j = g_i = g_t$ ， $\varepsilon_j = \varepsilon_{g_i} = \varepsilon_{g_t}$)。因此，在编码器对各用户度数据加噪扰动前，需由各分布式用户结合分析器发布的参数 ε 、 σ 、 d 及 n_j 计算当前组实际扰动所需的隐私预算 ε_j 及加噪跳转半径 R_j ，后续依次由编码器及混洗器对各组度数据进行 ε_j -SW 扰动及混洗操作。

为了完成上述计算，本小节首先论证 SW 扰动及混洗过程满足 (ε, σ) -SDP 时，各组用户实际扰动所需的隐私预算 ε_j ；其次，提出各分组用户扰动所需隐私预算 ε_j 及加噪跳转半径 R_j 等参数的计算步骤。为避免 ε_j 及 R_j 选取相互依赖的问

题，本节提出一种 R_j 选取方法，并基于该方法提出各分布式用户在本地端所需进行的计算操作算法。

定理 3.1: 在混洗差分隐私模型中，给定 ε_1 -LDP 的 SW 算法扰动本地数据，则这些加噪扰动后的数据经过混洗后满足 (ε, σ) -SDP，且

$$\varepsilon = \sqrt{\left\{14 \ln \left(\frac{2}{\sigma}\right) [(2R+1)e^{\varepsilon_1} + d - 1]\right\} / (n-1)}。$$

其中， R 为本地数据进行 SW 扰动所需的加噪跳转半径。

证明: 在混洗差分隐私模型中，对任意 $d_i \in D$ ($D = \{0, 1, \dots, d-1\}$)，经过 ε_1 -LDP 的 SW 算法扰动后，噪声服从二项分布

$$\text{Bin}\left(n-1, q = \frac{1}{(2R+1)e^{\varepsilon_1} + d - 1}\right)。$$

在此基础之上，依据定义 2.5 可知，利用上述二项分布噪声机制对原始数据 D 加噪，洗牌后该协议满足 (ε, σ) -SDP，其中

$$\varepsilon = \sqrt{\left\{14 \ln \left(\frac{2}{\sigma}\right) [(2R+1)e^{\varepsilon_1} + d - 1]\right\} / (n-1)}。$$

证毕。

定理 3.2: 对任意数据集 $D = \{0, 1, \dots, d-1\}$ 进行 ε -SW 扰动时，最优加噪跳转

半径为 $R = \left\lceil \frac{(\varepsilon e^\varepsilon - e^\varepsilon + 1)d}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)} \right\rceil。$

证明: 参照文献[60]中所提出的理论知识，假设 U 为 Graph-SDP 输入的随机变量， U' 为 Graph-SDP 输出的变量， U 与 U' 之间的互信息可以用 U 与 U' 的微分熵以及条件微分熵之间的差来进行表示，即

$$I(U, U') = g(U) - g(U|U') = g(U') - g(U'|U)。$$

由于 $I(U, U')$ 的数量取决于输入数据的分布，该部分信息无法在执行过程中获取，因此可以选取 $I(U, U')$ 的一个上界，即 U' 均匀分布在 $D' = \{-R, 1-R, \dots, 0, \dots, d+R-1\}$ 上。此时，假设 W 为均匀分布在 D' 上的随机变量，依据文献[60]，有 $g(U') \leq g(W)$ 。因此，

$$I(U, U') = g(U') - g(U'|U) \leq g(W) - g(U'|U)。$$

同时， W 为均匀分布在 D' 上的随机变量，而 D' 的大小为 $2R+d$ ($|D'|=2R+d$)，故有 $g(W) = \ln(2R+d)$ 。而 $g(U'|U)$ 取决于 Graph-SDP 扰动机制，即

$$\begin{aligned}
g(U'|U) &= -\int_{\mathcal{V}} PR(U=v)[(2R+1)p \ln p + (d-1)q \ln q] \\
&= -[(2R+1)p \ln p + (d-1)q \ln q] \\
&= -\frac{(2R+1)e^\varepsilon}{(2R+1)e^\varepsilon + d - 1} \ln \left(\frac{e^\varepsilon}{(2R+1)e^\varepsilon + d - 1} \right) - \frac{(d-1)}{(2R+1)e^\varepsilon + d - 1} \ln \left(\frac{e^\varepsilon}{(2R+1)e^\varepsilon + d - 1} \right) \\
&= -\frac{(2R+1)\varepsilon e^\varepsilon}{(2R+1)e^\varepsilon + d - 1} + \ln[(2R+1)e^\varepsilon + d - 1]。
\end{aligned}$$

因此整体的互信息是依据参数 R 构成的一个函数，即

$$\frac{(2R+1)\varepsilon e^\varepsilon}{(2R+1)e^\varepsilon + d - 1} + \ln \left[\frac{2R+d}{(2R+1)e^\varepsilon + d - 1} \right]。 对该函数进行求导并设其为 0，可以得$$

$$\text{到 } R = \frac{(\varepsilon e^\varepsilon - e^\varepsilon + 1)d}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)} - \frac{(e^\varepsilon - 1)^2}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)}。$$

由于 ε 一般为小于 1 的数，其变化对 $\frac{(e^\varepsilon - 1)^2}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)}$ 的影响相对较小，且用户度均为整数，因此不失一般性，当隐私预算及组距为 ε 及 d 时，

$$R = \left\lfloor \frac{(\varepsilon e^\varepsilon - e^\varepsilon + 1)d}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)} \right\rfloor。 \quad \text{证毕。}$$

由定理 3.1，任意组 j 中的所有用户通过 SW 机制及混洗器加噪混洗子图度值时，若该混洗差分隐私模型满足 (ε, σ) -SDP，则当前组用户实际加噪扰动其度值所需的隐私预算为

$$\varepsilon_j = \ln \left\{ \left[(n_j - 1) \frac{\varepsilon^2}{14 \ln \left(\frac{2}{\sigma} \right)} - d + 1 \right] / (2R_j + 1) \right\}。$$

类似的，依据定理 3.2，任意组 j 中的用户使用 ε_j -SW 机制所需的加噪跳转半径为

$$R_j = \left\lfloor \frac{(\varepsilon_j e^{\varepsilon_j} - e^{\varepsilon_j} + 1)d}{2e^{\varepsilon_j}(e^{\varepsilon_j} - 1 - \varepsilon_j)} \right\rfloor。$$

易知各组实际所需的隐私预算 ε_j 及加噪跳转半径 R_j 计算相互依赖。为保证本文所提模型仍能提供一定的隐私收益，本文首先提出各分布式用户均利用分析器给定的初始参数 ε 及 d 计算初始加噪跳转半径 $\tilde{R}$ ；然后，当前组用户利用 $\tilde{R}$ 计

算当满足 (ε, σ) -SDP 时，加噪扰动其度值实际所需的隐私预算 ε_j ；最后，再利用隐私预算 ε_j 计算各自实际的加噪跳转半径 R_j 。具体分为如下 3 个步骤：

(1)所有分布式用户通过初始隐私预算 ε 、 σ 及组距 d 计算初始加噪跳转半径 $\tilde{R}$ ，保持初始参数均一致，即

$$\tilde{R} = \left\lfloor \frac{(\varepsilon e^\varepsilon - e^\varepsilon + 1)d}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)} \right\rfloor。$$

(2)任意组 j 中的用户可结合 $\tilde{R}$ 、 ε 及 n_j 等参数计算满足 ε -SDP 条件下的各用户实际加噪扰动其度值所需的隐私预算 ε_j ，即

$$\varepsilon_j = \ln \left\{ \left[\left(n_j - 1 \right) \frac{\varepsilon^2}{14 \ln \left(\frac{2}{\sigma} \right)} - d + 1 \right] / (2\tilde{R} + 1) \right\}。$$

(3)各用户分别依据计算出的隐私预算 ε_j 计算实际加噪扰动时的加噪跳转半径 R_j ，即

$$R_j = \left\lfloor \frac{(\varepsilon_j e^{\varepsilon_j} - e^{\varepsilon_j} + 1)d}{2e^{\varepsilon_j}(e^{\varepsilon_j} - 1 - \varepsilon_j)} \right\rfloor。$$

由此，各用户便可在本地端计算对应扰动所需的参数，具体如算法 3.2 所示。其中，分布式用户 i ($i \in \{1, 2, \dots, n\}$) 在确立自身组号为 g_i ($g_i \in \{0, 1, \dots, S\}$) 后，首先将自身的度 d_i 归一化为 $\tilde{d}_i$ ($\tilde{d}_i = d_i - g_i d$)，保持各组度的输入域 D 均为 $\{0, 1, \dots, d-1\}$ ($|D| = d$)。然后结合组内用户数量 n_{g_i} 、隐私预算 ε 、 σ 及组距 d 等参数计算当前组 $Group\ g_i$ 扰动所需的隐私预算 ε_{g_i} 以及加噪跳转半径 R_{g_i} (对任意两个用户 i 、 t ，若二者同处于组 j ，即 $j = g_i = g_t$ ，则 $\varepsilon_j = \varepsilon_{g_i} = \varepsilon_{g_t}$ ， $R_j = R_{g_i} = R_{g_t}$)。各分布式用户各自执行完算法 3.2 后，将计算好的参数 ε_{g_i} 、 R_{g_i} 及归一化后的度 $\tilde{d}_i$ 发送至对应编码器，由编码器对度值 $\tilde{d}_i$ 进行 ε_{g_i} -SW 扰动。

算法 3.2 分布式用户参数计算算法

输入：隐私预算 ε 、 σ ，度的分组范围 d ，各组用户数量 $\mathbf{N} = \{n_0, n_1, \dots, n_S\}$

输出: $\{m_1, m_2, \dots, m_n\}$ //各用户参数列表(用于编码器对度值扰动加噪)

1. for i in $\{1, 2, \dots, n\}$ do

$$2. \quad \tilde{d}_i = d_i - g_i d, g_i = \left\lfloor \frac{d_i}{d} \right\rfloor$$

3. Calculate $\tilde{R}$ by ε :

$$\tilde{R} = \left\lfloor \frac{(\varepsilon e^\varepsilon - e^\varepsilon + 1)d}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)} \right\rfloor$$

4. Calculate ε_{g_i} :

$$\varepsilon_{g_i} = \ln \left\{ \left[\left(n_{g_i} - 1 \right) \frac{\varepsilon^2}{14 \ln \left(\frac{2}{\sigma} \right)} - d + 1 \right] / (2\tilde{R} + 1) \right\}$$

//其中 n_{g_i} 是指第 i 个用户所处 *group* 中用户的数量, 若 $g_i = g_j$, 则 $n_{g_i} = n_{g_j}$

5. Calculate R_{g_i} :

$$R_{g_i} = \left\lfloor \frac{(\varepsilon_{g_i} e^{\varepsilon_{g_i}} - e^{\varepsilon_{g_i}} + 1)d}{2e^{\varepsilon_{g_i}}(e^{\varepsilon_{g_i}} - 1 - \varepsilon_{g_i})} \right\rfloor$$

//对任意用户 i 和 j , 若 $g_i = g_j$, 则有 $\varepsilon_{g_i} = \varepsilon_{g_j}$ 、 $R_{g_i} = R_{g_j}$

6. $m_i = (\tilde{d}_i, \varepsilon_{g_i}, R_{g_i}, g_i)$ #用户 i 参数列表

7. end

8. Return $\{m_1, m_2, \dots, m_n\}$

算法 3.2 主要由各分布式用户端进行操作。步骤 1 至步骤 2, 各用户计算所处组号 g_i ($g_i \in \{0, 1, \dots, S\}$) 并将度值归一化, 以保证分组后各组输入域大小一致; 步骤 3 至步骤 8, 用户首先结合初始隐私预算 ε 及分组距离 d 计算初始加噪跳转半径 $\tilde{R}$, 后依据参数 ε 、 σ 、 n_{g_i} 、 d 及初始加噪跳转半径 $\tilde{R}$ 计算当前组 *Group* g_i 对本地度值数据进行 SW 扰动及混洗过程满足 (ε, σ) -SDP 时实际扰动所需的隐私预算 ε_{g_i} 及加噪跳转半径 R_{g_i} 等参数。算法 2 中, 各分布式用户仅需在本地端将各项参数计算好后发送给分析器, 在此过程中, 用户所需的时间复杂度及空间复杂度均为 $O(1)$ 。

执行完算法 3.2 后, 各分布式用户将归一化后的度 $\tilde{d}_i$ 、隐私预算 ε_{g_i} 和加噪跳转半径 R_{g_i} 统一为 $m_i = (\tilde{d}_i, \varepsilon_{g_i}, R_{g_i}, g_i)$, 并发送 m_i 至编码器。编码器进行具体的本地差分隐私加噪扰动操作, 详见 3.2.3 节。

3.1.4 混洗差分隐私保护的图数据度分布加噪算法

在 3.1.1 节图 3.2 所示的第⑧步中, 编码器根据各用户组的隐私预算和子图度值加噪跳转半径, 以组为单位对各用户组中用户的原始度值数据进行 SW 机制本地加噪。在第⑨步中由混洗器对加噪后的各组度值数据分别进行混洗。本小节首先按照 SW 加噪机制给出各组原始度值数据的本地差分隐私加噪模型, 其次给出具体的本地差分隐私和混洗算法, 最后给出该算法满足混洗差分隐私的证明。

设任意组 j 中各用户混洗扰动度值时满足 (ε, σ) -SDP 实际所需的隐私预算和 SW 机制加噪跳转半径分别为 ε_j 和 R_j , 则该组度值数据的加噪模型为: 对任意 $d_{j_s} \in D (D = \{0, 1, \dots, d-1\})$, 有

$$\Pr[SW(d_{j_s}) = d'_{j_s}] = \begin{cases} p_j, & \text{if } |d_{j_s} - d'_{j_s}| \leq R_j, \\ q_j, & \text{otherwise,} \end{cases}$$

其中 $p_j = \frac{e^{\varepsilon_j}}{(2R_j + 1)e^{\varepsilon_j} + d - 1}$, $q_j = \frac{1}{(2R_j + 1)e^{\varepsilon_j} + d - 1}$, $d'_{j_s} \in D'$ ($D' = \{-R_j, \dots, 0, \dots, d + R_j - 1\}$), d_{j_s} 为第 j 组中用户 s 的度 ($s \in \{1, 2, \dots, n_j\}$)。

算法 3.3 为混洗差分隐私保护的图数据度分布直方图发布模型的混洗加噪算法, 基于算法 3.2 的输出参数以组为单位对各用户度值进行混洗扰动。具体而言, 如第 j 组, 编码器分别对组内所有分布式用户的子图节点度 d_{j_s} 进行本地差分隐私加噪, 加噪模型如前文所述; 加噪后由混洗器收集当前组所有用户的噪声数据 $\bar{D}_j = \{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$, 并对 $\bar{D}_j$ 中数据进行统一混洗, 即 $\tilde{D}_j = \text{Shuffle}(\bar{D}_j)$ (其中 $\tilde{D}_j$ 与 $\bar{D}_j$ 中仍为同一批数据, 仅初始顺序被混洗打乱, 以此消除输入数据与用户间的关联, 达到保护分布式用户身份隐私的作用)。算法 3.3 执行结束后, 混洗器统一将各组扰动混洗后的数据 $\tilde{D} = (\tilde{D}_0, \tilde{D}_1, \dots, \tilde{D}_S)$ 发送至分析器。

算法 3.3 混洗差分隐私保护的图数据度分布直方图加噪算法

输入: $\{m_1, m_2, \dots, m_n\}$

输出: $\tilde{D} = (\tilde{D}_0, \tilde{D}_1, \dots, \tilde{D}_S)$ //混洗后各组的带噪数据

编码器:

1.for j in $\{0, 1, \dots, S\}$ do

2. Collect current group user data by $\{m_1, m_2, \dots, m_n\}$:

$$H_j = \{m_{j_1}, m_{j_2}, \dots, m_{j_{n_j}}\}$$

// $H_j = \{m_{j_1}, m_{j_2}, \dots, m_{j_{n_j}}\}$ 为 $\{m_1, m_2, \dots, m_n\}$ 中组号为 j 的用户数据

3. get ε_j, R_j by $H_j = \{m_{j_1}, m_{j_2}, \dots, m_{j_{n_j}}\}$:

$$\varepsilon_j, R_j = m_{j_1}(\varepsilon_j, R_j)$$

//对任意组，组内所有用户扰动所需的隐私预算及加噪跳转半径 ε_j 、 R_j 均相等

4. for s in $\{0, 1, \dots, n_j\}$:

5. $d_{j_s} = H_{j_s}(d_{j_s}) = m_{j_s}(d_{j_s})$ //当前组第 s 个用户归一化后的度

6. ε_j -SW perturbation of data d_{j_s} :

$$\Pr[SW(d_{j_s}) = d'_{j_s}] = \begin{cases} p_j, & \text{if } |d_{j_s} - d'_{j_s}| \leq R_j, \\ q_j, & \text{otherwise,} \end{cases}$$

7. end

8. send $\{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$ to j -th Shuffler

9.end

混洗器:

10.for j in $\{0, 1, \dots, S\}$ do

11. $\bar{D}_j = \{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$ # $\bar{D}_j = \{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$ 为第 j 组的带噪数据, n_j 为该组的用户数量

12. $\tilde{D}_j = \text{Shuffle}(\bar{D}_j)$

13.end

14.Return $\tilde{D} = (\tilde{D}_0, \tilde{D}_1, \dots, \tilde{D}_S)$

算法 3.3 用以实现混洗差分隐私保护，其由编码器进行本地差分隐私加噪扰动，并由混洗器进行加噪后的数据混洗。步骤 1 至步骤 9，编码器对各组用户归一化后的度值数据分别进行 ε_j -SW 扰动并将带噪度数据发送至混洗器；步骤 10 至步骤 14，混洗器收集编码器发送的带噪数据，利用混洗机制消除数据与分布式用户间的关联，并发送至分析器。该算法执行过程中，混洗机制与 SW 扰动机制的结合能保障各组用户的身份隐私不被分析器获取，且整个过程满足 (ε, σ) -

混洗差分隐私，具体证明见定理 3.3。算法 3.3 中，编码器以组为单位对每组用户归一化后的度值进行加噪，其中 SW 机制的时间复杂度和空间复杂度为 $O(1)$ ，因此整个算法 3 中编码器所需的时间复杂度和空间复杂度均为 $O(n)$ 。同时，混洗器需对每组噪声数据进行依次混洗，混洗的时间复杂度为 $O(1)$ ，但混洗器需对 $S+1$ 组用户数据进行混洗，因此混洗器所需的时间复杂度为 $O(S+1)$ ，空间复杂度为 $O(n)$ (其中， n 为图 G 中用户数量，即顶点数)。

定理 3.3: 算法 3.3 满足 (ε, σ) -SDP。

证明: 对任意组 $group\ j$ 中任意两个输入值 $d_{j_1}, d_{j_2} \in D$ ，及任意输出 $z \in D'$ ，有

$$\frac{Pr[z | d_{j_1}]}{Pr[z | d_{j_2}]} \leq \frac{p}{q} = \frac{\frac{e^{\varepsilon_j}}{(2R_j+1)e^{\varepsilon_j} + d - 1}}{\frac{1}{(2R_j+1)e^{\varepsilon_j} + d - 1}} = e^{\varepsilon_j}。$$

因此，任意组 $group\ j$ 中用户通过的 ε_j -SW 扰动的度值满足 ε_j -LDP。依据 3.2.3 节的定理 3.1 可知，任意组 n_j 个用户在大小为 d 的取值范围上进行 SW 扰动时，若扰动算法满足 ε_j -LDP，则经过混洗器洗牌后满足 (ε, σ) -SDP，其中

$$\varepsilon = \sqrt{\left\{ 14 \ln \left(\frac{2}{\sigma} \right) \left[(2R_j+1)e^{\varepsilon_j} + d - 1 \right] \right\} / (n_j - 1)}。$$

虽各组内用户根据分析器发送的 ε ， σ 及组内用户数量 n_j 计算的 ε_j 不一定相等，但其初始隐私预算 ε ， σ 相等，所以任意 $group\ j$ 扰动混洗后的数据均满足 (ε, σ) -SDP。

由于 DP 具有并行性，且该性质适用于 LDP 及 SDP，因此，Graph-SDP 同样具有并行性。故，根据 DP 的并行性， $S+1$ 组的扰动混洗算法 $(\mathcal{S} \circ \mathcal{R}_0(D_0), \mathcal{S} \circ \mathcal{R}_1(D_1), \dots, \mathcal{S} \circ \mathcal{R}_S(D_S))$ 满足 $\max_{0 \leq i \leq S} \{(\varepsilon_i, \sigma_i)\}$ -SDP，且前述已证明任意 $group\ j$ 扰动混洗后的数据均满足 (ε, σ) -SDP，即 $\max_{0 \leq i \leq S} \{(\varepsilon_i, \sigma_i)\} = (\varepsilon, \sigma)$ 。因此，Graph-SDP 中混洗加噪算法(算法 3.3)满足 (ε, σ) -SDP。证毕。

3.1.5 混洗差分隐私保护的图数据度分布校正算法

在 3.1.1 节图 3.2 所示的第⑩步中，分析器接收到混洗后的噪声数据，将对

数据进行统计矫正以提升最终发布的图数据度分布直方图数据的效用。

首先，分析器收集各组带噪数据 $\tilde{D} = (\tilde{D}_0, \tilde{D}_1, \dots, \tilde{D}_S)$ 后，对各组带噪度分布进行汇总。例如：对组 j 中的带噪数据 $\tilde{D}_j$ ，统计噪声数据中 $\{0, 1, \dots, d-1\}$ 的分布 $\tilde{f}_j = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$ ，并计算该组用户扰动时使用的参数 p_j, q_j 及转换概率矩阵 $\mathbf{M}_j \in [0, 1]^{d' \times d}$ 。其中 $\mathbf{M}_j$ 用于描述当前组中数据的随机化过程， $M_{j_{l,s}}$ 表示当前组用户输出值为 l ，输入值为 s 的概率，即 p_j 或 q_j ， $s \in \{0, 1, \dots, d-1\}$ ， $l \in \{-R_j, \dots, 0, \dots, d+R_j-1\}$ ， $j \in \{0, 1, \dots, S\}$ ， $d' = d + 2R_j$ 。

其次，结合 $\mathbf{M}_j$ 及 $\tilde{f}_j = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$ ，通过极大似然估计 (Maximum Likelihood Estimation, MLE) 方法对各组带噪分布 $\tilde{f}_j$ 进行聚合校正。具体而言，构建 EM 算法重构分布 $f'_j = \{f'_{j_0}, f'_{j_1}, \dots, f'_{j_{d-1}}\} = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$ ，并结合对数似然函数 $L(f'_j) = \ln \Pr[\tilde{D}_j | f'_j]$ 找到最优分布 f'_j ，最优 f'_j 便为第 j 组校正后的分布。

如上所述，分析器可通过依次校正各组的分布得到最优分布 $\{f'_0, f'_1, \dots, f'_S\}$ 。最后，分析器归一化各组校正后的分布聚合得到具备混洗差分隐私保护的度分布直方图估计 $F' = \{f_0^*, f_1^*, \dots, f_S^*\}$ 。具体如算法 3.4 所示。

算法 3.4 混洗差分隐私保护的图数据度分布直方图校正算法

输入：隐私预算 ε ，组距 d ， $\tilde{D} = (\tilde{D}_0, \tilde{D}_1, \dots, \tilde{D}_S)$ ， $\mathbf{N} = \{n_0, n_1, \dots, n_S\}$

输出：度分布直方图 F' //该分布为对原始分布的估计

1. for j in $\{0, 1, \dots, S\}$ do //分别对每个组内的数据进行校正

2. Calculate $\tilde{f}_j$ by $\tilde{D}_j$:

$$\tilde{f}_j = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$$

//其中， $\tilde{f}_j$ 为 $\tilde{D}_j$ 中 $\{0, 1, \dots, d-1\}$ 的分布情况

3. Calculate p_j, q_j by ε, d and n_j :

$$\tilde{R} = \left\lfloor \frac{(\varepsilon e^\varepsilon - e^\varepsilon + 1)d}{2e^\varepsilon(e^\varepsilon - 1 - \varepsilon)} \right\rfloor, \varepsilon_j = \ln \left\{ \left[(n_j - 1) \frac{\varepsilon^2}{14 \ln\left(\frac{2}{\sigma}\right)} - d + 1 \right] / (2\tilde{R} + 1) \right\}$$

$$R_j = \left\lfloor \frac{(\varepsilon_j e^{\varepsilon_j} - e^{\varepsilon_j} + 1)d}{2e^{\varepsilon_j}(e^{\varepsilon_j} - 1 - \varepsilon_j)} \right\rfloor, p_j = \frac{e^{\varepsilon_j}}{(2R_j + 1)e^{\varepsilon_j} + d - 1}, q_j = \frac{1}{(2R_j + 1)e^{\varepsilon_j} + d - 1}$$

4. Calculate $\mathbf{M}_j$

5. $f'_j = \{f'_{j_0}, f'_{j_1}, \dots, f'_{j_{d-1}}\} = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$

6. While not converge do
7. E-step: $\forall i \in \{0,1,...,d-1\}$
- 8.

$$P_{j_i} = f'_{j_i} \sum_{l \in [d']} n_{j_l} \frac{\Pr[x' \in B'_l | x \in B_i, f'_j]}{\Pr[x' \in B'_l | f'_j]} = f'_{j_i} \sum_{l \in [d']} n_{j_l} \frac{M_{j_{l,i}}}{\sum_{s=0}^{d-1} M_{j_{l,s}} f'_{j_s}}$$

// 其中 n_{j_l} 为 $\tilde{D}_j$ 中值为 l 的数量, $x \in B_i$ 表示用户输入值为 i ($i \in [d] = \{0,1,...,d-1\}$), $x' \in B'_l$ 表示输出值为 l ($l \in [d'] = [-R_j, ..., 0, ..., d + R_j - 1]$)。

9. M-step: $\forall i \in \{0,1,...,d-1\}$

$$10. \quad f'_{j_i} = \frac{P_{j_i}}{\sum_{s'=0}^{d-1} P_{j_{s'}}}$$

11. end while

$$12. \quad f'_j = \{f'_{j_0}, f'_{j_1}, ..., f'_{j_{d-1}}\}$$

13. for i in $\{0,1,...,d-1\}$ do

$$14. \quad f_{j_i}^* = \frac{f'_{j_i} n_j}{n} \quad // \text{归一化}$$

// f'_{j_i} 为第 j 组中度为 i 的频率

15. end

$$16. \quad f_j^* = \{f_{j_0}^*, f_{j_1}^*, ..., f_{j_{d-1}}^*\}$$

17. end

$$18. F' = \{f_0^*, f_1^*, ..., f_s^*\}$$

19. Return $F' = \{f_0^*, f_1^*, ..., f_s^*\}$ //度分布直方图估计

算法 3.4 用以分析器对接收到的各组加噪混洗度值分布数据进行矫正, 进而聚合得到效用更高的图数据度分布直方图估计结果数据。步骤 1 至步骤 4 统计各组噪声数据 $\tilde{D}_j$ 中 $\{0,1,...,d-1\}$ 的分布 $\tilde{f}_j$, 并计算该组用户扰动所使用的参数 p_j, q_j 及转换概率矩阵 $\mathbf{M}_j$; 步骤 5 至步骤 12 结合 $\mathbf{M}_j$ 及 $\tilde{f}_j$, 构建 EM 算法对带噪分布 $\tilde{f}_j$ 进行聚合校正, 结合对数似然函数计算最优分布 f'_j ; 步骤 13 至步骤

19, 分析器对各组校正后的度分布估计 f'_j 进行归一化 ($f_j^* = \frac{n_j}{n} f'_j$), 聚合得到具备混洗差分隐私保护的度分布直方图估计 $F' = \{f_0^*, f_1^*, \dots, f_s^*\}$ 。其中, 步骤 5 至步骤 12 中由 EM 算法校正获得的分布 f'_j 收敛于真实分布 f_j , 具体证明见定理 3.4。

在此过程中, 分析器仅能获取近似原始图度分布的直方图估计, 无法知晓各组中数据来源于哪位用户, 同时也无法获晓数据原始值, 因此在该过程中分布式用户的身份隐私和度值数据均得到了安全保障。即便混洗器与分析器共谋, 各组数据仍能得到 ε_j -LDP 的隐私保护。此外, 由于分析器获取 $S+1$ 组中所有用户(即图 G 中 n 个用户)的噪声数据, 并对其进行合并校正, 所以算法 3.4 的时间复杂度和空间复杂度均为 $O(n)$ 。

定理 3.4: 对于任意组带噪数据 $\tilde{D}_j$, 经过算法 4 校正后的分布 f'_j 收敛于真实分布 f_j 的极大似然估计。

证明: 算法 3.4 实则是通过 EM 算法构建极大似然估计对带噪分布进行聚合校正, 若证明校正后的分布 f'_j 收敛于真实分布 f_j 的极大似然估计, 即证明 EM 算法收敛于 的极大似然估计。因此, 证明对数似然函数为凹函数即可。

对任意组带噪数据 $\tilde{D}_j$ 及其初始数据真实分布 f_j , 其对数似然函数有

$$L(f_j) = \ln \Pr[\tilde{D}_j | f_j] = \ln \left(\prod_{t=1}^{N_j} \Pr[\tilde{d}_{j_t} | f_j] \right) = \sum_{t=1}^{N_j} \ln \left(\sum_{i=1}^d f_{j_i} \Pr[\tilde{d}_{j_t} | x \in B_i] \right).$$

其中, $\Pr[\tilde{d}_{j_t} | x \in B_i]$ 是由算法 Graph-SDP 确定的常数, 即 p_j 或者 q_j ; $\tilde{d}_{j_t}$ 表示 $\tilde{D}_j$ 中第 t 位数据, $t \in \{1, 2, \dots, N_j\}$, $\tilde{D}_j = \{\tilde{d}_{j_1}, \tilde{d}_{j_2}, \dots, \tilde{d}_{j_{N_j}}\}$ 为第 j 组的噪声数据, N_j 为 $\tilde{D}_j$ 中数据数量; $f_{j_i} \in f_j = \{f_{j_0}, f_{j_1}, \dots, f_{j_{d-1}}\}$, $x \in B_i$ 表示用户输入值为 i 。

可知, 对数似然函数 $L(f_j)$ 是一个凹函数。故, EM 算法校正后的分布 f'_j 收敛于真实分布 f_j 的极大似然估计。 证毕。

3.2 实验与分析

为评估所提混洗差分隐私保护算法(Graph-SDP)在分布式图数据度分布直方图发布场景下的效用, 本节选取多个公开真实数据集进行实验对比分析。首先, 利用不同指标进行度量, 在相同隐私预算条件下对比分析所提算法与其他度分布隐私保护算法的效用。其次, 分析所提算法在组距 d 设置不同的情况对运行时间、效用的影响。最后, 分析其他参数 (σ, R) 对所提算法效用的影响。本节所有实验均在 Inter Core i5-6200U CPU 处理器、Windows 10 系统上运行, 利用 Python3.8 进行实现。

3.2.1 实验设置

本节实验数据集选取了 Stanford Large Network Dataset Collection 网站上 5 个具有代表性的真实图数据集, 分别为: Twitter、Amazon、gemsec-facebook_artist、com-dblp.ungraph 和 gemsec_deezer_HU, 表 3.1 简要分析了实验数据集的节点、边和最大度(d_{max})等特征信息。

表 3.1 数据集信息

数据集	$ V $	$ E $	d_{max}
Twitter	81306	1768149	3383
Amazon	262111	1234877	420
com-dblp.ungraph	317080	1049866	343
gemsec-facebook_artist	50515	819306	1469
gemsec_deezer_HU	47538	222887	112

为对比分析不同隐私保护算法的效用, 本节采用 L_1 距离、H 距离(Hellinger Distance)以及均方差 MSE (Mean Square Error)三个指标进行量化。具体而言, 针对于两个度分布 F 及 F' , 其中 F 为真实度分布直方图, F' 为隐私保护后的度分布直方图, 设 F 和 F' 的长度为 $l = d \times S$ (其中, d 为组距, S 为分组数量), 则 F 与

F' 之间的 L_1 距离记为 $L_1 = \sum_{i=0}^{l-1} |F_i - F'_i|$; H 距离记为 $H(F', F) = \frac{1}{\sqrt{2}} \|\sqrt{F'} - \sqrt{F}\|_2$,

用以计算两个度分布之间的距离, 衡量两个分布间的相似性; MSE 的计算方式

则为 $MSE = \frac{1}{l} \sum_{i=0}^{l-1} (F_i - F'_i)^2$ 。其中 F_i 表示分布 F 中度为 i 的频率, L_1 距离、H 距离


及 MSE 越小, 即表明度分布越相似, 度分布之间的差异性越小。

3.2.2 效用分析


介于分布式图数据场景下度分布发布算法研究相对较少，本节将本文所提 Graph-SDP 算法与文献[15,31]中提出的算法进行对比。其中，文献[31]的 RJ 算法是一种基于 LDP 的图数据度分布直方图发布算法，文献[15]的 GRR 和 SUE 算法都为 LDP 算法。由于当扰动域过大时，GRR 会引入过多噪声，造成发布数据的效用不理想，SUE 的计算代价过大且效用不理想，因此实验中对 SUE 和 GRR 也进行了数据分组，避免每组数据扰动域过大，减少算法的计算复杂度并提升效用。

四种算法的效用对比结果如图 3.3 所示，图 3.3(a)-(e)分别为隐私预算 $\epsilon=[0.15,0.25,0.5,0.75,0.85,1]$ ，Graph-SDP、RJ、GRR 及 SUE 算法在表 3.2 所示的不同数据集上的实验效果，图 3.3(a)-(e)各个子图分为左中右三列分别表示 L_1 距离、H 距离和 MSE 三个指标的实验结果。由图 3.3 可知，针对不同的数据集，Graph-SDP 算法的数据效用在三个不同的指标纬度上均优于其他算法。具体的，如图 3.3(a)，在 Twitter 数据集上，随着隐私预算的增大，四种算法的数据效用都随之提升；GRR、SUE、RJ 和 Graph-SDP 四种算法的数据效用依次变高，相比于 GRR、SUE 和 RJ 算法，Graph-SDP 在 L_1 距离和 H 距离维度的效用优势随隐私预算的变大而提升，在 MSE 维度具有一定优势，不及其他两个指标明显，总体数据效用提升了 30%-92%。如图 3.3(b)，在 Amazon 数据集上，类似地随着隐私预算的增大，四种算法的数据效用都随之提升；但是，数据效用变为 RJ、GRR、SUE 和 Graph-SDP 依次变高，Graph-SDP 在 L_1 距离和 H 距离维度的效用优势随隐私预算的变大而变小，在 MSE 维度优势不再明显，总体数据效用提升了 60%-99%。同样地，如图 3.3(c)-(e)相较于其他三种算法，Graph-SDP 算法在 com-dblp_ungraph、gemsec-facebook_artist 和 gemsec_deezer_HU 三个数据集上的数据效用在三个不同指标维度上都有不同程度的稳定优势，不随数据集中图数据的节点数量、边数量和度值数据变化而发生太大变化。


本章所提基于混洗差分隐私的图数据度分布直方图发布算法 Graph-SDP 数据效用优于其他算法的原因有两方面。其一、Graph-SDP 算法基于 ESA 框架设计了混洗差分隐私模型，利用混洗器提升了数据到达分析端的整体安全性，可以适当放宽用户端所需的隐私预算，进而减少了噪声量；其二、在分析端对各分组噪声数据构建 EM 算法进而校正，使得最终发布的数据效用得到提升。通过两个层面的改进与设计，保证了同等 ϵ 下隐私保护后的图数据度分布直方图数据效用得到提升。




(a) Twitter 数据集的数据效用对比




(b) Amazon 数据集的数据效用对比



(c) com-dblp.ungraph 数据集的数据效用对比



(d) gemsec-facebook_artist 数据集的数据效用对比




(e) gemsec_deezer_HU 数据集的数据效用对比

图 3.3 不同图数据集度分布直方图发布算法的效用分析(左: L_1 距离, 中: H 距离, 右: MSE)

3.2.3 用户分组影响分析

本文所提 Graph-SDP 算法在本地差分隐私加噪时, 根据所有分布式用户的子图度值数据对用户进行了分组, 不同组距将使各组初始数据输入域大小不同, 进而影响算法的效率和最终的数据效用。为了进一步考察该算法在不同组距时所呈现的算法效率和数据效用, 本节先后将组距 d 分别设置为 $[10, 15, 20, 25, 30, 35, 40]$, 在相同组距设置下运行算法 20 次取其平均值, 观察不同组距条件下的时间开销和三个效用指标的变化, 实验结果如图 3.4 所示。由图 3.4(a)可知, Graph-SDP 算法的时间开销与图数据的顶点和边的数量呈正相关, 同时随着分组的组距增大而增大, 200s 时间开销内可以完成百万级边数量的图数据度分布直方图发布; 由图 3.4(b)-(d)可知, 同一数据集中, Graph-SDP 算法效用受组距变动的影响相对较小, 其效用随着组距的增加有略微的降低。所有数据集中, 随着组距的改变, L_1 距离和 H 距离的波动都保持在 0.05 以内, MSE 的影响则整体保持在 1×10^{-6} 以内。






图 3.4 组距变化对 Graph-SDP 的时间与效用影响

3.2.4 参数影响分析

依据前述定理 3.1 及定理 3.2 可知, 所提 Graph-SDP 算法在发布度分布直方图的过程中需要各组用户依据分组情况及各项参数(如 ε, σ)计算实际所需的隐私预算。同时, 编码器在通过 SW 机制扰动混淆数据的同时也需引入加噪跳转半径 R 。因此, 为进一步分析各项参数对算法 Graph-SDP 发布数据效用的影响, 在上述真实数据集上进一步对比隐私泄露率 σ 及加噪跳转半径 R 对发布数据的效用影响。实验效用度量方法依旧采用 L_1 距离、H 距离以及 MSE 。

(1)在计算各组实际隐私预算 ε_j 的过程中, σ 是必不可少的参数之一, 同时 σ 也反映了算法可能遭受泄露的概率。因此在表 3.2 所示的 5 个真实数据集上, 进一步测试 σ 的设置对算法 Graph-SDP 最终发布度分布直方图效用的影响。首先将初始隐私预算和组距进行设定, 即 $\varepsilon=1$, $d=10$ 。后续依次选取隐私泄露率 $\sigma = [10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}, 10^{-5}, 10^{-6}, 10^{-7}]$, 对比 Graph-SDP 算法在 5 个数据集上的效用。实验结果在相同泄露率的情况下均运行 10 次取平均值, 具体如图 3.5 所示。

由图 3.5 可知, 随着 σ 的值依次从 10^{-1} 下降至 10^{-7} , 算法 Graph-SDP 在 5 个数据集上均呈现上升趋势。如 Twitter 数据集, 随着 σ 的下降, L_1 距离指标整体上升了约 0.002, H 距离指标上升了 0.02, MSE 指标也随之上升了 1.8×10^{-8} 。同理, 文中所提算法在其余 4 个数据集上的效用指标也随着 σ 的下降而上升。

可见, σ 的值与 Graph-SDP 的最终效用呈负相关, 但整体影响相对较小。由此, 在条件允许的情况下可进一步将 σ 的值设置更小一些, 从而降低泄露风险。




图 3.5 σ 变化对 Graph-SDP 的效用影响

(2)文中所提 Graph-SDP 算法扰动过程中需要使用加噪跳转半径 R ，从而合理地添加噪声，保证数据安全。但 R 的不合理设置也可能会影响到发布数据的实际效用。在节 3.1.3 中提出最优 R 的计算方式，即各组应结合实际隐私预算 ϵ_j 对 R_j 进行计算。为进一步评估 R 的计算方式是否更优以及 R 的设置对发布数据精度的影响，以 Twitter 数据集为例进行实验，在 $\epsilon=[0.25, 0.35, 0.5, 0.75, 0.85, 1]$ 以及 $d=10$ 时，分别测试 $R=[1, 2, 3, 4, 5]$ 和最优 R 在真实数据集上发布度分布直方图的效用，具体结果如图 3.6 所示。其中，最优 R 为所提最优加噪跳转半径计算方式。

图 3.6 表明，在大多数情况下，文中所提选取方法得到的最优加噪跳转半径 R 在 L_1 距离、 H 距离、 MSE 3 个效用指标方面均达到最低。具体而言，随着初始隐私预算 ϵ 的逐步上升，最优 R 的效用在 3 个效用指标基本上优于 $R=[1, 2, 3, 4, 5]$ 。其中存在相对较差一些的情况，如当 $\epsilon=0.25$ 时， R 相较于最优 R 在 L_1 距离和 MSE 两个指标上略微优一些。但整体而言，最优 R 在整体效用上要比其余 5 个值更为出色。

因此，本章所提 Graph-SDP 算法设置的 R 计算方式能更为优秀地发布更精确的度分布直方图。




图 3.6 加噪跳转半径 R 对 Graph-SDP 的效用影响

3.3 本章小结

本章围绕分布式图数据度分布直方图发布场景,研究高效的差分隐私保护机制,解决了已有算法存在的数据效用低下和隐私保护效用不高的问题。基于 ESA 混洗差分隐私框架设计了面向图数据度分布直方图发布的混洗差分隐私保护模型,设计了交互式参数计算协议,重构了 ESA 混洗差分隐私保护框架的编码器和分析器;通过混洗差分机制保护分布式用户的身份隐私,通过用户分组降低度数据加噪的加噪跳转半径并利用极大似然估计矫正提高数据效用。在所设计的图数据度分布直方图发布混洗差分隐私保护模型的基础上,提出了具体的隐私保护数据发布算法并证明了其满足 (ϵ, σ) -SDP。利用真实数据集进行实验并与已有算法进行对比,大量实验结果表明了所提出的算法具有更高的数据效用,其数据效用相较已有算法有了显著提升,同时该算法具有较低的时间开销,能适用于不同规模的图数据直方图发布隐私保护需求。

第4章 基于混洗差分隐私的聚类系数发布算法

在传统基于 DP 的图数据聚类系数发布模型中,同样存在可信第三方威胁以及数据效用过低等挑战。同时,相较于度分布而言,聚类系数具备高维性及更强大的结构特性,在引入混洗差分隐私降低发布效用时,难以直接应用。具体而言,在分布式场景下发布聚类系数,数据收集者往往需要获取每个分布式用户的邻接向量来对聚类系数进行估计,而混洗差分隐私的引入,将导致以下两种问题:

- (1) 分布式用户的邻接向量属于高维数据,使得在 SDP 下需要极大的隐私预算,来保证边缘 DP 的实现。换言之,常规方式应用 SDP 发布聚类系数将使得边缘 DP 的隐私保护水平非常低;
- (2) 混洗差分隐私的隐私保护一方面依靠分布加噪机制对数据加噪,提供差分隐私保障;另一方面,借助混洗器匿名数据来源,提升 DP 的保护强度;然而,直接混洗邻接向量将很大程度导致图数据无法直接重构,进而失去使用价值。

基于上述问题,本章提出一种基于混洗差分隐私的聚类系数发布算法(GCC-SDP),尽可能的避免或削弱上述两种问题带来的负面影响,并进一步提高发布的聚类系数的最终效用。具体而言,在 GCC-SDP 中,所有分布式用户分别首先通过 SDP、RR 和拉普拉斯机制向数据收集者报告每条边的楔形列表(2 跳路径信息)、邻接位向量和度值。其次,数据收集者结合收集到的楔形列表、邻接位向量和度值,收集图数据的全局聚类系数。

本章从理论上讨论了 GCC-SDP 在不同 DP 下提供的隐私保护上界,并证明了发布的聚类系数是无偏的。此外,通过在真实数据集和生成数据集上的实验,验证了 GCC-SDP 的效用相较于传统分布式差分隐私聚类系数发布算法,具备显著的效用提升。

4.1 GCC-SDP 框架

本章所提算法 GCC-SDP 的目标是通过 SDP, RR 和拉普拉斯机制分别收集所有用户的局部三角形计数和度值,进而估计全局聚类系数。图 4.1 为 GCC-SDP 的总体框架,分别由以下三个实体组成:

- (1) **分布式用户**: 每个分布式用户持有一个以其节点为中心的星图(一跳邻居子图)。在 GCC-SDP 中,他们需要通过 RR 和拉普拉斯机制报告楔形、邻接向量和度值等信息。
- (2) **混洗器**: 混洗器需要对用户报告的噪声楔形数据进行洗牌,从而提升

隐私收益。

- (3) **数据收集者**：数据收集者接收混洗器和用户报告的噪声数据，并对收集到的数据进行后处理(数据校正)，发布最终的全局聚类系数。




图 4.1 基于混洗差分隐私的聚类系数发布框架

如图 4.1 所示，三个实体之间通过四个步骤交互完成算法 GCC-SDP 的流程，进行实现具备混洗差分隐私保护的聚类系数发布。以下为四个步骤的简单阐述：

- (1) **步骤①**：首先，分布式用户从数据收集者处接收初始隐私预算 ε 、隐私泄露率 σ 、以及隐私预算分配率 α ；其次，用户需要将 ε 拆分为 ε_1 和 ε_2 ，分别用户报告三角计数和度值，其中 $\varepsilon_1 = \alpha\varepsilon$ ， $\varepsilon_2 = (1-\alpha)\varepsilon$ ；

进一步地，用户需要计算隐私放大后的 ε_L ，即 $\varepsilon_L = f\left(\frac{\varepsilon_1}{2}, n-2, \frac{\sigma}{2}\right)$ 。

- (2) **步骤②**：首先，分布式用户通过 ε_1 -RR 报告其邻接向量 B_i ；其次，分布式用户通过 ε_L -RR 和混洗器报告图 G 中每条边对应的楔形列表 $W_{i,j}$ 。

- (3) **步骤③**：分布式用户 ε_2 -拉普拉斯机制向数据收集者报告其度值 d_i 。

- (4) **步骤④**：首先，数据收集者根据用户报告的噪声邻接向量以及噪声楔形列表估计每个用户的局部三角计数；其次，数据收集者根据用户报告的度值和噪声邻接向量优化每个用户的度值；最后，数据收集者根据校正的三角计数和度值计算图 G 的全局聚类系数，并将其发布。

以上为本章所提基于混洗差分隐私的聚类系数发布算法 GCC-SDP 的具体步骤，本章将在 4.2 节中详细阐述每个步骤的实施细节，具体见 4.2 节。

4.2 GCC-SDP 实施

4.1 节中描述了算法 GCC-SDP 的基本框架,在隐私预算分配后(步骤①),每个分布式用户便可执行步骤②-③来报告其邻接向量、边契形列表以及度值;进一步地,数据收集者可综合处理收集到的数据(步骤④),估计最终的聚类系数。因此,本节主要阐述步骤②-④的具体实施细节。

4.2.1 报告邻接向量和契形列表

在完成步骤①后,每个分布式用户均具备 ε_1 、 ε_2 和 ε_L 。进一步地,用户可以执行步骤②,主要分为两个部分,即分别向数据收集者报告邻接向量和契形列表,以便于数据收集者在执行步骤④时估计各用户的局部三角计数。本小节主要解释在算法 GCC-SDP 中如何报告这两种类型的数据。

(1)报告邻接向量。任意用户 i 需要通过 ε_1 -RR 向数据收集者报告他的邻接向量 $\mathbf{B}_i$,具体实施细节为:

给定邻接向量 $\mathbf{B}_i = (b_1, b_2, \dots, b_n)$ 和隐私预算 ε_1 ,受 ε_1 -RR 扰动的噪声邻接向量

$\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_n)$ ($\mathbf{B}'_i = \text{RR}_{\varepsilon_1}(\mathbf{B}_i)$)可表示为

$$b'_j = \begin{cases} b_i, & p_1 = \frac{e^{\varepsilon_1}}{e^{\varepsilon_1} + 1}, \\ 1 - b_i, & q_1 = \frac{1}{e^{\varepsilon_1} + 1}, \end{cases}$$

如上所述,图 G 中每个用户均可采用 ε_1 -RR 扰动其邻接向量,并将噪声邻接向量报告至数据收集者。进一步地,数据收集者便可获取每个分布式用户的噪声邻接向量,聚合为图 G 的噪声邻接矩阵 $\mathbf{M}' = (\mathbf{B}'_1, \mathbf{B}'_2, \dots, \mathbf{B}'_n)$,即 $\mathbf{M}' = \text{RR}_{\varepsilon_1}(\mathbf{M})$ 。根据定理 4.1 可知, $\mathbf{B}'_i = \text{RR}_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP 以及 ε_1 -LDP。

然而,需要注意的是,上述直接让每位用户采用 ε_1 -RR 扰动其邻接向量的方式,可能会导致边的重复报告。换言之,用户 i 和用户 j 可能都会将边 (i, j) 的存在与否进行报告,这一定程度上会引发噪声量的增大。因此,本章采取报告矩阵下三角的方式来避免此类问题,即每位用户仅需报告其邻接向量中序号小于其顶点号对应位上的数值。以用户 i 为例,在报告邻接向量过程中,其仅通过需 ε_1 -RR 扰动邻接向量中的前 $i-1$ 位,即 $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_{i-1}) = \text{RR}_{\varepsilon_1}[(b_1, b_2, \dots, b_{i-1})]$ 。以此类推,在所有用户结束了报告后,数据收集者便可获取图 G 邻接矩阵对应的噪声下三角邻接矩阵 $\mathbf{M}'$ 。根据定理 4.2 可知, $\mathbf{M}' = \text{RR}_{\varepsilon_1}(\mathbf{M})$ 满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP 以及 ε_1 -LDP。

定理 4.1. $\mathbf{B}'_i = \text{RR}_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP 以及 ε_1 -LDP。

证明： 给定隐私预算 ε_1 、邻接向量 $\mathbf{B}_i = (b_1, b_2, \dots, b_n)$ 和与其仅相差一位的相邻邻接向量 $\mathbf{S} = (s_1, s_2, \dots, s_n)$ ，设 $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_n)$ 为经过 ε_1 -RR 扰动的噪声邻接向量，其中 $b_j, s_j, b'_j \in \{0, 1\}$ 。不失一般性，假设 $\mathbf{B}_i, \mathbf{S}$ 仅第一位对应值不同，即 $b_1 \neq s_1$ ，则有

$$\begin{aligned} \frac{\Pr[\text{RR}_{\varepsilon_1}(\mathbf{B}_i) = \mathbf{B}'_i]}{\Pr[\text{RR}_{\varepsilon_1}(\mathbf{S}) = \mathbf{B}'_i]} &= \frac{\Pr[\text{RR}_{\varepsilon_1}(b_1) = b'_1] \Pr[\text{RR}_{\varepsilon_1}(b_2) = b'_2] \dots \Pr[\text{RR}_{\varepsilon_1}(b_n) = b'_n]}{\Pr[\text{RR}_{\varepsilon_1}(s_1) = b'_1] \Pr[\text{RR}_{\varepsilon_1}(s_2) = b'_2] \dots \Pr[\text{RR}_{\varepsilon_1}(s_n) = b'_n]} \\ &= \frac{\Pr[\text{RR}_{\varepsilon_1}(b_1) = b'_1]}{\Pr[\text{RR}_{\varepsilon_1}(s_1) = b'_1]} \leq \frac{p_1}{q_1} = e^{\varepsilon_1}。 \end{aligned}$$

因此， $\mathbf{B}'_i = \text{RR}_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -Edge-LDP。

进一步地，由于当前所报告的仅是单个用户 i 的邻接位向量 $\mathbf{B}_i$ ，因此只代表用户 i 的局部视角，而不涉及图 G 的全局视角。在这种情况下，可进一步将 $\mathbf{B}'_i = \text{RR}_{\varepsilon_1}(\mathbf{B}_i)$ 视为一个集中式 DP 场景种的问题。换言之，用户 i 的每一条边仅对应于 $\mathbf{B}_i$ 中的 1 位，即增加或删除一条边只会影响 $\mathbf{B}_i$ 中的 1 位。此时，根据组合隐私， $\mathbf{B}'_i = \text{RR}_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -Edge-LDP 等价于满足 ε_1 -Edge-DP。

在另一个场景下，可将用户 i 报告 $\mathbf{B}_i$ 中每一位理解为将每条边作为单独的计数进行报告，即若边 (i, j) 存在报告 1，否则报告 0。此时，边 (i, j) 存在与否所引起的计数可以看作是用户 i 持有的两个相邻数据集的计数。因此，对任意两个输入值 $b_j, s_j \in \{0, 1\}$ ，以及输出值 $b'_j = \text{RR}_{\varepsilon_1}(b_j)$ ，有

$$\frac{\Pr[\text{RR}_{\varepsilon_1}(b_j) = b'_j]}{\Pr[\text{RR}_{\varepsilon_1}(s_j) = b'_j]} \leq \frac{p_1}{q_1} = e^{\varepsilon_1}。$$

因此， $b'_j = \text{RR}_{\varepsilon_1}(b_j)$ 满足 ε_1 -DP。由于每条边的计数都可以被认为是独立的值，可进行单独报告。因此，根据 DP 的并行组合性质， $\mathbf{B}'_i = \text{RR}_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -DP。

同理，可将 $\mathbf{B}_i$ 中每一位视为单独的布尔值。在 LDP 场景下，对任意两个布尔值 $b_j, s_j \in \{0, 1\}$ ，以及输出值 $b'_j = \text{RR}_{\varepsilon_1}(b_j)$ ，有

$$\frac{Pr[RR_{\varepsilon_1}(b_j)=b'_j]}{Pr[RR_{\varepsilon_1}(s_j)=b'_j]} \leq \frac{p_1}{q_1} = e^{\varepsilon_1}。$$

因此, $b'_j = RR_{\varepsilon_1}(b_j)$ 满足 ε_1 -LDP。根据 DP 的并行组合性质, $\mathbf{B}'_i = RR_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -LDP。

综上所述, $\mathbf{B}'_i = RR_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP 以及 ε_1 -LDP。证毕。

定理 4.2. $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M})$ 满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP、 ε_1 -LDP, 其中 $\mathbf{M}'$ 为噪声下三角邻接矩阵。

证明: 给定隐私预算 ε_1 和下三角邻接矩阵 $\mathbf{M} = (\mathbf{B}_1, \mathbf{B}_2, \dots, \mathbf{B}_n)$, 其中 $\mathbf{B}_i = (b_1, b_2, \dots, b_{i-1})$ 。设 $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M}) = (\mathbf{B}'_1, \mathbf{B}'_2, \dots, \mathbf{B}'_n)$ 为经过 ε_1 -RR 扰动的噪声下三角邻接矩阵。

根据定理 4.1, 可知 $\mathbf{B}'_i = RR_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -Edge-LDP、 ε_1 -DP 以及 ε_1 -LDP。

首先, $\mathbf{M}'$ 中任意邻接向量 $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_{i-1})$ 在 Edge-LDP 约束下是一个独立的个体。因此, 根据 DP 的并行组合性, 任意 $\mathbf{B}'_i = RR_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -Edge-LDP, $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M}) = (\mathbf{B}'_1, \mathbf{B}'_2, \dots, \mathbf{B}'_n)$ 同样满足 ε_1 -Edge-LDP。

其次, 在 DP 和 LDP 的约束下, 无需考虑边的相关性, 每条边的计数是一个独立的个体, 即 $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_{i-1})$ 中每一位的报告过程可以视为是独立的。因此, 任意 $\mathbf{B}'_i = RR_{\varepsilon_1}(\mathbf{B}_i)$ 满足 ε_1 -DP 和 ε_1 -LDP, $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M}) = (\mathbf{B}'_1, \mathbf{B}'_2, \dots, \mathbf{B}'_n)$ 耶满足 ε_1 -DP 和 ε_1 -LDP。

最后, 在 Edge-DP 约束下, 则存在两种情况:

1. 不采用下三角的方式报告邻接矩阵, 即 $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M}) = (\mathbf{B}'_1, \mathbf{B}'_2, \dots, \mathbf{B}'_n)$, $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_n)$ 。此时, 增加或删除一条边 (i, j) 将影响 $\mathbf{M}'$ 中的两位, 即 $\mathbf{B}'_i$ 中第 j 位和 $\mathbf{B}'_j$ 中第 i 位。根据组合隐私, $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M})$ 满足 $2\varepsilon_1$ -Edge-DP。
2. 采用下三角的方式报告邻接矩阵, 即 $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M}) = (\mathbf{B}'_1, \mathbf{B}'_2, \dots, \mathbf{B}'_n)$, $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_{i-1})$, 此时, 增加或删除一条边 (i, j) 只影响 $\mathbf{M}'$ 中的 1 位。根据组合隐私^[63], $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M})$ 满足 ε_1 -Edge-DP。

因此, $\mathbf{M}' = RR_{\varepsilon_1}(\mathbf{M})$ ($\mathbf{M}'$ 为噪声下三角邻接矩阵) 满足 ε_1 -Edge-DP。综上,

$M' = RR_{\varepsilon_1}(M)$ 满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP、 ε_1 -LDP。 证毕。

(2)报告契形列表。根据 2.1 节可知，报告任意用户 i 的边契形列表 W_i ，需要图 G 中其他用户的配合。以用户 i 为例，在图 G 中，他至多有 $n-1$ 条边，这意味着他是除他自己以外所有用户的邻居。因此，用户 i 的边契形列表可表示为 $W_i = (W_{i,1}, W_{i,2}, \dots, W_{i,n-1})$ ，其中 $W_{i,j} \in (0,1)^{n-2}$ 表示边 (i,j) 的楔形列表。换言之，契形列表 W_i 是由用户 i 与其他 $n-1$ 个用户形成的边对应的边楔形列表所组成。因此，获取契形列表 W_i 需要收集用户 i 每条边的楔形列表 $W_{i,j}$ 。以边 (i,j) 楔形列表 $W_{i,j}$ 为例，报告 $W_{i,j}$ 的细节为：

设 $I_{i,j}$ 为图 G 中除用户 i 和用户 j 以外其余 $n-2$ 个用户的集合。给定边 (i,j) 楔形列表 $W_{i,j} = (e_1, e_2, \dots, e_{n-2}) = (0,1)^{n-2}$ 和隐私预算 ε_L ， $W_{i,j}$ 中的每个元素均由 $I_{i,j}$ 中 $n-2$ 个用户分布式持有。因此，在报告 $W_{i,j}$ 的过程中，需 $I_{i,j}$ 中 $n-2$ 个用户依次通过 ε_L -RR 报告 e_k ，即

$$e'_k = \begin{cases} e_k, & p_L = \frac{e^{\varepsilon_L}}{e^{\varepsilon_L} + 1}, \\ 1 - e_k, & q_L = \frac{1}{e^{\varepsilon_L} + 1}, \end{cases}$$

其中 e'_k 由用户 k 所报告。 $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2}) = (0,1)^{n-2}$ 表示受 ε_L -RR 扰动的噪声边契形列表，即边 (i,j) 的噪声楔形列表。

与邻接向量 $B'_i = RR_{\varepsilon_1}(B_i)$ 的报告方式一致， $W'_{i,j}$ 满足 ε_L -LDP。但，与之不同的是，后续步骤只需要计算 $W'_{i,j}$ 中 1 的个数，无需知晓它们的来源。因此，可进一步引入一个混洗器洗牌 $W'_{i,j}$ ，从而提升隐私收益，即 $W'_{i,j} = R_{\varepsilon_L} \circ S(W_{i,j})$ 。根据定理 4.3，经过 ε_L -RR 扰动和混洗器洗牌后的噪声楔形列表 $W'_{i,j} = R_{\varepsilon_L} \circ S(W_{i,j})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $(\varepsilon_1/2, \sigma/2)$ -Edge-DP，并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。基于此类方式，分布式用户可依次通过 ε_L -RR 和混洗器报告用户 i 所有边的契形列表，即 $W'_i = (W'_{i,1}, W'_{i,2}, \dots, W'_{i,n-1})$ ，其中 $W'_{i,j} = R_{\varepsilon_L} \circ S(W_{i,j})$ 。根据定理 4.4 可知，

$W'_i = (W'_{i,1}, W'_{i,2}, \dots, W'_{i,n-1})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $((n-2)\varepsilon_1/2, (n-2)\sigma/2)$ -Edge-DP, 并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。

与前述邻接向量的报告过程一致, 该过程需要获取每个用户的噪声楔形列表。因此, 需要所有用户通过 ε_L -RR 和混洗器交互式的向数据收集者报告图 G 中所有边的噪声楔形列表, 也可定义为所有用户的噪声楔形列表, 即 $W' = (W'_1, W'_2, \dots, W'_n)$ 。可直观发现, 真实楔形列表 W 也是对称的, 即 $W_{i,j} = W_{j,i}$ 。因此, 为避免边缘重复报告, 本章选择上三角的方式报告楔形列表。例如, 当报告用户 i 的楔形列表时, 用户们仅需通过 ε_L -RR 和混洗器报告用户 i 与顶点序号大于 i 的用户之间构成的边所对应的楔形列表, 即

$$W'_i = R_{\varepsilon_L} \circ S[W_{i,i+1}, W_{i,i+2}, \dots, W_{i,n}] = (W'_{i,i+1}, W'_{i,i+2}, \dots, W'_{i,n})。$$

进而, 数据收集者仍能获取图 G 中所有边的噪声楔形列表 $W' = (W'_1, W'_2, \dots, W'_n)$, 其中 $W'_i = (W'_{i,i+1}, W'_{i,i+2}, \dots, W'_{i,n})$ 。

定理 4.3. $W'_{i,j} = R_{\varepsilon_L} \circ S(W_{i,j})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $(\varepsilon_1/2, \sigma/2)$ -Edge-DP, 并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。

证明: 给定隐私预算 ε_L 和边 (i, j) 的楔形列表 $W_{i,j} = (e_1, e_2, \dots, e_{n-2}) = (0, 1)^{n-2}$, 其中 $\varepsilon_L = f\left(\frac{\varepsilon_1}{2}, n-2, \frac{\sigma}{2}\right)$ 。设 $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2}) = (0, 1)^{n-2}$ 为经过 ε_L -RR 和混洗器保护的噪声楔形列表, 其中任意 $e'_k = R_{\varepsilon_L}(e_k)$ 是由用户 k 所报告。因此, 设任意两个值 e_k 和 $e_s \in \{0, 1\}$, 输出值 $e'_k = R_{\varepsilon_L}(e_k) \in \{0, 1\}$, 有

$$\frac{\Pr[RR_{\varepsilon_L}(e_k) = e'_k]}{\Pr[RR_{\varepsilon_L}(e_s) = e'_k]} \leq \frac{p_L}{q_L} = \frac{\frac{e^{\varepsilon_L}}{e^{\varepsilon_L} + 1}}{\frac{1}{e^{\varepsilon_L} + 1}} = e^{\varepsilon_L}。$$

因此, $e'_k = R_{\varepsilon_L}(e_k)$ 满足 ε_L -LDP。同理, 根据 DP 的并行性, $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2})$ 也满足 ε_L -LDP。进一步地, 根据定义 2.9, 若 $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2})$ 满足 ε_L -LDP, 且被混洗器洗牌, 则 $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP。

此外, 任意 e_k 表示的是二跳路径 $i-k-j$ 构成的楔形, 其包含两条边, 即边

(k, i) 和边 (k, j) 。值得注意的是, 当且仅当边 (k, j) 存在时, 改变边 (k, i) 才能影响 e_k 的最终值。换言之, 添加或删除一条边最多只影响 $W_{i,j} = (e_1, e_2, \dots, e_{n-2})$ 中的 1 位。因此, 考虑边关联性的情况下, $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -Edge-DP。

若混洗器和数据收集器之间存在勾结, 即混洗器无法提供隐私收益时, 则 $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2})$ 至少满足 ε_L -LDP; 同理, 由于添加或删除一条边最多只影响 $W_{i,j} = (e_1, e_2, \dots, e_{n-2})$ 中的 1 位, 则 $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2})$ 至少满足 ε_L -Edge-LDP。

综上, $W'_i = R_{\varepsilon_L} \circ S(W_{i,j})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $(\varepsilon_1/2, \sigma/2)$ -Edge-DP, 并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。 **证毕。**

定理 4.4. $W'_i = (W'_{i,1}, W'_{i,2}, \dots, W'_{i,n-1})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $((n-2)\varepsilon_1/2, (n-2)\sigma/2)$ -Edge-DP, 并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。

证明: 根据定理 4.3 可知, $W'_{i,j}$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $(\varepsilon_1/2, \sigma/2)$ -Edge-DP。不考虑边关联性的情况下, 根据 DP 的并行性, $W'_i = R_{\varepsilon_L} \circ S[W_{i,i+1}, W_{i,i+2}, \dots, W_{i,n}]$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP。若考虑边关联性, 在 $W'_i = R_{\varepsilon_L} \circ S[W_{i,1}, W_{i,2}, \dots, W_{i,n-1}]$ 报告过程中, 任意边 (k, i) 会被报告 $n-2$ 次; 进而, 添加或删除一条边将影响 W_i 中 $n-2$ 位。因此, $W'_i = R_{\varepsilon_L} \circ S[W_{i,1}, W_{i,2}, \dots, W_{i,n-1}]$ 满足 $((n-2)\varepsilon_1/2, (n-2)\sigma/2)$ -Edge-DP。

此外, 根据定理 4.3 可知, 若混洗器和数据收集器之间存在勾结, $W'_{i,j}$ 至少满足 ε_L -LDP 和 ε_L -Edge-LDP。因此, 根据 DP 的并行性, 不考虑边关联性的情况下, $W'_i = R_{\varepsilon_L} \circ S[W_{i,i+1}, W_{i,i+2}, \dots, W_{i,n}]$ 至少满足 ε_L -LDP。进一步地, 在 Edge-LDP 场景下, 仅需考虑每个楔形列表中所存在的边关联性, 即添加或删除一条边最多只影响 $W_{i,j}$ 中的 1 位。因此, 根据 DP 的并行性, 不考虑边关联性的情况下, W'_i 至少满足 ε_L -Edge-LDP。

综上, W'_i 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $((n-2)\varepsilon_1/2, (n-2)\sigma/2)$ -Edge-DP, 并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。 **证毕。**

上述(1)和(2)为图 4.1 中步骤②的具体实施细节, 定理 4.5 提供了(1)和(2)整

体满足的隐私保护。在此基础之上，数据收集者可采集到图 G 的噪声邻接矩阵 $\mathbf{M}'$ 和噪声契形列表 $\mathbf{W}'$ ，其可进一步结合二者估计图 G 中每个用户的局部三角计数，该细节见 4.2.3 节。

定理 4.5. 前述步骤②(报告邻接矩阵和契形列表)整体满足 $(\varepsilon_1, \sigma/2)$ -DP、 $((n-1)\varepsilon_1, (n-2)\sigma)$ -Edge-DP，并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。

证明： 首先，根据定理 4.4 可知，报告 $\mathbf{W}'_i = (W'_{i,1}, W'_{i,2}, \dots, W'_{i,n-1})$ 满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $((n-2)\varepsilon_1/2, (n-2)\sigma/2)$ -Edge-DP，并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。同理， $\mathbf{W}' = (W'_1, W'_2, \dots, W'_n)$ 也满足 $(\varepsilon_1/2, \sigma/2)$ -DP，并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。考虑 Edge-DP 约束下边的关联性时， $\mathbf{W}' = (W'_1, W'_2, \dots, W'_n)$ 满足的隐私保障存在两种情况：

1. 不采用上三角的方式报告契形列表，即 $\mathbf{W}' = (W'_1, W'_2, \dots, W'_n)$ ， $W'_i = (W'_{i,1}, W'_{i,2}, \dots, W'_{i,n-1})$ 。此时，增加或删除一条边 (i, j) 将影响 $\mathbf{M}'$ 中的 $4(n-2)$ 位。根据组合隐私， $\mathbf{W}'$ 满足 $(2(n-2)\varepsilon_1, 2(n-2)\sigma)$ -Edge-DP。
2. 不采用上三角的方式报告契形列表，即 $\mathbf{W}' = (W'_1, W'_2, \dots, W'_n)$ ， $W'_i = (W'_{i,i+1}, W'_{i,i+2}, \dots, W'_{i,n})$ 。此时，增加或删除一条边 (i, j) 只影响 $\mathbf{M}'$ 中的 $2(n-2)$ 位。根据组合隐私^[63]， $\mathbf{W}'$ 满足 $((n-2)\varepsilon_1, (n-2)\sigma)$ -Edge-DP。

因此， $\mathbf{W}'$ 满足 $((n-2)\varepsilon_1, (n-2)\sigma)$ -Edge-DP。

其次，根据定理 4.2 可知，报告邻接矩阵 $\mathbf{M}'$ 满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP 和 ε_1 -LDP 的隐私保护。

最后，设算法 $\mathcal{M}$ 为报告邻接矩阵 $\mathbf{M}'$ 的随机算法，满足 ε_1 -Edge-LDP、 ε_1 -Edge-DP、 ε_1 -DP 和 ε_1 -LDP 的隐私保护；设算法 $\mathcal{R} \circ \mathcal{S}$ 为报告契形列表 $\mathbf{W}'$ 的随机算法，满足 $(\varepsilon_1/2, \sigma/2)$ -DP、 $((n-2)\varepsilon_1, (n-2)\sigma)$ -Edge-DP，并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。进而，报告邻接矩阵和契形列表的随机算法可整体记为 $\{\mathcal{M}, \mathcal{R} \circ \mathcal{S}\}$ ，其满足的隐私保护可分三个方面进行讨论：

1. 在 DP 约束下，由于无需考虑边的关联性， $\mathbf{M}$ 和 $\mathbf{W}$ 中的元素均为独立的。因此，根据 DP 的并行性， $\{\mathcal{M}, \mathcal{R} \circ \mathcal{S}\}$ 满足 $\{\varepsilon_1, (\varepsilon_1/2, \sigma/2)\}_{\max}$ -DP，即 $(\varepsilon_1, \sigma/2)$ -DP。
2. 在 Edge-DP 约束下， $\mathbf{M}$ 和 $\mathbf{W}$ 中的元素则不独立的。因此，根据 DP 的序列组合性， $\{\mathcal{M}, \mathcal{R} \circ \mathcal{S}\}$ 满足 $(\varepsilon_1 + (n-2)\varepsilon_1, 0 + (n-2)\sigma)$ -Edge-DP，即 $((n-1)\varepsilon_1, (n-2)\sigma)$ -Edge-DP。
3. 考虑若混洗器和数据收集者之间存在勾结，混洗器将不再提供隐私收益。

此时，噪声契形列表可表示为 $W' = \mathcal{R}(W)$ ，并至少满足 ε_L -LDP。在 LDP 和 Edge-LDP 约束下， $\mathbf{M}$ 和 W 中的元素依旧独立。因此，根据 DP 的组合性质， $\{\mathcal{M}, \mathcal{R}\}$ 满足 $\{\varepsilon_1, \varepsilon_L\}_{\max}$ -LDP 和 $\{\varepsilon_1, \varepsilon_L\}_{\max}$ -Edge-LDP。根据定义 2.9 可知， $\varepsilon_L \gg \varepsilon_1$ ，则随机算法 $\{\mathcal{M}, \mathcal{R}\}$ 整体满足 ε_L -LDP 和 ε_L -Edge-LDP。

综上，前述步骤②(报告邻接矩阵和契形列表)整体满足 $(\varepsilon_1, \sigma/2)$ -DP、 $((n-1)\varepsilon_1, (n-2)\sigma)$ -Edge-DP，并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。证毕。

4.2.2 报告度值

在完成步骤②后，各分布式用户可进一步结合隐私预算 ε_2 实施步骤③，即向数据收集者报告度值，以便于数据收集者在执行步骤④时优化度值并估计全局聚类系数。本小节主要解释在算法 GCC-SDP 中如何报告用户度值。

根据 2.1 节的介绍可知，度值是每个用户存在的边的计数，属于离散型实值数据。对于此类数据，在报告中采用拉普拉斯机制可以有效地减少噪声。因此，本节采用该方法来实现度值的报告。

显然，从任意分布式用户 i 的视角来看，删除任意一条边只会影响其相邻位向量 $\mathbf{B}_i$ 中的一位，即度 d_i 的敏感度为 1。因此，向 d_i 添加 $Lap(1/\varepsilon_2)$ 的噪声(即 $d'_i = d_i + Lap(1/\varepsilon_2)$)便可满足 ε_2 -Edge-LDP。进一步地，若仅采集用户 i 一个人的度值，删除任意一条边只影响 $\mathbf{B}_i$ 中的 1 位，则 $d'_i = d_i + Lap(1/\varepsilon_2)$ 也满足 ε_2 -Edge-DP。然而，在采集所有用户度值时，删除任意一条边 (i, j) 将影响 2 位，即 $\mathbf{B}_i$ 中的第 j 位和 $\mathbf{B}_j$ 中的第 i 位。进而，在 Edge-LDP 视角下， $d'_i = d_i + Lap(1/\varepsilon_2)$ 依旧满足 ε_2 -Edge-LDP，但仅满足 $2\varepsilon_2$ -Edge-DP。

因此，为提供更严格的全局 Edge-DP 隐私保护，本节建议在所有用户报告度值时均向 d_i 中添加 $Lap(2/\varepsilon_2)$ 的噪声(即 $d'_i = d_i + Lap(2/\varepsilon_2)$)，以确保其满足 ε_2 -Edge-DP。换言之，在度值报告过程中，每个用户通过向自身度值添加 $Lap(2/\varepsilon_2)$ 的噪声，来提供隐私报告。进而，数据收集者便可采集各分布式用户的度值，即图 G 的噪声度序列 $D' = (d'_1, d'_2, \dots, d'_n)$ ，其中 $d'_i = d_i + Lap(2/\varepsilon_2)$ 。定理 4.6 提供了所有分布式用户度值报告过程中满足的隐私保护。

定理 4.6. $d'_i = d_i + Lap(2/\varepsilon_2)$ 满足 $\varepsilon_2/2$ -DP、 ε_2 -Edge-DP、 $\varepsilon_2/2$ -Edge-LDP、 $\varepsilon_2/2$ -LDP。

证明：给定隐私预算 ε_2 和度值 d_i 。设 d'_i 为用户通过 ε_2 -拉普拉斯机制报告的噪声度值

1. 若 $d'_i = d_i + Lap(1/\varepsilon_2)$ ，首先，在 DP、LDP、Edge-LDP 约束下， d_i 的敏感度均为 1，则 d'_i 满足 ε_2 -DP、 ε_2 -LDP 和 ε_2 -Edge-LDP。其次，在全局图视角下，删除任意一条边 (i, j) 将影响 $\mathbf{M}$ 中的 2 位，即 $\mathbf{B}_i$ 中的第 j 位和 $\mathbf{B}_j$ 中的第 i 位，敏感度为 2。因此，在 Edge-DP 约束下， d_i 的敏感度为 2， d'_i 满足 $2\varepsilon_2$ -Edge-DP。
2. 若 $d'_i = d_i + Lap(2/\varepsilon_2)$ ，首先，在 DP、LDP、Edge-LDP 约束下， d_i 的敏感度均为 1，则 d'_i 满足 $\varepsilon_2/2$ -DP、 $\varepsilon_2/2$ -LDP 和 $\varepsilon_2/2$ -Edge-LDP。其次，在 Edge-DP 约束下， d_i 的敏感度为 2， d'_i 满足 ε_2 -Edge-DP。

综上， $d'_i = d_i + Lap(2/\varepsilon_2)$ 满足 $\varepsilon_2/2$ -DP、 ε_2 -Edge-DP、 $\varepsilon_2/2$ -Edge-LDP、 $\varepsilon_2/2$ -LDP。证毕。

4.2.3 聚合校正

在完成步骤②和③后，数据收集者便采集了噪声矩阵 $\mathbf{M}'$ 、噪声契形列表 $\mathbf{W}'$ 以及噪声度序列 $\mathbf{D}'$ 。进一步地，数据收集者可执行步骤④，即对噪声数据进行后处理，并估计全局聚类系数。具体而言，首先，数据收集器通过 $\mathbf{M}'$ 和 $\mathbf{W}'$ 估计各用户的局部三角计数；其次，数据收集器通过 $\mathbf{M}'$ 和 $\mathbf{D}'$ 优化各用户的度值；最后，数据收集者根据估计的局部三角形计数序列和优化后的度序列计算每个用户的局部聚类系数，并发布图 G 的全局聚类系数估计。本节主要分为三个方面进行阐述。

(1)估计局部三角计数。介于估计每个用户的局部三角计数所采用的方式是一致的，因此此处使用单个用户 i 为例，进行阐述。

用户 i 的局部三角形计数 T_i 可以被记为

$$T_i = \frac{\sum_{j=1}^n T_{i,j} (j \neq i)}{2},$$

其中 $T_{i,j}$ 表示边 (i, j) 关联的三角形计数。换言之， T_i 可以通过对用户 i 所有可能存在的边 $(n-1$ 条边) 关联的三角计数估计进行求和，从而获得用户 i 的局部三

角形计数估计。

根据 2.1 节的描述可知，任意三角形 $i-k-j-i$ 都可以通过契形 $i-k-j$ 和边 (i, j) 进行表示。进一步地，边 (i, j) 关联的三角形计数 $T_{i,j}$ 其实就对应于边 (i, j) 的契形列表 $W_{i,j}$ 中 1 的数量。值得注意的是，边 (i, j) 的存在与否和 $W_{i,j}$ 均属于图数据的隐私信息，不能直接报告给数据收集者。因此，此处数据收集者需通过噪声矩阵 $\mathbf{M}'$ 和噪声契形列表 $\mathbf{W}'$ 中的噪声边信息和噪声契形列表对 $T_{i,j}$ 进行估计。方法如下：

给定 $b'_j = \mathbf{RR}_{\varepsilon_1}(b_j)$ 表示受噪声扰动的边 (i, j) 信息，以及其对应的噪声边契形列表 $W'_{i,j}$ ，其中 $b'_j \in \{0,1\}$ 为 $\mathbf{B}'_i$ 中的第 j 位或 $\mathbf{B}'_j$ 中的第 i 位。首先，数据收集者需估计契形列表 $W_{i,j}$ 中 1 的数量。设 $\hat{C}_{i,j}$ 和 $C'_{i,j}$ 分别表示噪声边契形列表 $W'_{i,j}$ 中 1 的数量和契形列表 $W_{i,j}$ 中 1 的数量的估计值。根据 RR 的校正方式，可知：

$$C'_{i,j} = \frac{\hat{C}_{i,j} - (n-2)q_L}{1-2q_L},$$

其中 $q_L = \frac{1}{e^{\varepsilon_L} + 1}$ 。

其次，数据收集者需根据受噪声扰动的边 (i, j) 信息和契形列表 $W_{i,j}$ 中 1 的数量的估计值 $C'_{i,j}$ 对 $T_{i,j}$ 进行估计，即

$$T'_{i,j} = \frac{(b'_j - q_1)C'_{i,j}}{1-2q_1},$$

其中 $q_1 = \frac{1}{e^{\varepsilon_1} + 1}$ ， $T'_{i,j}$ 为边 (i, j) 关联的三角形计数估计。根据定理 4.7 可知，边 (i, j) 关联的三角计数估计 $T'_{i,j}$ 是其关联的真实三角计数 $T_{i,j}$ 的无偏估计。

在此基础之上，数据收集者可以进一步依次估计用户 i 每条边 $(n-1)$ 条边的三角形计数，估计方式为：

$$T'_{i,j} = \frac{(b'_j - q_1)[\hat{C}_{i,j} - (n-2)q_L]}{(1-2q_1)(1-2q_L)},$$

其中 $q_L = \frac{1}{e^{\varepsilon_L} + 1}$ ， $q_1 = \frac{1}{e^{\varepsilon_1} + 1}$ ， b'_j 为 $\mathbf{B}'_i$ 中的第 j 位或 $\mathbf{B}'_j$ 中的第 i 位， $\hat{C}_{i,j}$ 为噪声边契形列表 $W'_{i,j}$ 中 1 的数量。进一步地，数据收集者便可计算用户 i 的局部三角形

计数估计, 即

$$T'_i = \frac{\sum_{j=1}^n T'_{i,j} (j \neq i)}{2}。$$

根据定理 4.8 可知, 用户 i 的局部三角计数估计 T'_i 是其真实三角计数 T_i 的无偏估计。

基于上述方式, 数据收集者可依次估计每个分布式用户的局部三角计数估计, 采集图 G 的三角计数估计序列 $T' = (T'_1, T'_2, \dots, T'_n)$ 。

定理 4.7. 边 (i, j) 关联的三角计数估计 $T'_{i,j}$ 是其关联的真实三角计数 $T_{i,j}$ 的无偏估计。

证明: 证明 $T'_{i,j}$ 是 $T_{i,j}$ 的无偏估计, 即证明

$$E(T'_{i,j}) = E\left\{\frac{(b'_j - q_1)[\hat{C}_{i,j} - (n-2)q_L]}{(1-2q_1)(1-2q_L)}\right\} = E\left[\frac{(b'_j - q_1)C'_{i,j}}{1-2q_1}\right] = T_{i,j}。$$

其中, $q_L = \frac{1}{e^{\varepsilon_L} + 1}$, $q_1 = \frac{1}{e^{\varepsilon_1} + 1}$, b'_j 为 $\mathbf{B}'_i$ 中的第 j 位或 $\mathbf{B}'_j$ 中的第 i 位, $\hat{C}_{i,j}$ 和 $C'_{i,j}$ 分别表示噪声边契形列表 $\mathbf{W}'_{i,j}$ 中 1 的数量和契形列表 $\mathbf{W}_{i,j}$ 中 1 的数量的估计值。

首先证明 $E(C'_{i,j}) = C_{i,j}$, 即

$$\begin{aligned} E(C'_{i,j}) &= E\left\{\frac{[\hat{C}_{i,j} - (n-2)q_L]}{1-2q_L}\right\} = \frac{(1-q_L)C_{i,j} + (n-2-C_{i,j})q_L - (n-2)q_L}{1-2q_L} \\ &= \frac{(1-2q_L)C_{i,j}}{1-2q_L} = C_{i,j}, \end{aligned}$$

其中, $C_{i,j}$ 为真实契形列表 $\mathbf{W}_{i,j}$ 中 1 的数量。因此, 可知 $C'_{i,j}$ 为真实 $C_{i,j}$ 的无偏估计, 有

$$E(T'_{i,j}) = E\left[\frac{(b'_j - q_1)C'_{i,j}}{1-2q_1}\right] = C_{i,j}E\left[\frac{(b'_j - q_1)}{1-2q_1}\right]。$$

其次, 存在两种情况:

1. 若边 (i, j) 不存在, 此时 $T_{i,j} = 0$, b'_j 等于 1 的概率为 q_1 。因此,

$$E(T'_{i,j}) = E\left[\frac{(b'_j - q_1)C'_{i,j}}{1-2q_1}\right] = 0 = T_{i,j}。$$

2. 若边 (i, j) 存在, 此时 $T_{i,j} = C_{i,j}$, b'_j 等于 1 的概率为 $p_1 = 1 - q_1$ 。因此,

$$E(T'_{i,j}) = E\left[\frac{(b'_j - q_1)C'_{i,j}}{1 - 2q_1}\right] = E\left[\frac{(1 - q_1 - q_1)C'_{i,j}}{1 - 2q_1}\right] = E[C'_{i,j}] = C_{i,j} = T_{i,j}。$$

综上, $E(T'_{i,j}) = T_{i,j}$, 即 $T'_{i,j}$ 是 $T_{i,j}$ 的无偏估计。 证毕。

定理 4.8. 用户 i 的局部三角计数估计 T'_i 是其真实三角计数 T_i 的无偏估计。

证明: 证明 T'_i 是 T_i 的无偏估计, 即证明

$$E(T'_i) = E\left[\frac{\sum_{j=1}^n T'_{i,j} (j \neq i)}{2}\right] = \frac{\sum_{j=1}^n E(T'_{i,j}) (j \neq i)}{2} = T_i。$$

依据定理 4.7 可知, $E(T'_{i,j}) = T_{i,j}$ 。因此有

$$E(T'_i) = \frac{\sum_{j=1}^n E(T'_{i,j}) (j \neq i)}{2} = \frac{\sum_{j=1}^n T_{i,j} (j \neq i)}{2} = T_i。$$

综上, $E(T'_i) = T_i$, 即 T'_i 是 T_i 的无偏估计。 证毕。

(2)优化度值。根据文献[25]可知, 若数据收集者持有用户 i 的噪声邻接向量 B'_i 和具备拉普拉斯噪声的度值 d'_i , 其可进一步通过二者对度值进行优化, 优化方式为:

$$\tilde{d}_i = \operatorname{argmin}_{\tilde{d}_i} \left[(\bar{d}_i - \tilde{d}_i)^2 + \phi^2 |d'_i - \tilde{d}_i| \varepsilon_2 \right],$$

$$\text{其中, } \phi^2 = n \left[\frac{1}{16(p_1 - 1/2)^2} - \left(\frac{d_i}{n} - \frac{1}{2} \right)^2 \right], \quad \bar{d}_i = \frac{\sum_{j=1}^n B'_{i,j} + n(p_1 - 1)}{2p_1 - 1}, \quad p_1 = \frac{e^{\varepsilon_1}}{e^{\varepsilon_1} + 1},$$

$\tilde{d}_i$ 表示用户 i 优化后的度值。

在此, 本章也采用该方法对噪声度值进行优化。进一步地, 数据收集者便可通过该方法依次优化每个用户的噪声度值, 获取最优噪声度序列 $\tilde{D} = (\tilde{d}_1, \tilde{d}_2, \dots, \tilde{d}_n)$ 。

转换不变性表明, 对满足 DP 的算法输出进行后处理不会影响隐私保障^[61]。因此, 度值的优化过程不会影响隐私保护。

(3)计算全局聚类系数。在结束(1)和(2)的估计和优化过程后, 数据收集者便可持有三角计数序列估计 $T' = (T'_1, T'_2, \dots, T'_n)$ 和优化后的度序列 $\tilde{D} = (\tilde{d}_1, \tilde{d}_2, \dots, \tilde{d}_n)$ 。进而, 数据收集者便可依次计算每个用户的局部聚类系数估计, 并发布最终的全局聚类系数估计。以用户 i 为例, 其局部聚类系数估计可记为:

$$CC'_i = \frac{2T'_i}{\tilde{d}_i(\tilde{d}_i - 1)},$$

其中, T'_i 和 $\tilde{d}_i$ 分别对应用户 i 的局部三角计数估计以及优化后的度值。以此类推, 数据收集者可依次计算每个用户的局部聚类系数估计, 得到图 G 的全局聚类系数估计 $CC' = (CC'_1, CC'_2, \dots, CC'_n)$, 并将其发布。

4.3 GCC-SDP 算法

基于 4.2 节的描述, 本节进一步阐述 GCC-SDP 的具体算法, 主要包含两个部分, 分别为用户端算法和数据收集者算法。

4.3.1 用户端算法

算法 4.1 为用户端算法, 以实现图 4.1 中步骤②和步骤③, 即报告噪声楔形列表、噪声邻接矩阵及噪声度值。具体而言, 分为 3 个部分。

首先, 算法 4.1 中 1-11 行为楔形列表报告过程。以报告用户 i 的楔形列表 W_i 为例, 当报告 W_i 时, 需要其他 $n-1$ 个用户依次通过 ε_L -RR 和混洗器, 向数据收集者报告用户 i 与节点号大于其的用户之间的边所对应的楔形列表。其次, 算法 4.1 中 12-13 行为邻接向量报告过程。用户分别通过 ε_1 -RR, 扰动其邻接向量 $B_i = (b_1, b_2, \dots, b_n)$ 中的前 $i-1$ 位, 并将其报告给数据收集者。最后, 算法 4.1 中第 14 行为度值报告过程。所有分布式用户依次向自身度值添加 $Lap(2/\varepsilon_2)$ 的噪声, 并将其报告给数据收集者。

算法 4.1 用户端算法

输入: 邻接矩阵 $M = (B_1, B_2, \dots, B_n)$, $B_i = (b_1, b_2, \dots, b_n)$, $b_j \in \{0, 1\}$, 隐私预算 ε , 隐私泄露率 σ , 隐私预算分配率 α , 隐私预算 $\varepsilon_1 = \alpha\varepsilon$, $\varepsilon_2 = (1-\alpha)\varepsilon$, $\varepsilon_L = f(n-2, \varepsilon_1/2, \sigma/2)$ 。

输出: 噪声楔形列表 $W' = (W'_1, W'_2, \dots, W'_n)$, 噪声下三角邻接矩阵 $M' = (B'_1, B'_2, \dots, B'_n)$, 噪声度序列 $D' = (d'_1, d'_2, \dots, d'_n)$

1. for i in $\{1, 2, \dots, n\}$ do

 用户端(I_i 中的用户)

2. for j in $I_{j>i}$ do // $I_{j>i}$ 表示图 G 中顶点号大于 i 的用户集合

3. for k in $I_{i,j}$ // $I_{i,j}$ 表示图 G 中除用户 i 和用户 j 以外的用户集合

4. $e_k \in \{0, 1\} \leftarrow w_{i-k-j}$ // 判断是否存在楔形 w_{i-k-j} , 存在为 1, 否则 0

5. $e'_k = RR_{\varepsilon_L}(e_k)$ // 通过 ε_L -RR 扰动真实楔形计数

6. 将 $e'_k = RR_{\varepsilon_L}(e_k)$ 发送给混洗器

7. end
 8. $W'_{i,j} = (e'_1, e'_2, \dots, e'_{n-2}) = (0,1)^{n-2}$ //边 (i, j) 的噪声契形列表
 9. $Shuffle(W'_i)$ //混洗器对噪声契形列表进行洗牌
 10. 混洗器将打乱后的 $W'_{i,j}$ 发送给数据收集者
 11. end
- 用户端(用户 i)

12. 通过 ε_1 -RR 扰动 B'_i 中的前 $i-1$ 位

$$B'_i[j](j < i) = \begin{cases} B_i[j], & p_1 = \frac{e^{\varepsilon_1}}{e^{\varepsilon_1} + 1}; \\ 1 - B_i[j], & q_1 = \frac{1}{e^{\varepsilon_1} + 1}; \end{cases}$$

13. $B'_i = (b'_1, b'_2, \dots, b'_{i-1}) = \{0,1\}^{i-1}$
14. 计算噪声度值

$$d'_i = d_i + Lap(2/\varepsilon_2)$$

15. 将 B'_i 和 d'_i 发送给数据收集者
16. end
17. $W' = (W'_1, W'_2, \dots, W'_n)$, $M' = (B'_1, B'_2, \dots, B'_n)$, $D' = (d'_1, d'_2, \dots, d'_n)$
18. Return W' , M' , D'

算法 4.1 中，每个用户需要配合其他用户报告契形列表、报告自身邻接向量的前 $i-1$ 位以及计算度值。因此，用户的空间复杂度和时间复杂度上限为 $((n-2)(n-1)/2)$ 。混洗器需要对每条边的契形列表进行洗牌，洗牌一次的时间复杂度为 $O(1)$ ，且一个契形列表具备 $n-2$ 个布尔值。因此混洗器的整体空间复杂度为 $O(n^2(n-1)/2)$ ，时间复杂度为 $O(n(n-1)/2)$ 。

4.3.2 数据收集者算法

算法 4.2 为数据收集者算法，以实现图 4.2 中步骤④，即估计三角计数、优化度值和计算聚类系数估计。具体而言，分为 3 个部分。

首先，算法 4.2 中 1-6 行为估计三角计数过程；数据收集者依次估计每个用户可能存在的 $n-1$ 条边所关联的三角计数，并最终求和各用户的局部三角计数估计。其次，算法 4.2 中第 7 行为度值优化过程；数据收集者根据噪声度序列和噪声邻接矩阵依次优化各用户的度值，并获取最终的度序列。最后，算法 4.2 中第 8 行为聚类系数计算过程；数据收集者根据各用户的局部三角计数估计和优化后

的度序列，依次计算各用户的聚类系数估计，并发布最终的聚类系数估计。

算法 4.2 数据收集者算法

输入：噪声契形列表 $W'=(W'_1, W'_2, \dots, W'_n)$ ，噪声下三角邻接矩阵 $M'=(B'_1, B'_2, \dots, B'_n)$ ，噪声度序列 $D'=(d'_1, d'_2, \dots, d'_n)$

输出：聚类系数估计 $CC'=(CC'_1, CC'_2, \dots, CC'_n)$

1. for i in $\{1, 2, \dots, n\}$ do
2. for j in I_i do
3. $\hat{C}_{i,j} = \sum_{j=1}^{n-2} W'_{i,j}$ or $\hat{C}_{i,j} = \sum_{j=1}^{n-2} W'_{j,i}$ //统计边 (i, j) 的噪声契形列表

$W'_{i,j}$ 或 $W'_{j,i}$ 中 1 的数量

4. 估计边 (i, j) 关联的三角计数估计

$$T'_{i,j} = \frac{(b'_j - q_1) [\hat{C}_{i,j} - (n-2)q_L]}{(1-2q_1)(1-2q_L)}$$

// b'_j 为 $M'_{i,j}$ 或 $M'_{j,i}$

5. end
6. 计算用户 i 的局部三角计数估计

$$T'_i = \frac{\sum_{j=1}^n T'_{i,j} (j \neq i)}{2}$$

7. 优化度值

$$\tilde{d}_i = \operatorname{argmin}_{\tilde{d}_i} \left[(\bar{d}_i - \tilde{d}_i)^2 + \phi^2 |d'_i - \tilde{d}_i| \varepsilon_2 \right],$$

8. 计算用户 i 的局部聚类系数估计

$$CC'_i = \frac{2T'_i}{\tilde{d}_i(\tilde{d}_i - 1)}$$

9. end

10. $CC'=(CC'_1, CC'_2, \dots, CC'_n)$

11. Return CC'

算法 4.2 中，数据收集者需收集噪声契形列表、噪声邻接矩阵以及噪声度序列，并计算每个用户的聚类系数估计，因此空间复杂度为 $O(n(n^2+1)/2)$ 。同时，其需要估计每个用户可能存在的 $n-1$ 条边关联的三角计数、汇总每个用户的局部三角计算、优化度值以及计算聚类系数，时间复杂度为 $O(n^2)$ 。

4.4 隐私与效用分析

本节对本章所提算法 GCC-SDP 隐私及效用进行分析,证明了算法 GCC-SDP 满足的各类 DP 保护,以及发布的聚类系数是无偏的。具体见定理 4.9 和定理 4.10。

定理 4.9. 算法 GCC-SDP 满足 $(\varepsilon_1 + \varepsilon_2/2, \sigma/2)$ -DP、 $((n-1)\varepsilon_1 + \varepsilon_2, (n-2)\sigma)$ -Edge-DP, 并且至少满足 $\varepsilon_L + \varepsilon_2/2$ -LDP 和 $\varepsilon_L + \varepsilon_2/2$ -Edge-LDP。

证明: 根据 4.1 节可知, 算法 GCC-SDP 主要分为四个步骤, 而提供隐私保护的步骤为步骤②和步骤③。

首先, 根据定理 4.5, 步骤②满足 $(\varepsilon_1, \sigma/2)$ -DP、 $((n-1)\varepsilon_1, (n-2)\sigma)$ -Edge-DP, 并且至少满足 ε_L -LDP 和 ε_L -Edge-LDP。

其次, 根据定理 4.6, 步骤③满足 $\varepsilon_2/2$ -DP、 ε_2 -Edge-DP、 $\varepsilon_2/2$ -Edge-LDP、 $\varepsilon_2/2$ -LDP。

需要注意的是, 任意用户 i 的度值 d_i 可以通过计算其邻接向量 B_i 得出。因此, 步骤②和步骤③所报告的数据具备相关性。根据 DP 的序列组合性质, 算法 GCC-SDP 的隐私保护满足 $(\varepsilon_1 + \varepsilon_2/2, \sigma/2)$ -DP、 $((n-1)\varepsilon_1 + \varepsilon_2, (n-2)\sigma)$ -Edge-DP, 并且至少满足 $\varepsilon_L + \varepsilon_2/2$ -LDP 和 $\varepsilon_L + \varepsilon_2/2$ -Edge-LDP。 **证毕。**

定理 4.10. 算法 GCC-SDP 发布的任意用户 i 的局部聚类系数估计 CC'_i 是其真实聚类系数 CC_i 的无偏估计。

证明: 证明 CC'_i 是 CC_i 的无偏估计, 即证明

$$E(CC'_i) = CC_i.$$

首先, 根据定理 4.8, $E(T'_i) = T_i$ 。

其次, 根据拉普拉斯机制的性质, 其结果是无偏的。因此, 有

$$E(CC'_i) = E\left[\frac{2T'_i}{\tilde{d}_i(\tilde{d}_i - 1)}\right] = 2E(T'_i)E\left[\frac{1}{\tilde{d}_i(\tilde{d}_i - 1)}\right] = 2T_i \frac{1}{d_i(d_i - 1)} = CC_i.$$

综上, $E(CC'_i) = CC_i$, 即 CC'_i 是 CC_i 的无偏估计。

证毕。

4.5 实验分析

为评估所提基于混洗差分隐私的聚类系数发布场景下的效用, 本节选取多个公开真实数据集进行实验对比分析。首先, 介绍实验数据集的一般特征信息和效用度量方法。其次, 在相同隐私预算下, 分别在真实数据集和生成图数据集上比较 GCC-SDP 与其他基于 LDP 的算法的效用。再次, 分别分析隐私预算分配率 α 和隐私披露率 σ 对收集数据效用的影响。本节实验均在 Inter Core i5-6200U CPU

处理器、Windows 10 系统上运行，利用 Python3.8 进行实现。

4.5.1 实验设置

本节实验数据集选取了 Stanford Large Network Dataset Collection 网站上 4 个具有代表性的真实图数据集，这些数据集也被广泛应用于图数据隐私保护研究中^[24-26,31]。由于公开数据集都非分布式的图数据，为了有效评估不同算法在分布式图数据发布中的隐私保护效果，本文采用与文献^[24-26,31]相同的数据处理方法，对实验图数据集进行了分布式处理，使得每个分布式用户仅持有单个顶点的一阶邻居子图。

实验选取的图数据集分别为 Facebook，Lastfm，AstroPh，Email-Enron，表 4.1 简要分析了数据集包含的节点数、边数，以及最大度和平均度等特征信息。

4.1 真实图数据集的主要特征

数据集	节点数	边数	最大度	平均度
Facebook	4039	88234	1045	43.7
Lastfm	7624	27806	216	7.3
AstroPh	18772	198110	504	21.1
Email-Enron	36692	367662	1383	10

为对比分析聚类系数发布效用，本节在实验中采用均方误差 MSE (mean squared error)和平均绝对误差 MAE (mean absolute error)2 个指标进行量化对比。

设 $CC = (CC_1, CC_2, ..., CC_n)$ 和 $CC' = (CC'_1, CC'_2, ..., CC'_n)$ 分别为原始图数据和隐私

保护发布后的聚类系数， $MSE = \frac{1}{n} \sum_{i=1}^n (CC_i - CC'_i)^2$ 和 $MAE = \frac{1}{n} \sum_{i=1}^n |CC_i - CC'_i|$ 。其


中， MSE 和 MAE 值越小，则表明发布的聚类系数效用越优。

4.5.2 效用分析

本节比较本章所提出的算法 GCC-SDP 与算法 LF-GDPR^[25]、RNL^[24]和 Local2Round_Δ^[26]在发布聚类系数时的效用。其中，三者均为基于 LDP 的隐私保护算法，可通过在分布端收集聚类系数。具体而言，算法 RNL 通过采用 RR 机制对邻接向量进行扰动加噪，并利用带噪声的邻接矩阵直接估计聚类系数；算法 LF-GDPR 在算法 RNL 的基础之上，将一定的隐私预算分配给噪声度序列，以获取精度更高的度值，进而计算更高效的聚类系数；算法 Local2Round_Δ则是一种两轮交互模型，它在第一轮交互过程中通过 RR 收集噪声图 G (噪声邻接矩阵)，并将其发还给用户，由用户在第二轮交互过程报告三角计数或度值，以提升效用。

在此，我们设置算法 Local2Round $_{\Delta}$ 来发布聚类系数。本节分别在表 4.1 中 4 个真实数据集和生成图数据集上，测试 4 种算法在相同隐私预算时，发布聚类系数的效用。

首先，设定隐私预算为 $\varepsilon = [1, 2, 3, 4, 5]$ ，在表 4.1 中 4 个真实数据集上测试 4 中算法的效用，采用 *MSE* 和 *MAE* 指标进行度量。如图 4.2 所示，图 4.2(a), (c), (e), (g)和图 4.2 (b), (d), (f), (h)分别为 *MSE* 和 *MAE* 指标结果。可直观发现，大多数情况下，所提算法 GCC-SDP 发布的聚类系数在 *MSE* 和 *MAE* 效用指标上均优于其他三种 LDP 算法。具体而言，如图 4.2(a)和(b)所示，在 Facebook 数据集上，当 $\varepsilon = [1, 2, 3, 4, 5]$ 时，算法 GCC-SDP 发布的聚类系数在 *MSE* 和 *MAE* 指标上优于算法 RNL 和 Local2Round $_{\Delta}$ 约 15.2%~66.5%和 10%~51%。与算法 LF-GDPR 相比，当 $\varepsilon = [1, 2, 3, 4]$ 时，算法 GCC-SDP 的效用在 *MSE* 和 *MAE* 指标上也优于算法 LF-GDPR 约 8%~30%和 3%~18%；而当 $\varepsilon = 5$ 时，二者的效用则相似。同理，在 Lastfm、AstroPh 以及 Email-Enron 数据集上，算法 GCC-SDP 相较于其他三种 LDP 算法均存在不同程度的效用优势。可直观发现，当数据集相对较小时，算法 GCC-SDP 相较于现有的 LDP 算法具备更高的效用；而当数据集较大时，算法 GCC-SDP 的整体效用将与算法 LF-GDPR 相似。此外，算法 GCC-SDP 的效用优势会随着 ε 的增加而缓慢上升。








图 4.2 真实数据集上 4 种算法发布聚类系数效用对比

其次，为进一步彰显所提算法 GCC-SDP 的效用优势，设定 $\varepsilon = [1, 2, 3, 4, 5]$ ，分别在规模为 $n = 10^3 \times [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]$ 的生成图数据集上测试 4 种算法发布聚类系数的效用。如图 4.3 所示，图 4.3(a), (c), (e), (g), (i) 和图 4.3 (b), (d), (f), (h), (j) 分别为四种算法在生成数据集上 MSE 和 MAE 效用指标结果。根据图 4.3 可直观发现，随着生成图数据集规模的逐渐增大，算法 GCC-SDP 在不同 ε 下的聚类系数的发布效用优于其他 3 种 LDP 算法。具体而言，如图 4.3(a) 和 (b) 所示，当 $\varepsilon = 1$ 时，算法 GCC-SDP 发布的聚类系数在 MSE 和 MAE 效用指标上优于算法 RNL 约 52%~72% 和 43%~57%，且效用接近于算法 Local2Round $_{\Delta}$ 和 LF-GDPR。如图 4.3(c) 和 (d) 所示，当 $\varepsilon = 2$ 时，算法 GCC-SDP 发布的聚类系数在 MSE 和 MAE 效用指标上优于算法 RNL 和 LF-GDPR 约 63.5%~94% 和 38.5%~81.5%；同时，除 $n = 10 \times 10^3$ 外，算法 GCC-SDP 在 MSE 和 MAE 指标上较算法 Local2Round $_{\Delta}$ 同样具备约 9%~67% 和 2%~44% 的效用优势。同理，如图 4.2(e)-(j)，当 $\varepsilon = [3, 4, 5]$ 时，无论 n 为何值，算法 GCC-SDP 均具备更大的效用优势。


总体而言，本章所提算法 GCC-SDP 在发布聚类系数时相较于现有的 LDP 算法具备显著的效用优势。




(a) $\varepsilon=1$ 时 MSE 度量




(b) $\varepsilon=1$ 时 MAE 度量




(c) $\varepsilon=2$ 时 MSE 度量




(d) $\varepsilon=2$ 时 MAE 度量




(e) $\varepsilon=3$ 时 MSE 度量



(f) $\varepsilon=3$ 时 MAE 度量



(g) $\varepsilon=4$ 时 MSE 度量



(h) $\varepsilon=4$ 时 MAE 度量





图 4.3 生成数据集上 4 种算法发布聚类系数效用对比

4.5.3 隐私预算分配率对效用的影响

本章所提算法 GCC-SDP 需要通过隐私分配率 α 对隐私预算 ϵ 进行拆分, 即 $\epsilon_1 = \alpha\epsilon$ 用于报告三角计数, $\epsilon_2 = (1-\alpha)\epsilon$ 用于报告度值。不同的隐私分配率 α 可能会对算法 GCC-SDP 的最终效用产生不同的影响。因此, 为进一步探究不同 α 对算法 GCC-SDP 的实际影响, 找到尽可能优的 α 使得效用最大化, 本节在前述表 4.1 中 4 个真实数据集上进行测试。本节仍采用 MSE 和 MAE 两个指标进行度量。


实验设定隐私预算为 $\epsilon = [1, 2, 3, 4, 5]$, 探究分配率 $\alpha = [0.3, 0.5, 0.7, 0.9]$ 对 GCC-SDP 最终效用的影响。实验图如图 4.4 所示, 其中图 4.4(a), (c), (e), (g) 和图 4.4 (b), (d), (f), (h) 分别为 MSE 和 MAE 指标结果。首先, 如图 4.4(a) 和 (b) 以及图 4.4(g) 和 (h) 所示, 在 Facebook 和 Email-Enron 数据集上, 随着 ϵ 的增加, $\alpha = 0.7$ 时 MSE 和 MAE 两个效用指标明显优于其他三个值 ($\alpha = [0.3, 0.5, 0.9]$)。其次, 如图 4.4(c) 和 (d) 以及图 4.4(e) 和 (f) 所示, 在 Lastfm 和 AstroPh 数据集上, $\alpha = 0.9$ 时 MSE 和 MAE 两个效用指标最优; 除此之外, 当 $\alpha = 0.7$ 时, 算法 GCC-SDP 对应 MSE 和 MAE 两个指标接近 $\alpha = 0.9$ 时; 而当 α 较小时, 即 $\alpha = 0.3$ 或 $\alpha = 0.5$ 时, 算法 GCC-SDP 在 Lastfm 和 AstroPh 数据集上发布的聚类系数效用最低。

可得出结论, 在大多数情况下, 可以尽可能的设置更大的隐私预算分配率 α ($\alpha = 0.7 \sim 0.9$) 来保证 GCC-SDP 发布聚类系数时的效用。




(a) Facebook 上 MSE 度量

(b) Facebook 上 MAE 度量




(c) Lastfm 上 MSE 度量

(d) Lastfm 上 MAE 度量



(e) AstroPh 上 MSE 度量

(f) AstroPh 上 MAE 度量



(g) Email-Enron 上 MSE 度量

(h) Email-Enron 上 MAE 度量

图 4.4 真实数据集上隐私分配率 α 对算法 GCC-SDP 效用影响

4.5.4 隐私泄露率对效用的影响

根据定理 3.9(隐私放大理论)可知,除初始隐私预算 ε 和用户数 n 外,隐私泄露率 σ 同样是计算混洗放大后的隐私预算 ε_L 的重要参数。因此,本节在 Facebook 数据集上进行测试,评估隐私泄露率 σ 对算法 GCC-SDP 最终效用的影响。

本节实验仅在 Facebook 数据集上进行测试,设定隐私预算为 $\varepsilon=[1,2,3,4,5]$,分别探究分配率 $\sigma=[10^{-1},10^{-2},10^{-3},10^{-4},10^{-5},10^{-6},10^{-7}]$ 对 GCC-SDP 最终效用的影响。实验图如图 4.5 所示,其中图 4.5(a)和图 4.5 (b)分别为 MSE 和 MAE 效用指标。如图 4.5(a)和图 4.5 (b)所示,可直观发现,随着 σ 的逐步减少,无论 ε 为何值,整体的效用都是趋于稳定的,即 σ 对算法 GCC-SDP 最终效用影响较小。因此,可得出结论,在真实场景中,可以将 σ 设置得尽可能小,以保证数据的安全性和低泄漏率。




图 4.5 隐私泄露率 σ 对算法 GCC-SDP 效用影响

4.6 本章小结

为了改善分布式场景中聚类系数收集效率低的问题,本章尝试引入 SDP 来发布高纬度、高结构特征的聚类系数,提出一种基于 SDP 的分布式图数据聚类系数发布算法。与传统的 LDP 机制直接采用 RR 发布子图度量(如楔形、邻接位向量和度)所不同,该算法引入 SDP 收集用户的楔形列表,并结合 RR 机制和拉普拉斯机制分别收集用户的邻接位向量和度值。进而确保数据收集者具备足够有效的信息来估计全局图数据聚类系数。同时,本章在理论上证明了 GCC-SDP 的各种 DP 以及该领域的不足,并且收集的结果是无偏的。最后,实验结果表明,在大多数情况下,所提算法在发布精度方面优于其他 LDP 方案。

第 5 章 基于本地差分隐私的分布式图统计发布算法

依据前述内容,可直观发现,SDP 模型虽可提升分布式图统计指标的最终发布效用,但在发布强关联性及高纬度统计指标时,仍难以实现高 Edge-DP 约束。同时,无论是 SDP 机制和现有的 LDP 算法,均难以实现多统计指标的同时发布,及自适应强度的 DP 保护。

因此,为了满足分布式图数据应用中的多样化统计指标发布需求,实现高强度和个性化的隐私保护,且降低扰动加噪对数据效用的影响,本章引入 Node-LDP 和 Edge-LDP 提出基于本地差分隐私的图统计指标发布算法 GS-LDP,将度值发布作为基础统计指标发布,在发布过程中通过限制加噪的扰动域来降低噪声输入,并在加噪过程中对用户子图进行剪枝来大幅降低无效噪声量提升数据效用,通过自适应隐私设置来调节满足 Node-LDP 或 Edge-LDP 以适应用户的个性化隐私偏好。具体地:首先,引入分组机制和对称一元编码,提出一种满足 Node-LDP 的图数据度分布发布算法,通过限制 SUE 扰动域上限的方式降低发布过程中的噪声输入,实现 Node-LDP 保护的同时实施高效用的分布式图数据度分布发布;其次,基于所提出的度分布发布算法,利用剪枝(Prune)算法对用户持有的子图进行剪枝,通过设置度值阈值来对一阶邻居子图的邻居位向量进行剪切投影,从而限制随机过程中所产生的噪声边的量,通过大幅度降低无效噪声提高数据效用;再次,引入拉普拉斯机制、随机响应机制和 2 轮交互模型,提出满足 Node-LDP 和 Edge-LDP 的三角计数序列发布算法及满足 Node-LDP 和 Edge-LDP 的聚类系数发布算法,通过自适应隐私设置来调节满足 Node-LDP 或 Edge-LDP 以适应用户的个性化隐私偏好,实现不同隐私保护强度和数据效用需求的分布式图数据多统计指标发布。

5.1 基于本地差分隐私的图统计发布框架

本节阐述基于 LDP 的图数据统计发布(GS-LDP)框架。分布式图数据应用场景下,所有用户仅持有包含自身节点的一阶邻居子图,而非拥有整个图数据集,数据收集者(服务提供者)希望能采集到整个图数据的度分布、三角计数序列和聚类系数等多个统计指标进行发布;为了避免自身的身份隐私和与他人间的关系隐私遭受泄露,用户不愿将自身和他人的原始数据直接共享发布给数据收集者^[64]。故而在数据发布的过程中需要考虑用户的不同隐私需求和数据收集者发布不同统计指标时的数据效用需求。

为了同时实现分布式图数据的多个统计指标隐私保护发布,结合 Node-LDP

和 Edge-LDP 设计 GS-LDP 算法，具体构建框架如图 5.1 所示。




图 5.1 基于本地差分隐私的图数据统计指标发布框架

图 5.1 中，所提 GS-LDP 算法主要实现 3 个统计指标的隐私保护发布，即度分布、三角序列和聚类系数。这 3 个统计指标差异性较大，其中度分布相对单一，三角序列和聚类系数具有复杂结构性。因此，针对不同的统计指标发布需求，分别设计了基于 Node-LDP 的度分布、基于 Node-LDP 的三角序列和聚类系数发布，以及基于 Edge-LDP 的三角序列和聚类系数发布算法。在 GS-LDP 算法中，三角计数序列和聚类系数 2 个统计指标的发布依赖于度分布设置阈值，同时聚类系数需要基于三角计数结果进行估计。

(1) 基于 Node-LDP 的度分布发布算法。 由于各用户持有子图定点的度值属于各用户可直接计算的数值类数据，采用 Edge-LDP 发布此类数据将无法有效保护关系隐私。因此，引入分组机制和 SUE 机制设计基于 Node-LDP 的度分布发布算法。具体如图 5.1 中指标 I 所示，以单个用户与数据收集者的交互为例，过程为：首先，数据收集者将初始隐私预算 ϵ 和组距 L 发布给用户；其次，用户 i 收到 ϵ 和 L 后，根据自身度值 d_i 和 L 计算组号 g_i ($g_i = \lfloor d_i/L \rfloor$)；再次，用户 i 根据 g_i 将 d_i 归一化 ($d_i' = d_i - g_i L$)，并通过一元编码将归一化的 d_i' 编码成 1 个维度为 L 的二元

度向量；然后，用户 i 通过对称一元编码扰动机制对度向量进行逐位扰动，并将扰动结果发送给数据收集者；最后，数据收集者分组聚合估计各度值的频率，得到满足 Node-LDP 的度分布结果。具体算法和证明过程见 5.2 节。

2) 基于 Node-LDP 和 Edge-LDP 的三角序列发布算法。该算法过程如图 5.1 的统计指标 II 所示，具体包含 1 个参数设置阶段和 1 个 2 轮交互过程。在参数设置阶段，首先，数据收集者将初始隐私预算 ε 拆分为 $\varepsilon_1, \varepsilon_2, \varepsilon_3$ ，并将 $\varepsilon_1, \varepsilon_2, \varepsilon_3$ ，组距 L 和频率上限 $Level$ 发布给每位用户；其次，用户和数据收集者以 ε_1 和 L 为参数按照基于 Node-LDP 的度分布发布算法过程获得图数据的度分布估计，并将度频率和达到 $Level$ 时的度值设为度阈值 θ (即 $\sum_{j=0}^{\theta} f'_j \geq Level$ ，其中 f'_j 为度为 j 的频率估计)。在第 1 轮交互中，首先，用户通过 θ 和 Prune 算法将自身一阶邻居子图的邻接向量 $\mathbf{B}_i$ 进行裁剪；其次，用户通过 ε_2 -RR 机制对裁剪后的邻接向量 $\mathbf{B}'_i$ 进行扰动，将扰动结果 $\tilde{\mathbf{B}}_i$ 发送给数据收集者；然后，数据收集者基于所有用户发送的扰动邻接向量 $\tilde{\mathbf{B}}_i$ ，构建噪声图 G' ，并将 G' 发送给各用户。在第 2 轮交互中，首先，用户根据 $\mathbf{B}'_i$ 和 G' 对自身局部三角计数 T_i 进行估计；其次，用户通过 ε_3 -拉普拉斯机制将估计值扰动后发送给数据收集者；然后，数据收集者对所有用户的估计值进行后处理，获取每个用户的局部三角计数估计 T'_i ，进而发布满足 Node-LDP 或 Edge-LDP 的三角计数序列估计 $T' = (T'_1, T'_2, \dots, T'_n)$ 。

在实际中，根据发布三角计数序列的隐私或效用需求，设置不同的 ε_2 应用于 RR 及不同的敏感度应用于拉普拉斯机制，可使得算法满足 Node-LDP 或 Edge-LDP。具体算法和证明见 5.3 节。

3) 基于 Node-LDP 和 Edge-LDP 的聚类系数发布算法。算法过程如图 5.1 的统计指标 III 所示，包含 3 个步骤。首先，数据收集者将初始隐私预算 ε 拆分为 $\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4$ ，并将 $\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4$ ，组距 L 和频率上限 $Level$ 发布给每位用户；其次，用户以 $\varepsilon_1, \varepsilon_2, \varepsilon_3$ 为隐私参数向数据收集者报告三角计数序列估计 $T' = (T'_1, T'_2, \dots, T'_n)$ ，并以 ε_4 为参数通过拉普拉斯机制向数据收集者报告度值序列 $\tilde{D} = (d'_1, d'_2, \dots, d'_n)$ ；最后，数据收集者根据所获得的 $T' = (T'_1, T'_2, \dots, T'_n)$ 和 $\tilde{D} = (d'_1, d'_2, \dots, d'_n)$ 计算全局聚类系数估计 $CC' = (CC'_1, CC'_2, \dots, CC'_n)$ 。

类似地，在实际中，可以根据发布分布式图数据聚类系数时的隐私或效用需求，设置不同的加噪参数，使算法满足 Node-LDP 或 Edge-LDP。具体算法和证

明见第 5.4 节。

需要注意的是，当算法满足 Node-LDP 时，各分布式用户度值的敏感度为整体图数据的最大度 d_{max} 。在真实分布式场景下：一方面，用户无法在分布式端直接获取全局图数据的最大度值 d_{max} ；另一方面，真实场景图数据往往是稀疏的，敏感度为 d_{max} 的拉普拉斯加噪将使噪声过大。因此，在所设计的算法中，仍采用 θ 为图数据的度阈值，并通过投影技术报告各分布式用户的度值，降低敏感度。

5.2 基于 Node-LDP 的度分布发布算法

面向分布式图数据的统计指标发布过程中，现有基于 LDP 或 Edge-LDP 的度分布发布算法隐私保护效果不佳；同时，现有的 Node-LDP 度分布发布算法往往采用拉普拉斯机制加噪，其加噪敏感度大且投影阈值获取困难。本节设计基于 Node-LDP 的分布式图数据度分布发布算法来提高隐私保护强度，同时引入分组扰动机制和对称一元编码来提高数据效用。首先，详细介绍所提算法；其次，给出算法的分析与证明。

5.2.1 用户分组影响分析

本小节给出具体基于 Node-LDP 的分布式图数据度分布发布算法，即图 5.1 中的指标 I，具体过程如算法 5.1 所示。

在算法 1 中，具体分为 5 个步骤。首先，数据收集者向用户发送度频率分布查询请求，并设置用户隐私预算 ε 和组距 L 。其次，用户依次计算自身组号 g_i ，归一化度值 $(d_i - g_i L)$ ，并将归一化后的度值编码为 1 个 L 维的二元度向量 $\mathbf{D}_i$ (算法 1 第 2-3 行)。再次，用户通过 $\varepsilon/2$ -RR 逐位扰动 $\mathbf{D}_i$ ，并将扰动后的度向量 $\mathbf{D}'_i$ 和 g_i 发送给数据收集者 (算法 1 第 4-5 行)。然后，数据收集者获取所有用户数据后，计算总的分组数量和各组用户数量，并按分组依次校正各度值频率 (第 7~12 行)。例如，以度值 i 为例，设 $v = \lfloor i/L \rfloor$ 和 n_v 分别为其所处组号及当前组用户数量， $j = i - \lfloor i/L \rfloor L$ 为归一化后的度值。数据收集者计算第 v 组中所有噪声度向量中第 j 位为 1 的个数，并通过下式估计频率

$$f'_i = \frac{\sum_{c=0}^{n_v} D'_c[j] - n_v q}{n(p-q)},$$

其中 $\sum_{c=0}^{n_v} D'_c[j]$ 为第 v 组中所有噪声度向量中第 j 位为 1 的个数。最后，数据收集

者可聚合发布所有度值的频率估计 $F' = (f'_0, f'_1, \dots, f'_{maxL-1})$ (第 13 行)。

算法 5.1 基于 Node-LDP 的度分布算法(NLDP-DD)

输入：隐私预算 ε ，组距 L

输出：度频率分布估计 F'

用户端：

1. for j in $\{1, 2, \dots, n\}$ do
2. $g_i = \lfloor d_i / L \rfloor$ //用户 i 的组号
3. $D_i = \text{Unary-Encoding}(d_i - g_i L)$ //对用户 i 的度值进行归一化，并编码为

L 维二元向量

4. 通过 $\varepsilon/2$ -RR 扰动 D_i 中的每一位

$$D'_i[j] = \begin{cases} D_i[j], & p = \frac{e^{\varepsilon/2}}{e^{\varepsilon/2} + 1}; \\ 1 - D_i[j], & q = \frac{1}{e^{\varepsilon/2} + 1}; \end{cases}$$

5. 将 D'_i 和 g_i 发送给数据收集者

6. end

数据收集者端：

7. for v in $\{0, 1, \dots, \max\{g_1, g_2, \dots, g_n\}\}$ do

8. $n_v = \sum_{i=0}^n (g_i = v)$ //组号为 v 的用户数量

9. for j in $\{0, 1, \dots, L-1\}$ do

10. $f'_{j+vL} = \frac{\sum_{c=0}^{n_v} D'_c[j] - n_v q}{n(p-q)}$ //度值为 $j + vL$ 的频率估计

11. end

12. end

13. $F' = (f'_0, f'_1, \dots, f'_{\max L-1})$

14. Return F'
-

在算法 5.1 中，采用分组编码扰动的方式控制每个用户度值的报告域值大小，使得算法 5.1 在满足 Node-LDP 的同时发布精度得到提升。此外，该算法还能进一步避免随机化过程中扰动阈值过大的问题。

5.2.2 度分布发布算法的隐私效用分析

本小节对 5.2.1 节中所提基于 Node-LDP 的分布式图数据度分布发布算法的

隐私及效用进行分析。证明了算法 5.1 满足 ε -Node-LDP, 发布的度值频率估计 f'_i 具有无偏性, 以及 f'_i 的方差。

定理 5.1. 算法 5.1 满足 ε -Node-LDP。

证明: 设 $\mathbf{D}_i$ 和 $\mathbf{D}_j$ 为任意组中的 2 个 L 维二元度向量, 同时设算法 $\mathcal{R}$ 为算法 1 中各用户扰动度向量时的随机算法。易知, $\mathbf{D}_i$ 和 $\mathbf{D}_j$ 中元素最多 2 位不同, 其余位为 0。设 $\mathbf{S} \subseteq \text{range}(\mathcal{R})$ ($\mathbf{S} = (s_1, s_2, \dots, s_L)$, $s_i \in \{0, 1\}$) 为算法 $\mathcal{R}$ 的随机输出。不失一般性, 设 $\mathbf{D}_i$ 和 $\mathbf{D}_j$ 仅前 2 位不同, 则有

$$\begin{aligned} \frac{\Pr[\mathcal{R}(\mathbf{D}_i) = \mathbf{S}]}{\Pr[\mathcal{R}(\mathbf{D}_j) = \mathbf{S}]} &= \frac{\Pr[\mathcal{R}(b_1) = s_1] \Pr[\mathcal{R}(b_2) = s_2] \dots \Pr[\mathcal{R}(b_L) = s_L]}{\Pr[\mathcal{R}(b'_1) = s_1] \Pr[\mathcal{R}(b'_2) = s_2] \dots \Pr[\mathcal{R}(b'_L) = s_L]} \\ &= \frac{\Pr[\mathcal{R}(b_1) = s_1] \Pr[\mathcal{R}(b_2) = s_2]}{\Pr[\mathcal{R}(b'_1) = s_1] \Pr[\mathcal{R}(b'_2) = s_2]} \leq \frac{p^2}{q^2} = e^{\frac{2\varepsilon}{2}} = e^\varepsilon, \end{aligned}$$

其中 $p = \frac{e^{\varepsilon/2}}{e^{\varepsilon/2} + 1}$, $q = 1 - p$ 。因此, 任意分布式用户报告度向量的随机化过程均

满足 ε -Node-LDP。

进一步, 根据引理 2.2, 算法 5.1 整体满足 ε -Node-LDP。

证毕。

定理 5.2. 算法 5.1 所估计的度值频率 f'_i 是真实频率 f_i 的无偏估计。

证明: 设 $z = \sum_{c=0}^{n_v} D'_c[j]$, 即第 v 组中各用户度向量第 j 位为 1 的数量, 则

$$f'_i = \frac{z - qn_v}{n(p - q)}, \text{ 有}$$

$$E(f'_i) = E\left[\frac{z - qn_v}{n(p - q)}\right] = \frac{1}{n(p - q)}[E(z) - qn_v]。$$

设 f_i 为真实度值为 i 的频率, $w = nf_i$ 为对应的频数, 则有

$$E(z) = wp + (n_v - w)q = wp - wq + n_vq,$$

$$E(f'_i) = \frac{1}{n(p - q)}[E(z) - qn_v] = \frac{1}{n(p - q)}(wp - wq + qn_v - qn_v) = \frac{w}{n} = f_i。$$

因此, 度值频率 f'_i 是真实频率 f_i 的无偏估计。

证毕。

定理 5.3. 算法 5.1 中估计的任意度值频率 f'_i 的方差满足

$$\text{Var}(f'_i) = \frac{n_v q(1 - q)}{n^2(p - q)^2},$$

其中 n_v 为度值 i 所处组 v 的用户数量, $p = \frac{e^{\varepsilon/2}}{e^{\varepsilon/2} + 1}$, $q = 1 - p$ 。

证明： 设 $w = nf_i$ 为对应度值 i 的频数, 即度值为 i 的用户数量, 同时

$z = \sum_{c=0}^{n_v} D'_c[j]$, 则有

$$\begin{aligned} \text{Var}(f'_i) &= \text{Var}\left[\frac{z - qn_v}{n(p-q)}\right] = \frac{1}{n^2(p-q)^2} \text{Var}(z) \\ &= \frac{wp(1-p) + (n_v - w)q(1-q)}{n^2(p-q)^2} = \frac{n_v q(1-q)}{n^2(p-q)^2} + \frac{w(1-p-q)}{n^2(p-q)^2} \end{aligned}$$

由于 $w = nf_i$, 则

$$\text{Var}(f'_i) = \frac{n_v q(1-q)}{n^2(p-q)^2} + \frac{f_i(1-p-q)}{n(p-q)}.$$

同时, $p + q = 1$ 。因此, f'_i 的方差为

$$\text{Var}(f'_i) = \frac{n_v q(1-q)}{n^2(p-q)^2}.$$

证毕。

在算法 5.1 中, 每个用户需要先计算自身组号 g_i 以及将度值 d_i 编码为 L 维的二维向量, 并对其二维向量中的每一位进行 RR 扰动, 因此用户的时间复杂度和空间复杂度分别为 $O(2L+1)$ 和 $O(L+1)$ 。对收集者而言, 其需要将每个用户的噪声度向量和组号收集, 计算各组用户数量, 并依次校正各度值的频率分布, 收集者的时间复杂度和空间复杂度均为 $O(n(L+1))$ 。

5.3 三角计数序列发布算法

真实分布式图数据应用场景下, 隐私保护和数据效用需求多样化, 分布式用户无法直接获取分布式图数据的三角计数序列等与图特征密切相关的统计指标, 故此类信息发布过程中的用户隐私保护非常具有挑战性。现有的算法在本地扰动加噪时, 还存在添加大量噪声边导致数据效用不高的问题。本节针对上述问题, 首先提出一种剪枝(Prune)算法, 用于控制噪声边添加的上限, 进而降低实际噪声图中的密集程度; 其次, 针对隐私及效用需求, 基于 Prune 算法和 2 轮交互模型分别提出基于 Node-LDP 的三角计数序列发布算法及基于 Edge-LDP 的三角序列发布算法; 最后, 给出三角计数序列发布算法的分析与证明。

5.3.1 基于 Node-LDP 的三角计数序列发布算法

诸如社交网络、物联网等真实场景中产生的图数据通常是稀疏图，即 $n \gg d_{\max} \gg d_{\text{ave}}$ 。其中， $d_{\max}$ 和 d_{ave} 分别为最大度和平均度。为了应对 LDP 随机加噪过程中产生过多虚假边，降低发布统计指标的效用问题，本节提出 Prune 算法，通过将用户邻接向量缩减成 1 个 θ 维的二元向量，从而减少随机过程中产生的噪声边，具体过程如算法 5.2 所示。

算法 5.2 中，包含 2 个步骤：第一，在用户持有度值上限 θ 后，用户可依据 θ 和邻居真实情况，裁剪自己的邻接向量。以用户 i 为例，若 $d_i > \theta$ ，则用户 i 随机抽取 θ 个邻居组成裁剪后的邻接向量 $\mathbf{B}'_i$ ，每一位均为 1(第 1-2 行)。相反，若 $d_i \leq \theta$ ，则用户将 d_i 个邻居组成裁剪后邻接向量的前 d_i 位，并随机抽取 $\theta - d_i$ 非邻居充当邻接向量的后几位，从而组成 1 个 θ 维的二元向量(第 3-4 行)。其中，真实邻居对应的位为 1，其余为 0。第二，在填充 $\mathbf{B}'_i$ 完毕之后，用户对 $\mathbf{B}'_i$ 进行洗牌，从而避免数据收集者按顺序推导用户的邻居信息(第 5 行)。在此基础之上，用户便可将 1 个 n 维的邻接向量缩减为 θ 维。依据真实图的稀疏性，许多非邻居位将会被移除，从而可一定程度上减少随机化过程产生的噪声边。

算法 5.2 剪枝算法(Prune)

输入：邻接向量 $\mathbf{B}_i = (b_1, b_2, \dots, b_n)$ ， $b_j \in \{0, 1\}$ ，阈值 θ

输出：剪枝后的邻接向量 $\mathbf{B}'_i = (b'_1, b'_2, \dots, b'_\theta)$

1. if $\sum_{j=1}^n b_j > \theta$ do // $\sum_{j=1}^n b_j$ 为用户 i 的度值 d_i

2. $\mathbf{B}'_i = \text{Cut}(\mathbf{B}_i) = (b'_1, b'_2, \dots, b'_\theta)$ // 随机选择 $\mathbf{B}_i$ 中 θ 个邻居，并均填充为 1，
即 $b'_j \in \{1\}$

3. else if $\sum_{j=1}^n b_j \leq \theta$ do

4. $\mathbf{B}'_i = \left(b'_1, b'_2, \dots, b'_{\sum_{j=1}^n b_j}, \dots, b'_\theta \right)$ // $b'_{j \in \left\{ 1, \sum_{j=1}^n b_j \right\}} \in \{1\}$ ，选取 $\sum_{j=1}^n b_j$ 个邻居填充为前

$\sum_{j=1}^n b_j$ 位，计为 1； $b'_{j \in \left\{ \sum_{j=1}^n b_j, \theta \right\}} \in \{0\}$ ，即随机抽取 $\theta - d_i$ 非邻居充当邻接向量的后几

位，计为 0

5. end if

6. $\text{Shuffle}(\mathbf{B}'_i)$ ；// 对 $\mathbf{B}'_i$ 进行洗牌

7. Return $\mathbf{B}'_i$

为了能在强隐私保护下发布三角计数序列，我们在算法 5.2 的基础之上提出基于 Node-LDP 的三角计数序列发布算法，具体如算法 5.3 所示。在所提出的算法中，引入 2 轮交互模型来进一步提升发布结果的数据效用。其中：第 1 轮交互用于获取分布式用户的噪声边信息，从而聚合获得噪声图数据；随后，数据收集者将噪声图数据发送给各分布式用户。第 2 轮交互过程中，各分布式用户利用自身一阶邻居子图的邻居信息和噪声图数据，计算各自的局部三角计数，并通过拉普拉斯机制对三角计数加噪，加噪后的三角计数发送给数据收集者。

算法 5.3 基于 Node-LDP 的三角计数序列发布算法(NLDP-TS)

输入：邻接矩阵 $M = (B_1, B_2, \dots, B_n)$ ， $B_i = (b_1, b_2, \dots, b_n)$ ， $b_j \in \{0, 1\}$ ，频率上限 $Level$ ，隐私预算 $\varepsilon = \varepsilon_1 + \varepsilon_2 + \varepsilon_3$ ，组距 L

输出：具备 Node-LDP 保护的三角计数序列 $T' = (T'_1, T'_2, \dots, T'_n)$

第一轮交互

1. $\theta = NLDP-DD(Level, \varepsilon_1, L)$ //调用算法 5.1 获取度分布估计，并结合 $Level$ 计算度阈值 θ

用户端：

2. for i in $\{1, 2, \dots, n\}$ do

3. $B'_i = Prune(B_i, \theta)$ //调用剪枝算法(算法 5.2)裁剪邻接向量

4. 通过 ε_2/θ -RR 扰动 B'_i 中的每一位

$$\tilde{B}_i[j] = \begin{cases} B'_i[j], & p = \frac{e^{\varepsilon_2/\theta}}{e^{\varepsilon_2/\theta} + 1}; \\ 1 - B'_i[j], & q = \frac{1}{e^{\varepsilon_2/\theta} + 1}; \end{cases}$$

// $B'_i[j]$ 表示 B'_i 中的第 j 位， $\tilde{B}_i[j]$ ($\tilde{B}_i$ 中的第 j 位) 表示扰动后的 $B'_i[j]$ ， $\tilde{B}_i$ 为经过扰动的 B'_i

5. 将 $\tilde{B}_i$ 发送给数据收集者

6. end

数据收集者端：

7. $G' = construct(\tilde{B}_1, \tilde{B}_2, \dots, \tilde{B}_n)$ //构建噪声图

8. 将噪声图 G' 发送给每个用户

第二轮交互

用户端：

9. for i in $\{1, 2, \dots, n\}$ do

10. 计算噪声 2-star 计数

$$t_i \leftarrow \frac{\left[\sum_{j=1}^{\theta} B'_{ij} \left(\sum_{j=1}^{\theta} B'_{ij} - 1 \right) \right]}{2}$$

11. 计算噪声局部三角计数

$$s_i = \left| \left(v_i, v_j, v_k \right) : j < k, a_{i,j} = a_{i,k} = 1, (v_j, v_k) \text{ in } G' \right|$$

12. $w_i \leftarrow s_i - qt_i$

13. $w'_i \leftarrow w_i + \text{Lap} \left(\frac{\theta(\theta-1)}{2\varepsilon_3} \right)$

14. 将 w'_i 发送给数据收集者

15.end

数据收集者端:

16.for i in $\{1, 2, \dots, n\}$ do

17. $T'_i = \frac{w'_i}{2p-1}$ //校正噪声数据, 获取用户 i 的局部三角计数估计

18.end

19. $T' = (T'_1, T'_2, \dots, T'_n)$

20.Return T'

算法 5.3 中, 第 1~8 行为第 1 轮交互, 第 9~19 行为第 2 轮交互, 各分为 4 个步骤。第 1 轮交互中, 首先, 数据收集者将隐私预算 ε 拆分为 $\varepsilon_1, \varepsilon_2, \varepsilon_3$, 并将 $\varepsilon_1, \varepsilon_2, \varepsilon_3$, 组距 L 和频率上限 $Level$ 发布给每位用户。其次, 用户和数据收集者以 ε_1 和 L 为参数, 通过算法 5.1 获取度频率分布估计。数据收集者根据 $Level$ 计算频率和达到 $Level$ 时的最大度值 θ , 将其设为度阈值(第 1 行); 再次, 用户根据 θ 和自身真实邻接向量 $\mathbf{B}_i$, 调用算法 2 对邻接向量 $\mathbf{B}_i$ 进行裁剪, 并通过 ε_2/θ -RR 扰动裁剪后的邻接向量中的每一位, 然后将加噪后的邻接向量 $\tilde{\mathbf{B}}_i$ 发送给数据收集者(第 3~5 行); 最后, 数据收集者根据采集到的噪声邻接向量 $\tilde{\mathbf{B}}_i$ 构建噪声图数据 G' , 并将其发送给用户(第 7-8 行)。值得注意的是, θ 无需用户或数据收集者自行设置, 其由 $Level$ 和度分布估计计算而得, 与 $Level$ 成正比, 即 $Level$ 越大, θ 越大。

第 2 轮交互中, 首先, 各分布式用户结合噪声图数据 G' 和自身裁剪后的邻接向量 $\mathbf{B}'_i$ 计算其局部三角计数。以用户 i 为例, 用户 i 根据裁剪后的 $\mathbf{B}'_i$ 计算其真实 2-star 计数(第 10 行)。其中, 用户 i 的 2-star 可表示为, 以其自身为中心节点, 连接 2 条边的子图。因此, 用户 i 的 2-star 计数可表示为

$$t_i \leftarrow \frac{\left[\sum_{j=1}^{\theta} B'_{ij} \left(\sum_{j=1}^{\theta} B'_{ij} - 1 \right) \right]}{2}。$$

同时,用户*i*可通过 $\mathbf{B}'_i$ 上的真实边缘信息和 G' 中的噪声边信息计算他的噪声局部三角计数(算法 3 第 11 行), 即

$$s_i = \left| (v_i, v_j, v_k) : j < k, a_{i,j} = a_{i,k} = 1, (v_j, v_k) \text{ in } G' \right|,$$

其中 $a_{i,j}$ 表示用户*i*本地端的边缘(*i, j*)是否存在, 若存在记为 1, 否则记为 0。其次, 用户*i*将 $s_i - qt_i$ 发送给数据收集者。由数据收集者根据用户发送 t_i 和 s_i 结合 RR 校正公式估计其三角计数, 即

$$T'_i = \frac{s_i - qt_i}{2p-1}。$$

为了避免直接发送 $s_i - qt_i$ 引发的边缘信息泄露问题, 用户向该值添加拉普拉斯噪声, 使算法满足 Node-LDP。同时, 为了降低满足 Node-LDP 时添加的噪声量, 算法不采用 $d_{\max}(d_{\max}-1)/2$ 为作为敏感度。用户*i*向 $s_i - qt_i$ 添加敏感度为 $\theta(\theta-1)/2$ 的拉普拉斯噪声, 使算法满足 Node-LDP(第 12-13 行)。再次, 数据收集者估计该用户的三角计数(第 17 行), 即

$$T'_i = \frac{s_i - qt_i + \text{Lap}\left(\frac{\theta(\theta-1)}{2\varepsilon_3}\right)}{2p-1}。$$

最后, 数据收集者根据获取的所有分布式用户的局部三角计数, 聚合发布满足 Node-LDP 的三角计数序列 $T' = (T'_1, T'_2, \dots, T'_n)$ (第 19 行)。

5.3.2 基于 Edge-LDP 的三角计数序列发布算法

为了满足各类场景下不同隐私保护和数据效用需求, 进一步提升数据效用并放松隐私保护强度, 本节在算法 5.2 的基础上提出基于 Edge-LDP 的三角计数序列发布算法, 如算法 5.4 所示。

算法 5.4 包含 2 轮交互, 第 1-8 行为第 1 轮交互, 第 9-19 行为第 2 轮交互, 各分为 4 个步骤。第 1 轮交互中, 首先, 数据收集者将隐私预算 ε 拆分为 $\varepsilon_1, \varepsilon_2, \varepsilon_3$, 并将 $\varepsilon_1, \varepsilon_2, \varepsilon_3$, 组距 L 和频率上限 $Level$ 发布给每位用户。其次, 用户和数据收集者以 ε_1 和 L 为参数, 通过算法 5.1 获取度频率分布估计。数据收集者根据 $Level$ 计算频率和达到 $Level$ 时的最大度值 θ , 将其设为度阈值(第 1 行); 再次, 用户通过 θ 将其邻接向量 $\mathbf{B}_i$ 进行剪枝, 获取到剪枝后的邻接向量 $\mathbf{B}'_i$, 并通过 ε_2 -RR 扰动 $\mathbf{B}'_i$ 中的每一位并将其发送给数据收集者(第 3-4 行); 最后, 数据收集者通过所有用户的噪声向量 $\tilde{\mathbf{B}}_i$ 聚合获得噪声图数据 G' , 并将 G' 发给所有分布式

用户(第 7-8 行)。值得注意的是, 由于 Edge-LDP 和 Node-LDP 下的隐私约束有所不同, 因此在满足 Edge-LDP 时, 算法 5.4 中用户在第 1 轮交互中仅需使用 ε_2 -RR(第 4 行)即可。

第 2 轮交互中, 首先, 所有分布式用户各自依据 G' 和 B'_i 计算其真实 2-star 计数 t_i 和噪声三角计数 s_i (第 10-11 行)。其次, 用户通过拉普拉斯机制将 $s_i - qt_i$ 加噪扰动后报告给数据收集者。此处与算法 5.3 不同的是, 用户仅需向 $s_i - qt_i$ 中添加 $Lap(\theta/\varepsilon_3)$ 的噪声即可满足 Edge-LDP。即用户分别向数据收集者报告 $s_i - qt_i + Lap(\theta/\varepsilon_3)$ (第 12-13 行)。再次, 数据收集者根据用户发送的数据, 结合 RR 校正公式估计其局部三角计数(第 17 行), 即

$$T'_i = \frac{s_i - qt_i + Lap(\theta/\varepsilon_3)}{2p-1}。$$

最后, 数据收集者可获得每个用户的局部三角计数估计 T'_i , 进一步发布满足 Edge-LDP 的三角计数序列估计 $T' = (T'_1, T'_2, \dots, T'_n)$ (第 19 行)。与前述同理, 在满足 Edge-LDP 时, 算法 5.4 中用户在第 2 轮交互的报告过程中(第 13 行)所使用的参数与算法 5.3 不同。(与算法 5.3 的不同之处, 在算法 5.4 中用灰色底色显示。)

算法 5.4 基于 Edge-LDP 的三角计数序列发布算法(ELDP-TS)

输入: 邻接矩阵 $M = (B_1, B_2, \dots, B_n)$, $B_i = (b_1, b_2, \dots, b_n)$, $b_j \in \{0,1\}$, 频率上限 $Level$, 隐私预算 $\varepsilon = \varepsilon_1 + \varepsilon_2 + \varepsilon_3$, 组距 L

输出: 具备 Edge-LDP 保护的三角计数序列 $T' = (T'_1, T'_2, \dots, T'_n)$

第一轮交互

1. $\theta = NLDP-DD(Level, \varepsilon_1, L)$

用户端:

2. for i in $\{1, 2, \dots, n\}$ do

3. $B'_i = Prune(B_i, \theta)$

4. 通过 ε_2 -RR 扰动 B'_i 中的每一位

$$\tilde{B}_i[j] = \begin{cases} B'_i[j], & p = \frac{e^{\varepsilon_2}}{e^{\varepsilon_2} + 1}; \\ 1 - B'_i[j], & q = \frac{1}{e^{\varepsilon_2} + 1}; \end{cases}$$

5. 将 $\tilde{B}_i$ 发送给数据收集者

6. end

数据收集者端:

7. $G' = construct(\tilde{B}_1, \tilde{B}_2, \dots, \tilde{B}_n)$

8. 将噪声图 G' 发送给每个用户

第二轮交互

用户端:

9. for i in $\{1, 2, \dots, n\}$ do

10. 计算噪声 2-star 计数

$$t_i \leftarrow \frac{\left[\sum_{j=1}^{\theta} B'_{ij} \left(\sum_{j=1}^{\theta} B'_{ij} - 1 \right) \right]}{2}$$

11. 计算噪声局部三角计数

$$s_i = \left| (v_i, v_j, v_k) : j < k, a_{i,j} = a_{i,k} = 1, (v_j, v_k) \text{ in } G' \right|$$

12. $w_i \leftarrow s_i - qt_i$

13. $w'_i \leftarrow w_i + \text{Lap}(\theta/\varepsilon_3)$

14. 将 w'_i 发送给数据收集者

15. end

数据收集者端:

16. for i in $\{1, 2, \dots, n\}$ do

$$17. T'_i = \frac{w'_i}{2p-1}$$

18. end

$$19. T' = (T'_1, T'_2, \dots, T'_n)$$

20. Return T'

5.3.3 三角计数序列发布算法隐私效用分析

本节对所提基于 Node-LDP 和基于 Edge-LDP 的三角计数序列发布算法(算法 5.3 和算法 5.4)所具备的隐私保证、结果无偏性及估计结果方差进行理论分析。

定理 5.4. 算法 5.3 满足 ε -Node-LDP。

证明: 算法 5.3 中, 存在 3 个过程提供隐私保障, 即通过算法 5.1 获取度值上限 θ (第 1 行), 通过 RR 扰动邻接向量(第 4 行)以及向估计值中添加拉普拉斯噪声(第 13 行)。

首先, 依据定理 5.1 可知, 通过算法 5.1 获取度值上限 θ 满足 ε_1 -Node-LDP。

其次, 在通过 RR 扰动位向量过程中, 易知剪枝后的邻接向量 $\mathbf{B}'_i$ 是 θ 维的。

不失一般性, 我们假设任意 2 个 $\mathbf{B}'_i$ 和 $\mathbf{B}'_j$ 为任意位都不一致的相邻位向量, 则通过 ε_2/θ -RR 扰动时, 有

$$\frac{\Pr[\mathcal{A}(\mathbf{B}'_i) = \mathbf{S}]}{\Pr[\mathcal{A}(\mathbf{B}'_j) = \mathbf{S}]} = \frac{\Pr[\mathcal{A}(b_1) = s_1] \Pr[\mathcal{A}(b_2) = s_2] \dots \Pr[\mathcal{A}(b_\theta) = s_\theta]}{\Pr[\mathcal{A}(b'_1) = s_1] \Pr[\mathcal{A}(b'_2) = s_2] \dots \Pr[\mathcal{A}(b'_\theta) = s_\theta]} < \frac{p^\theta}{q^\theta} = e^{\frac{\theta \varepsilon_2}{\theta}} = e^{\varepsilon_2},$$

其中 $p = \frac{e^{\varepsilon_2/\theta}}{e^{\varepsilon_2/\theta} + 1}$, $q = 1 - p$, $\mathbf{S}$ 为 ε_2/θ -RR 的任意输出值。因此, 该过程满足 ε_2 -Node-LDP。

再次, 在 Node-LDP 约束下, 删除任意顶点对三角计数的敏感度为 $\theta(\theta-1)/2$, 因此, 在报告三角计数过程中添加 $Lap\left(\frac{\theta(\theta-1)}{2\varepsilon_3}\right)$ 满足 ε_3 -Node-LDP。

根据引理 2.1, 算法 5.3 提供 $\varepsilon_1 + \varepsilon_2 + \varepsilon_3$ -Node-LDP。其中, $\varepsilon_1 + \varepsilon_2 + \varepsilon_3 = \varepsilon$, 因此算法 3 满足 ε -Node-LDP。 **证毕。**

定理 5.5. 算法 5.3 收集的任意用户局部三角计数 T'_i 都是真实计数 T_i 的无偏估计。

证明:

$$E(T'_i) = E\left(\frac{w'_i}{2p-1}\right) = E\left[\frac{s_i - qt_i + Lap\left(\frac{\theta(\theta-1)}{2\varepsilon_3}\right)}{2p-1}\right] = \frac{1}{2p-1} E(s_i - qt_i)。$$

设 t_i^* 为用户 i 的 2-star 中不包括三角形的计数, 即 $a_{i,j} = a_{i,k} = 1$, 且 $a_{k,j} = 0 (j < k)$ 。 T_i 为用户 i 的真实局部三角计数, 即 $a_{i,j} = a_{i,k} = a_{k,j} = 1 (j < k)$ 。 s_i 为用户结合 G' 和 $\mathbf{B}'_i$ 计数的噪声三角计数, 即

$$s_i = \left| (v_i, v_j, v_k) : j < k, a_{i,j} = a_{i,k} = 1, (v_j, v_k) \text{ in } G' \right|。$$

同时, 设 t_i 为用户 i 的真实 2-star 计数, 则有 $t_i = t_i^* + T_i$ 。根据 RR 的性质, 有

$$E(s_i) = T_i p + t_i^* q,$$

则

$$\begin{aligned} E(T'_i) &= \frac{1}{2p-1} E(s_i - qt_i) = \frac{1}{2p-1} [T_i p + t_i^* q - qt_i] \\ &= \frac{1}{2p-1} [T_i p + t_i^* q - q(T_i + t_i^*)] = \frac{(p-q)T_i}{2p-1} = T_i。 \end{aligned}$$

因此, T'_i 是真实计数 T_i 的无偏估计。 **证毕。**

定理 5.6. 算法 5.3 收集的任意用户局部三角计数 T'_i 的方差满足

$$\text{Var}(T'_i) \leq [\theta(\theta-1)] \frac{\varepsilon_3^2 pq + \theta(\theta-1)}{2(2p-1)^2 \varepsilon_3^2},$$

其中 $p = \frac{e^{\varepsilon_2/\theta}}{e^{\varepsilon_2/\theta} + 1}$, $q = \frac{1}{e^{\varepsilon_2/\theta} + 1}$ 。

证明：设 t_i 为用户 i 的 2-star 计数， t_i^* 为用户 i 的 2-star 中不包括三角形的计数，即 $a_{i,j} = a_{i,k} = 1$ ，且 $a_{k,j} = 0 (j < k)$ 。 T_i 为用户 i 的局部三角计数，即 $a_{i,j} = a_{i,k} = a_{k,j} = 1 (j < k)$ 。有

$$\begin{aligned}
 \text{Var}(T_i) &= \text{Var}\left(\frac{w'_i}{2p-1}\right) = \text{Var}\left[\frac{s_i - qt_i + \text{Lap}\left(\frac{\theta(\theta-1)}{2\varepsilon_3}\right)}{2p-1}\right] \\
 &= \frac{1}{(2p-1)^2} \text{Var}\left[s_i - qt_i + \text{Lap}\left(\frac{\theta(\theta-1)}{2\varepsilon_3}\right)\right] \\
 &= \frac{1}{(2p-1)^2} \left\{ \text{Var}(s_i) + \text{Var}\left[\text{Lap}\left(\frac{\theta(\theta-1)}{2\varepsilon_3}\right)\right] \right\} \\
 &= \frac{[T_i p(1-p) + t_i^* q(1-q)]}{(2p-1)^2} + \frac{\theta^2(\theta-1)^2}{2(2p-1)^2 \varepsilon_3^2} \\
 &= \frac{(T_i + t_i^*)pq}{(2p-1)^2} + \frac{\theta^2(\theta-1)^2}{2(2p-1)^2 \varepsilon_3^2} = \frac{t_i pq}{(2p-1)^2} + \frac{\theta^2(\theta-1)^2}{2(2p-1)^2 \varepsilon_3^2} \\
 &\leq \frac{\theta(\theta-1)pq}{2(2p-1)^2} + \frac{\theta^2(\theta-1)^2}{2(2p-1)^2 \varepsilon_3^2} = [\theta(\theta-1)] \frac{\varepsilon_3^2 pq + \theta(\theta-1)}{2(2p-1)^2 \varepsilon_3^2}.
 \end{aligned}$$

证毕。

定理 5.7. 算法 5.4 满足 ε_1 -Node-LDP + $\varepsilon_2 + \varepsilon_3$ -Edge-LDP。

证明：与算法 5.3 一致，算法 5.4 也存在 3 个过程提供隐私保障，即通过算法 5.1 获取度值上限 θ (第 1 行)，通过 RR 扰动位向量 (第 4 行) 以及通过向估计值中添加拉普拉斯噪声 (第 13 行)。

首先，依据定理 5.1 可知，通过算法 5.1 获取度值上限 θ 满足 ε_1 -Node-LDP。

其次，在通过 RR 扰动位向量过程中，易知剪枝后的位向量 $\mathbf{B}'_i$ 是 θ 维的。不失一般性，我们假设任意 2 个 $\mathbf{B}'_i$ 和 $\mathbf{B}'_j$ 为仅第 1 位不一致的相邻位向量，则通过 ε_2 -RR 扰动时，有

$$\begin{aligned}
 &\frac{\Pr[\mathcal{A}(\mathbf{B}'_i) = \mathbf{S}]}{\Pr[\mathcal{A}(\mathbf{B}'_j) = \mathbf{S}]} = \\
 &\frac{\Pr[\mathcal{A}(b_1) = s_1] \Pr[\mathcal{A}(b_2) = s_2] \dots \Pr[\mathcal{A}(b_\theta) = s_\theta]}{\Pr[\mathcal{A}(b'_1) = s_1] \Pr[\mathcal{A}(b'_2) = s_2] \dots \Pr[\mathcal{A}(b'_\theta) = s_\theta]} = \frac{\Pr[\mathcal{A}(b_1) = s_1]}{\Pr[\mathcal{A}(b'_1) = s_1]} < \frac{p}{q} = e^{\varepsilon_2},
 \end{aligned}$$

其中 $p = \frac{e^{\varepsilon_2}}{e^{\varepsilon_2} + 1}$, $q = 1 - p$, $\mathbf{S}$ 为 ε_2 -RR 的任意输出值。因此，该过程满足

ε_2 -Edge-LDP。

再次，在 Edge-LDP 约束下，删除任意顶点对三角计数的影响为 θ ，即敏感度为 θ ，因此，在报告三角计数过程中添加 $Lap(\theta/\varepsilon_3)$ 满足 ε_3 -Edge-LDP。

综上，根据引理 3.1，算法 5.4 满足 ε_1 -Node-LDP + $\varepsilon_2 + \varepsilon_3$ -Edge-LDP。
证毕。

定理 5.8。 算法 5.4 收集的任意用户局部三角计数 T'_i 都是真实计数 T_i 的无偏估计。

证明：

$$E(T'_i) = E\left(\frac{w'_i}{2p-1}\right) = E\left[\frac{s_i - qt_i + Lap\left(\frac{\theta}{\varepsilon_3}\right)}{2p-1}\right] = \frac{1}{2p-1}E(s_i - qt_i)。$$

与定理 5.5 同理， $E(s_i - qt_i) = (p - q)T_i$ ，因此

$$E(T'_i) = \frac{1}{2p-1}E(s_i - qt_i) = \frac{(p-q)T_i}{2p-1} = T_i。$$

综上， T'_i 都是真实计数 T_i 的无偏估计。

证毕。

定理 5.9。 算法 5.4 收集的任意用户局部三角计数 T'_i 的方差满足

$$Var(T'_i) \leq \frac{\varepsilon_3^2 pq [\theta(\theta-1)] + 4\theta^2}{2(2p-1)^2 \varepsilon_3^2}，$$

其中 $p = \frac{e^{\varepsilon_2}}{e^{\varepsilon_2} + 1}$ ， $q = \frac{1}{e^{\varepsilon_2} + 1}$ 。

证明： 设 t_i 和 t_i^* 分别为用户 i 的 2-star 计数和 2-star 中不包括三角形的计数， T_i 为用户 i 的局部三角计数，有

$$\begin{aligned} Var(T'_i) &= Var\left(\frac{w'_i}{2p-1}\right) = Var\left[\frac{s_i - qt_i + Lap\left(\frac{\theta}{\varepsilon_3}\right)}{2p-1}\right] \\ &= \frac{1}{(2p-1)^2} Var\left[s_i - qt_i + Lap\left(\frac{\theta}{\varepsilon_3}\right)\right] \\ &= \frac{1}{(2p-1)^2} \left\{ Var(s_i) + Var\left[Lap\left(\frac{\theta}{\varepsilon_3}\right)\right] \right\} \\ &= \frac{[T_i p(1-p) + t_i^* q(1-q)]}{(2p-1)^2} + \frac{2\theta^2}{(2p-1)^2 \varepsilon_3^2} \end{aligned}$$

$$\begin{aligned}
&= \frac{(T_i + t_i^*)pq}{(2p-1)^2} + \frac{2\theta^2}{(2p-1)^2 \varepsilon_3^2} = \frac{t_i pq}{(2p-1)^2} + \frac{2\theta^2}{(2p-1)^2 \varepsilon_3^2} \\
&\leq \frac{\theta(\theta-1)pq}{2(2p-1)^2} + \frac{2\theta^2}{(2p-1)^2 \varepsilon_3^2} = \frac{\varepsilon_3^2 \theta(\theta-1)pq + 4\theta^2}{2(2p-1)^2 \varepsilon_3^2}.
\end{aligned}$$

证毕。

在算法 5.3 和算法 5.4 中, 首先需要调用算法 5.1, 因此该过程中用户的时间复杂度和空间复杂度分别为 $O(2L+1)$ 和 $O(L+1)$, 数据收集者的时间复杂度和空间复杂度均为 $O(n(L+1))$ 。其次, 用户需先对邻接向量进行剪枝并扰动剪枝后的位向量, 该过程时间复杂度和空间复杂度均为 $O(2\theta)$, 数据收集者采集所有用户的噪声位向量并聚合噪声图, 时间复杂度和空间复杂度均为 $O(n\theta)$ 。再次, 用户需结合噪声图计算三角计数并加噪, 时间复杂度和空间复杂度分别为 $O\left(\frac{d_i(d_i-1)}{2}+1\right)$ 和 $O(n\theta)$ 。最后, 数据收集者聚合各用户的三角计数, 时间复杂度和空间复杂度均为 $O(n)$ 。

综上, 算法 5.3 和算法 5.4 用户所需的时间复杂度和空间复杂度分别为 $O\left(2L+2\theta+\frac{d_i(d_i-1)}{2}+2\right)$ 和 $O(L+1+(n+2)\theta)$, 数据收集者所需的时间复杂度和空间复杂度均为 $O(n(L+2+\theta))$ 。

5.4 聚类系数发布算法

本节在 5.3 节所提算法的基础之上, 进一步引入拉普拉斯机制报告分布式用户的度值, 设计满足 Node-LDP 和 Edge-LDP 的聚类系数发布算法。

5.4.1 基于 Node-LDP 的聚类系数发布算法

算法 5.5 为所提的基于 Node-LDP 的聚类系数发布算法, 具体分为 4 个步骤。首先, 数据收集者将隐私预算 ε 拆分为 $\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4$, 并将 $\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4$, 组距 L 和频率上限 $Level$ 发布给每位用户。其次, 用户和数据收集者以 $\varepsilon_1, \varepsilon_2, \varepsilon_3, L, Level$ 为参数调用算法 5.3 获取度阈值 θ 以及三角计数序列 $T' = (T'_1, T'_2, \dots, T'_n)$ (第 1 行)。再次, 每个用户通过 ε_4 -拉普拉斯机制向数据收集者

报告其度值 d_i 。值得注意的是，在满足 Node-LDP 时，度值的敏感度为 d_{max} 。显然，向常规图数据度值中添加 d_{max} 的拉普拉斯噪声将使得噪声量过大。因此我们仍然采用算法 5.3 中取得的阈值 θ 作为度上限，通过投影方式报告度值。具体而言，以用户 i 为例，当度值 d_i 大于 θ 时，用户 i 报告 $\theta + Lap(\theta/\varepsilon_4)$ ，否则直接向真实度值上添加 $Lap(\theta/\varepsilon_4)$ 的噪声并报告(第 3-7 行)。最后，数据收集者便可获取每个用户的局部三角计数估计 T'_i 和度值估计 d'_i ，其可依据 T'_i 和 d'_i 计算每个用户的局部聚类系数估计 CC'_i (第 12 行)，即

$$CC'_i = \frac{2T'_i}{d'_i(d'_i - 1)},$$

并最终聚合发布满足 Node-LDP 保护的聚类系数估计 $CC' = (CC'_1, CC'_2, \dots, CC'_n)$ (第 14 行)。

算法 5.5 基于 Node-LDP 的聚类系数发布算法(NLDP-CC)

输入：邻接矩阵 $\mathbf{M} = (\mathbf{B}_1, \mathbf{B}_2, \dots, \mathbf{B}_n)$ ， $\mathbf{B}_i = (b_{i1}, b_{i2}, \dots, b_{in})$ ， $b_j \in \{0, 1\}$ ，频率上限 $Level$ ，隐私预算 $\varepsilon = \varepsilon_1 + \varepsilon_2 + \varepsilon_3 + \varepsilon_4$

输出：具备 Node-LDP 保护的聚类系数 $CC' = (CC'_1, CC'_2, \dots, CC'_n)$

1. $T', \theta = NLDP-TS(\mathbf{M}, \varepsilon_1 + \varepsilon_2 + \varepsilon_3, Level)$ //调用算法 5.3 获取满足 Node-LDP 的三角计数序列 T' 及度阈值 θ

 用户端：

```

2. for  $i$  in  $\{1, 2, \dots, n\}$  do
  //对度值进行投影
3.   if  $d_i > \theta$  do //度值大于阈值  $\theta$ 
4.      $d'_i = \theta + Lap(\theta/\varepsilon_4)$ 
5.   else if  $d_i \leq \theta$  //度值小于或等于阈值  $\theta$ 
6.      $d'_i = d_i + Lap(\theta/\varepsilon_4)$ 
7.   end if
8.   将噪声度值  $d'_i$  发送给数据收集者
9. end
```

10. $\tilde{D} = \{d'_1, d'_2, \dots, d'_n\}$

 数据收集者端：

```

11. for  $i$  in  $\{1, 2, \dots, n\}$  do
12.    $CC'_i = \frac{2T'_i}{d'_i(d'_i - 1)}$ 
13. end
14.  $CC' = (CC'_1, CC'_2, \dots, CC'_n)$ 
```

5.4.2 基于 Edge-LDP 的聚类系数发布算法

本节在算法 5.4 和算法 5.5 的基础之上, 提出基于 Edge-LDP 的聚类系数发布算法, 如算法 5.6 所示。

类似地, 算法 5.6 也可分为 4 个步骤。首先, 数据收集者将隐私预算 ε 拆分为 $\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4$, 并将 $\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4$, 组距 L 和频率上限 $Level$ 发布给每位用户。其次, 用户和数据收集者以 $\varepsilon_1, \varepsilon_2, \varepsilon_3, L, Level$ 为参数调用算法 5.4, 获取满足 Edge-LDP 的三角计数序列 $T' = (T'_1, T'_2, \dots, T'_n)$ (第 1 行)。再次, 用户通过 ε_4 -拉普拉斯机制报告其度值 d_i (第 3-4 行)。与算法 5.5 所不同, 在满足 Edge-LDP 时, 删除任意 1 条边敏感度仅为 1, 敏感度相对较小, 因此算法 5.6 无需删边投影。用户在报告度值前仅需向度值中添加敏感度为 1 的拉普拉斯噪声, 即 $Lap(1/\varepsilon_4)$ 。最后, 数据收集者利用每个用户的局部三角计数估计 T'_i 和度值估计 d'_i 计算其局部聚类系数估计 CC'_i (第 7-9 行), 并聚合发布满足 Edge-LDP 的全局聚类系数 $CC' = (CC'_1, CC'_2, \dots, CC'_n)$ (第 10 行)。

与算法 5.5 不同的是, 在发布满足 Edge-LDP 的聚类系数时, 首先需调用算法 5.4 发布满足 Edge-LDP 的三角计数序列 (第 1 行); 其次, 在 Edge-LDP 约束下报告度值的敏感度仅为 1, 因此无需通过投影限制报度值告过程中的敏感度。进而, 在算法 5.6 的度值报告过程中 (第 3 行) 仅需添加 $Lap(1/\varepsilon_4)$ 即可。(与算法 5.5 的不同之处, 在算法 5.6 中用灰色底色显示。)

算法 5.6 基于 Edge-LDP 的聚类系数发布算法(ELDP-CC)

输入: 邻接矩阵 $M = (B_1, B_2, \dots, B_n)$, $B_i = (b_1, b_2, \dots, b_n)$, $b_j \in \{0, 1\}$, 频率上限 $Level$, 隐私预算 $\varepsilon = \varepsilon_1 + \varepsilon_2 + \varepsilon_3 + \varepsilon_4$

输出: 具备 Edge-LDP 保护的聚类系数 $CC' = (CC'_1, CC'_2, \dots, CC'_n)$

1. $T' = ELDP-TS(M, \varepsilon_1 + \varepsilon_2 + \varepsilon_3, Level)$ //调用算法 5.4 获取满足 Edge-LDP 的三角计数序列 T'

用户端:

2. for i in $\{1, 2, \dots, n\}$ do

3. $d'_i = d_i + Lap(1/\varepsilon_4)$

4. 将噪声度值 d'_i 发送给数据收集者

5. end

6. $\tilde{D} = \{d'_1, d'_2, \dots, d'_n\}$

数据收集者端:

7. for i in $\{1, 2, \dots, n\}$ do

8. $CC'_i = \frac{2T'_i}{d'_i(d'_i-1)}$

9.end

10. $CC' = (CC'_1, CC'_2, \dots, CC'_n)$

11.Return CC'

5.4.3 聚类系数发布算法隐私效用分析

本节对基于 Node-LDP 和基于 Edge-LDP 的聚类系数发布算法(算法 5.5 和算法 5.6)具备的隐私保证、结果无偏向及估计结果方差进行理论分析。

定理 5.10. 算法 5.5 满足 ε -Node-LDP。

证明: 算法 5.5 中, 需调用算法 5.3 获取用户三角计数序列估计(第 1 行), 并由用户通过拉普拉斯机制报告自身度值(第 3~7 行)。

首先, 根据定理 5.4 可知, 算法 5.3 满足 $\varepsilon_1 + \varepsilon_2 + \varepsilon_3$ -Node-LDP。

其次, 在 Node-LDP 约束下, 删除任意顶点敏感度为 θ , 因此在报告度值时添加 $Lap(\theta/\varepsilon_4)$ 的噪声满足 ε_4 -Node-LDP。

综上所述, 依据引理 2.1 可知, 算法 5.5 满足 $\varepsilon_1 + \varepsilon_2 + \varepsilon_3 + \varepsilon_4$ -Node-LDP($\varepsilon_1 + \varepsilon_2 + \varepsilon_3 + \varepsilon_4 = \varepsilon$), 因此算法 5.5 满足 ε -Node-LDP。证毕。

定理 5.11. 算法 5.5 收集的任意用户局部聚类系数 CC'_i 都是真实局部聚类系数 CC_i 的无偏估计。

证明:

$$E(CC'_i) = E\left[\frac{2T'_i}{d'_i(d'_i-1)}\right] = \frac{2}{d_i(d_i-1)} E(T'_i)。$$

依据定理 5.5 可知, $E(T'_i) = T_i$, 因此有

$$E(CC'_i) = \frac{2}{d_i(d_i-1)} E(T'_i) = \frac{2T_i}{d_i(d_i-1)} = CC_i。$$

因此, 任意用户局部聚类系数 CC'_i 都是真实局部聚类系数 CC_i 的无偏估计。证毕。

定理 5.12. 算法 5.5 收集的任意用户局部聚类系数 CC'_i 的方差满足

$$Var(CC'_i) \leq 4[\theta(\theta-1)] \frac{[\varepsilon_3^2 pq + \theta(\theta-1)] [\theta^2 (10d_i^2 - 10d_i + 3)]}{(2p-1)^2 \varepsilon_3^2 d_i^4 (d_i-1)^4 \varepsilon_4^2},$$

其中 $p = \frac{e^{\varepsilon_2/\theta}}{e^{\varepsilon_2/\theta} + 1}$, $q = 1 - p$ 。

证明:

$$\text{Var}(CC'_i) = \text{Var}\left[\frac{2T'_i}{d'_i(d'_i-1)}\right] = 4\text{Var}(T')\text{Var}\left[\frac{1}{d'_i(d'_i-1)}\right].$$

依据定理 5.6 可知

$$\text{Var}(T'_i) \leq [\theta(\theta-1)] \frac{\varepsilon_3^2 pq + \theta(\theta-1)}{2(2p-1)^2 \varepsilon_3^2}.$$

同时,

$$\text{Var}\left[\frac{1}{d'_i(d'_i-1)}\right] = E\left[\frac{1}{d'_i(d'_i-1)}\right]^2 - \left\{E\left[\frac{1}{d'_i(d'_i-1)}\right]\right\}^2.$$

根据文献[25]可知

$$E\left[\frac{1}{d'_i(d'_i-1)}\right]^2 \approx \frac{1}{d_i^2(d_i-1)^2} + \frac{2\theta^2(10d_i^2-10d_i+3)}{d_i^4(d_i-1)^4 \varepsilon_4^2}.$$

进一步地,

$$\left\{E\left[\frac{1}{d'_i(d'_i-1)}\right]\right\}^2 = \frac{1}{d_i^2(d_i-1)^2}.$$

因此, 有

$$\begin{aligned} \text{Var}\left[\frac{1}{d'_i(d'_i-1)}\right] &\approx \\ \frac{1}{d_i^2(d_i-1)^2} + \frac{2\theta^2(10d_i^2-10d_i+3)}{d_i^4(d_i-1)^4 \varepsilon_4^2} - \frac{1}{d_i^2(d_i-1)^2} &= \frac{2\theta^2(10d_i^2-10d_i+3)}{d_i^4(d_i-1)^4 \varepsilon_4^2}. \end{aligned}$$

综上,

$$\begin{aligned} \text{Var}(CC'_i) &\leq 4[\theta(\theta-1)] \frac{\varepsilon_3^2 pq + \theta(\theta-1)}{2(2p-1)^2 \varepsilon_3^2} \frac{2\theta^2(10d_i^2-10d_i+3)}{d_i^4(d_i-1)^4 \varepsilon_4^2} \\ &= 4[\theta(\theta-1)] \frac{[\varepsilon_3^2 pq + \theta(\theta-1)][\theta^2(10d_i^2-10d_i+3)]}{(2p-1)^2 \varepsilon_3^2 d_i^4(d_i-1)^4 \varepsilon_4^2}. \end{aligned}$$

证毕。

定理 5.13. 算法 5.6 满足 ε_1 -Node-LDP + $\varepsilon_2 + \varepsilon_3 + \varepsilon_4$ -Edge-LDP。

证明: 算法 5.6 中, 需调用算法 5.4 获取用户三角计数序列估计(第 1 行), 并由用户通过拉普拉斯机制报告自身度值(第 3 行)。

首先, 根据定理 5.7 可知, 算法 5.4 满足 ε_1 -Node-LDP + $\varepsilon_2 + \varepsilon_3$ -Edge-LDP。

其次, 在 Edge-LDP 约束下, 删除任意顶点敏感度为 1, 因此在报告度值时添加 $Lap(1/\varepsilon_4)$ 满足 ε_4 -Edge-LDP。

综上,依据引理 2.1 可知,算法 5.6 满足 ε_1 -Node-LDP + $\varepsilon_2 + \varepsilon_3 + \varepsilon_4$ -Edge-LDP。

证毕。

定理 5.14. 算法 5.6 收集的任意用户局部聚类系数 CC'_i 都是真实局部聚类系数 CC_i 的无偏估计。

证明:

$$E(CC'_i) = E\left[\frac{2T'_i}{d'_i(d'_i-1)}\right] = \frac{2}{d_i(d_i-1)} E(T'_i)。$$

依据定理 5.8 可知, $E(T'_i) = T_i$, 因此有

$$E(CC'_i) = \frac{2}{d_i(d_i-1)} E(T'_i) = \frac{2T_i}{d_i(d_i-1)} = CC_i。$$

因此,任意用户局部聚类系数 CC'_i 都是真实局部聚类系数 CC_i 的无偏估计。

证毕。

定理 5.15. 算法 5.6 收集的任意用户局部聚类系数 CC'_i 方差满足

$$\text{Var}(CC'_i) \leq \frac{4[\varepsilon_3^2 \theta(\theta-1)pq + 4\theta^2](10d_i^2 - 10d_i + 3)}{(2p-1)^2 \varepsilon_3^2 d_i^4 (d_i-1)^4 \varepsilon_4^2},$$

其中 $p = \frac{e^{\varepsilon_2}}{e^{\varepsilon_2} + 1}$, $q = 1 - p$ 。

证明:

$$\text{Var}(CC'_i) = \text{Var}\left[\frac{2T'_i}{d'_i(d'_i-1)}\right] = 4\text{Var}(T'_i)\text{Var}\left[\frac{1}{d'_i(d'_i-1)}\right]。$$

依据定理 2.9 可知

$$\text{Var}(T'_i) \leq \frac{\varepsilon_3^2 pq[\theta(\theta-1)] + 4\theta^2}{2(2p-1)^2 \varepsilon_3^2}。$$

同时,依据文献[25],

$$\begin{aligned} & \text{Var}\left[\frac{1}{d'_i(d'_i-1)}\right] \\ & \approx \frac{1}{d_i^2(d_i-1)^2} + \frac{2(10d_i^2 - 10d_i + 3)}{d_i^4(d_i-1)^4 \varepsilon_4^2} - \frac{1}{d_i^2(d_i-1)^2} = \frac{2(10d_i^2 - 10d_i + 3)}{d_i^4(d_i-1)^4 \varepsilon_4^2}。 \end{aligned}$$

综上,

$$\begin{aligned}
\text{Var}(CC'_i) &= 4\text{Var}(T')\text{Var}\left[\frac{1}{d'_i(d'_i-1)}\right] \\
&\leq 4\frac{\varepsilon_3^2 pq[\theta(\theta-1)]+4\theta^2}{2(2p-1)^2 \varepsilon_3^2} \frac{2(10d_i^2-10d_i+3)}{d_i^4(d_i-1)^4 \varepsilon_4^2} \\
&= \frac{4[\varepsilon_3^2 \theta(\theta-1) pq+4\theta^2](10d_i^2-10d_i+3)}{(2p-1)^2 \varepsilon_3^2 d_i^4 (d_i-1)^4 \varepsilon_4^2}.
\end{aligned}$$

证毕。

在算法 5.5 和算法 5.6 中，需要调用算法 5.3 和算法 5.4。由 5.3.节可知，该过程中用户所需的时间和空间复杂度分别为 $O\left(2(L+\theta+1)+\frac{d_i(d_i-1)}{2}\right)$ 和

$O(L+1+(n+2)\theta)$ ，数据收集者所需的时间和空间复杂度均为 $O(n(L+2+\theta))$ 。

此外，每个用户需报告自身度值，时间和空间复杂度均为 $O(1)$ 。数据收集者需根据用户的度值序列和三角计数序列依次计算每个用户的局部聚类系数，其时间和空间复杂度分别为 $O(n)$ 和 $O(2n)$ 。

综上所述，在算法 5.5 和算法 5.6 中，用户所需的时间和空间复杂度分别为 $O\left(2(L+\theta)+\frac{d_i(d_i-1)}{2}+3\right)$ 和 $O(L+2+(n+2)\theta)$ ，数据收集者的时间复杂度和空间复杂度分别为 $O(n(L+3+\theta))$ 和 $O(n(L+4+\theta))$ 。

5.5 实验分析

为评估本章所提出的 GS-LDP 算法在发布分布式图数据的不同统计指标(含度分布、三角序列及聚类系数)时的效果，本节选取多个公开真实数据集及生成数据集进行实验分析，并与其他同类图数据统计指标发布算法进行对比分析。本章所有实验均在 Windows 10 上运行，采用 Inter Core i5-6200U CPU 和 A4000-16G-ARM，Python3.8 实现。

5.5.1 实验设置

本文实验数据集选取了 Stanford Large Network Dataset Collection 网站上 3 个具有代表性的真实图数据集，这些数据集也被广泛应用于图数据隐私保护研究中^[24-26,31]。本章同样采用第四章相同的数据处理方法，对实验图数据集进行了分布式处理，使得每个分布式用户仅持有单个顶点的一阶邻居子图。

实验选取的图数据集分别为 Facebook, AstroPh, Email-Enron, 表 5.1 简要分析了数据集包含的节点数、边数, 以及最大度和平均度等特征信息。

表 5.1 真实图数据集的主要特征

数据集	节点数	边数	最大度	平均度
Facebook	4039	88234	1045	43.7
AstroPh	18772	198110	504	21.1
Email-Enron	36692	367662	1383	10

为对比分析图数据的不同统计指标的发布结果效用, 在实验中采用均方误差 MSE (mean squared error)和平均绝对误差 MAE (mean absolute error)2 个指标进行量化对比。以度分布为例, 设 $F = (f_1, f_2, \dots, f_l)$ 和 $F' = (f'_1, f'_2, \dots, f'_l)$ 分别为原始图

数据的度频率分布和隐私保护发布的度频率分布, $MSE = \frac{1}{l} \sum_{i=1}^l (f_i - f'_i)^2$ 和

$MAE = \frac{1}{l} \sum_{i=1}^l |f_i - f'_i|$ 。其中, MSE 和 MAE 值越小, 则表明度分布发布结果 F' 的效用越优。

5.5.2 算法对比与分析

本章所提 GS-LDP 可满足不同隐私保护强度和数据效用需求的分布式图数据多统计指标发布。在此方面, 与现有的基于 LDP 的分布式图数据统计指标发布算法具有明显差异。为了更好地表现这些算法间的不同点, 凸显算法 GS-LDP 的优势, 本节进行了理论对比与分析, 如表 5.2 所示。

由表 5.2 知, 算法 GS-LDP 可发布满足 Node-LDP 的度分布, 还可发布满足 Node-LDP 和 Edge-LDP 约束的三角计数序列及聚类系数。算法 RJ^[31]、NodeProj^[45]和 EdgeProj^[45]仅能发布度分布这一单一图数据统计指标。其中, 算法 RJ 直接对分布式节点的度值进行本地差分加噪, 其仅满足 LDP, 无法有效保护图数据节点间的隐私; 算法 NodeProj 和 EdgeProj 均可发布满足 Node-LDP 的度分布估计, 但二者需要花费更多的隐私预算以获取度阈值, 进而依据度阈值对度值进行加噪扰动, 因此其整体数据效用会受到影响; 算法 GS-LDP 在发布度分布时满足 Node-LDP, 采用分组机制和一元编码机制降低差分加噪量, 提高度分布的数据效用, 相较于算法 NodeProj 和 EdgeProj 具有更优的效用优势。

算法 RNL^[24]和 Local2Round_Δ^[26]都仅满足 Edge-LDP, 且能同时应用于发布三角计数序列和聚类系数, 但是不能有效发布度分布。其中, 算法 RNL 通过 RR 机制扰动子图的邻接向量并进一步聚合得到噪声图数据, 以此对三角计数序列和

聚类系数进行估计；算法 Local2Round_Δ在算法 RNL 基础上引入 2 轮交互模型降低估计中的噪声量；算法 GS-LDP 在发布三角计数序列和聚类系数时，通过引入 Prune 算法和 2 轮交互算法减少随机化过程及报告过程中的噪声量，相较于算法 RNL 和 Local2Round_Δ具有更优的效用优势。此外，在发布三角计数序列和聚类系数时，算法 GS-LDP 可根据不同的参数设置，进而满足 Node-LDP 和 Edge-LDP 2 种隐私约束。考虑到 Local2Round_Δ在 Node-LDP 设定下仍具备一定实用性，在 5.5.4 节和 5.5.5 节的对比实验中，将算法 Local2Round_Δ扩展使得其满足 Node-LDP，以便与算法 GS-LDP 在满足 Node-LDP 情况下的三角计数序列和聚类系数发布效用进行对比。

算法 IF-GDPR^[25]仅适用于发布聚类系数的算法，且仅满足 Edge-LDP，其在算法 RNL 的基础上引入拉普拉斯机制和优化机制发布度值，从而结合噪声图信息提升发布聚类系数的精度。而算法 GS-LDP 除了能发布聚类系数，还能同时发布度分布和三角计数序列，且能根据数据效用和隐私需求采用满足 Edge-LDP 或 Node-LDP 的隐私参数。

为了明确分析算法 GS-LDP 与其他不同算法在发布分布式图数据的不同统计指标时的时间复杂度差异，如表 5.2 所示，分为不同统计指标进行分析。

表 5.2 不同分布式图数据统计指标发布算法对比

发布不同指标		算法						
时具备的特征 及时间复杂度	度分布	GS-LDP(本文)	RJ ^[31]	NodeProj ^[45]	EdgeProj ^[45]	RNL ^[24]	Local2Round _Δ ^[26]	LF-GDPR ^[25]
	是否支持发布	√	√	√	√	×	×	×
	满足的隐私约束	Node-LDP	LDP	Node-LDP	Node-LDP	—	—	—
	用户时间复杂度	$O(2L+1)$	$O(1)$	$O(3K+1)$	$O(3K+\theta)$	—	—	—
布	数据收集者时间复杂度	$O(n(L+1))$	$O(n)$	$O\left(\frac{K(n+1)}{+n}\right)$	$O((K+n)(n+1))$	—	—	—
	三角计数	√	×	×	×	√	√	×
数	是否支持发布	√	×	×	×	√	√	×
	满足的隐私约束	Node-LDP Edge-LDP	—	—	—	Edge-LDP	Edge-LDP <u>Node-LDP</u>	—

序列	用户时间复杂度	$O\left(\frac{2(L+\theta+1)}{d_i(d_i-1)}\right)$	—	—	—	$O(n)$	$O\left(\frac{2+\frac{n}{2}+\frac{d_i(d_i-1)}{2}}{2}\right)$	—
	数据收集者时间复杂度	$O(n(L+2+\theta))$	—	—	—	$O\left(\frac{2n}{n^2}\right)$	$O\left(\frac{2n+n^2}{2}\right)$	—
聚类系数	是否支持发布	√	×	×	×	√	√	√
	满足的隐私约束	Node-LDP	—	—	—	Edge-LDP	Edge-LDP	Edge-LDP
		Edge-LDP	—	—	—	Edge-LDP	<u>Node-LDP</u>	Edge-LDP
	用户时间复杂度	$O\left(\frac{2(L+\theta)}{d_i(d_i-1)}\right)$	—	—	—	$O(n)$	$O\left(\frac{2+\frac{n}{2}+\frac{d_i(d_i-1)}{2}}{2}\right)$	$O(n+1)$
	数据收集者时间复杂度	$O(n(L+3+\theta))$	—	—	—	$O\left(\frac{4n}{n^2}\right)$	$O\left(\frac{4n+n^2}{2}\right)$	$O\left(3n+\frac{n^2}{2}\right)$

注：表中“—”指算法无法实现对应特征的发布。同时，发布满足的隐私约束，若未标记下划线，则原始文献所提的算法满足该隐私约束；若标记下划线，则原始文献所提的算法不满足该隐私约束，在本文实验中将其扩展为满足该隐私约束(具有一定实用性)以便进行实验对比。

(1)度分布。所提算法 GS-LDP 在发布度分布时用户和数据收集者的时间复杂度分别为 $O(2L+1)$ 和 $O(n(L+1))$ (其中， L 为组距，且 $L \ll d_{\max}$)；算法 RJ 中用户和数据收集者的时间复杂度分别为 $O(1)$ 和 $O(n)$ ；算法 NodeProj 中用户和数据收集者的时间复杂度分别为 $O(3K+1)$ 和 $O(K(n+1)+n)$ ；算法 EdgeProj 中用户和数据收集者的时间复杂度分别为 $O(3K+\theta)$ 和 $O((K+n)(n+1))$ (其中， $K \leq d_{\max}, \theta \leq d_{\max}, d_{\max} \ll n$)。可见，算法 GS-LDP 的时间复杂度高于算法 RJ，优于算法 NodeProj 和 EdgeProj。但由于算法 RJ 满足传统 LDP，不能保护图数据的结构性隐私，而算法 GS-LDP，NodeProj，EdgeProj 都满足 Node-LDP，故 GS-LDP 在同类度分布发布算法中具有效率优势。

(2)三角计数序列。所提算法 GS-LDP 在发布三角计数序列时，用户和数据收集者的时间复杂度分别为 $O\left(2(L+\theta+1)+\frac{d_i(d_i-1)}{2}\right)$ 和 $O(n(L+2+\theta))$ ($L \ll d_{\max}, d_i \leq d_{\max}, \theta \leq d_{\max}, d_{\max} \ll n$)；算法 RNL 用户和数据收集者的时间复杂

度分别为 $O(n)$ 和 $O(2n+n^2)$ ；算法 Local2Round $_{\Delta}$ 用户和收集者的时间复杂度分

别 $O\left(2+\frac{n+d_i(d_i-1)}{2}\right)$ 和 $O\left(\frac{2n+n^2}{2}\right)$ 。可见，3个算法中用户的计算时间开销相

差不大；而算法 GS-LDP 中数据收集者的计算时间开销要显著小于算法 RNL 和 Local2Round $_{\Delta}$ 。故而，算法 GS-LDP 在发布三角计数序列时具备显著的效率优势。

(3)聚类系数。所提算法 GS-LDP 在发布聚类系数时，用户和数据收集者的时间复杂度分别为 $O\left(2(L+\theta)+\frac{d_i(d_i-1)}{2}+3\right)$ 和 $O(n(L+3+\theta))$

$(L \ll d_{\max}, d_i \leq d_{\max}, \theta \leq d_{\max}, d_{\max} \ll n)$ ；算法 RNL 中用户和数据收集者的时间复

杂度分别为 $O(n)$ 和 $O(4n+n^2)$ ；算法 Local2Round $_{\Delta}$ 中用户和收集者的时间复杂

度分别 $O\left(2+\frac{n+d_i(d_i-1)}{2}\right)$ 和 $O\left(\frac{2n+n^2}{2}\right)$ ；算法 LF-GDPR 中用户和数据收集者

的时间复杂度分别 $O(n+1)$ 和 $O\left(3n+\frac{n^2}{2}\right)$ 。可见，4个不同算法中用户的计算时

间开销相差不大；而算法 GS-LDP 中数据收集者的计算时间开销要显著小于算法其他3个算法。

5.5.3 度分布发布效用对比与分析

本节对比算法 GS-LDP, NodeProj, EdgeProj, RJ 在发布度分布时的效用差异。

在对比实验中，对4种不同的算法均设定隐私预算为 $\varepsilon=[0.5,1,1.5,2,2.5,3]$ 和 $L=10$ ，对比算法在3个数据集上发布度分布时的效用。实验结果如图5.2所示，其中图5.2(a)~(c)分别为不同算法在3个数据集上的MSE效用对比结果，图5.2(d)~(f)分别为不同算法在3个数据集上的MAE效用对比结果。

由图5.2知，所提算法 GS-LDP 在发布度分布时的效用显著优于算法 NodeProj 和 EdgeProj，但差于算法 RJ。具体而言，如图5.2(a)(d)所示，当数据集为 Facebook 时，所提度分布算法相较于算法 NodeProj 和 EdgeProj，MSE 和 MAE 分别降低了63%~99%和19%~90%；相较于算法 RJ，MSE 和 MAE 分别提升了68%~90%和43%~73%。类似地，如图5.2(b)~(c)和图5.2(e)~(f)所示，当数据集为 AstroPh 和 Email-Enron 时，所提度分布算法的数据效用比法 NodeProj 和 EdgeProj 具有明显优势，但略差于算法 RJ。

所提出的基于 Node-LDP 的度分布发布算法的效用大幅度提升的原因是，该

算法采用了分组编码的方式,通过 SUE 机制扰动分布式用户的度向量,从而在满足 Node-LDP 的同时,减少所添加的噪声。此外,算法 RJ 仅为传统的 LDP 算法,并不能保护图数据的结构隐私,隐私约束相对宽松。因此相较于算法 RJ,算法 GS-LDP 在发布度分布时具备略微的效用劣势,但隐私保护强度要远优于算法 RJ。

总体而言,本文所提算法满足 Node-LDP,在提高隐私保护效果的同时提升了发布度分布的效用。




图 5.2 4 种不同度分布发布算法的效用对比

5.5.4 三角计数序列效用对比与分析

本节将对比所提算法 GS-LDP 与算法 RNL, Local2Round_Δ发布三角计数序列时的效用差异。


由 5.5.2 节可知,算法 GS-LDP 和 Local2Round_Δ可满足 2 种隐私约束,而算法 RNL 仅能在 Edge-LDP 约束下具备实用性。因此,在对比实验中,对 3 种算法均设定隐私预算为 $\epsilon = [1, 2, 3, 4, 5, 6]$ 和 $L = 10$,对比不同算法在 3 个数据集上发布不同隐私约束(Node-LDP 和 Edge-LDP)三角计数序列时的效用。实验结果如图 5.3 和图 5.4 所示。在此,通过在算法名后加 Node 和 Edge 符号作为满足 Edge-LDP 和 Node-LDP 约束的区分。其中图 5.3 为 GS-LDP-Edge, RNL-Edge, Local2Round_Δ-Edge 的效用对比结果,图 5.4 为 GS-LDP-Node 和 Local2Round_Δ-Node 的效用对比结果,其中,满足 Edge-LDP 的实验中 $Level = 0.98$,满足 Node-LDP 的实验中 $Level = 0.8$ 。

由图 5.3 可知,在大多数情况下,所提算法 GS-LDP 在 Edge-LDP 约束下发

布分布式图数据三角计数序列时的效用在 2 个指标度量下较算法 RNL-Edge 和 Local2Round Δ -Edge 具备一定的优势。具体而言,如图 5.3(a)和图 5.3(d)所示,在数据集 Facebook 上,当 $\varepsilon=[1,2,3]$ 时,GS-LDP-Edge 相比其他 2 个算法的 *MSE* 和 *MAE* 分别降低了 14%~99%和 50%~99%,而当 $\varepsilon=[4,5,6]$ 时,GS-LDP-Edge 相较于 Local2Round Δ -Edge 的 *MSE* 有一 36%~10%的波动,*MAE* 降低了 51%~62%,但相较于 RNL-Edge 在 *MSE* 和 *MAE* 具备一定的劣势。同理,如图 5.3(b)~(c)和图 5.3(e)~(f)所示,在数据集 AstroPh 和 Email-Enron 上,无论隐私预算为何值,GS-LDP-Edge 相较于 Local2Round Δ -Edge 在 *MSE* 和 *MAE* 上均存在不同程度的优势。而与 RNL-Edge 相比,当 $\varepsilon=[1,2,3,4]$ 时,GS-LDP-Edge 具备明显的效用优势,但当 $\varepsilon=[5,6]$ 时,GS-LDP-Edge 的效用较 RNL-Edge 存在劣势。

整体而言,在不同数据集上,GS-LDP-Edge 相较于 RNL-Edge 的 *MSE* 和 *MAE* 随着隐私预算的取值不同,各有优势,而相较于 Local2Round Δ -Edge 具备明显优势;特别是隐私预算较小时,所提算法效用优势更为突出。具体而言,在满足 Edge-LDP 约束及隐私预算较小时,Prune 算法和 2 轮交互模型在一定程度上可以减少三角计数估计过程中的噪声量;但当隐私预算较大时,噪声量的减少使得 Prune 算法可能会删掉部分无需删除的边从而导致最终估计精度受一定影响。但整体而言,在大多数情况下,本文提出的基于 Edge-LDP 的三角计数序列发布算法 GS-LDP-Edge 仍然具备相应的效用优势。


由图 5.4 可知,所提出的基于 Node-LDP 的分布式图数据三角计数序列发布算法 GS-LDP-Node 的效用在 2 个指标度量下都优于算法 Local2Round Δ -Node。具体而言,如图 5.4(a)和图 5.4(d)所示,在数据集 Facebook 上,当 $\varepsilon=[1,2,3,4,5,6]$ 时,GS-LDP-Node 相较于 Local2Round Δ -Node 的 *MSE* 和 *MAE* 分别降低了 74%~96%及 58%~84%。类似地,如图 4(b)~(c)和图 4(e)~(f)所示,在数据集 AstroPh 和 Email-Enron 上,GS-LDP-Node 的数据效用也明显优于算法 Local2Round Δ -Node。所提出的基于 Node-LDP 的三角计数序列发布算法的效用大幅度提升的原因是 Prune 算法可大幅限制噪声边的数量以及 Node-LDP 随机化过程隐私预算分配过小等问题,进而可提升估计精度。



(a) Facebook 上 *MSE* 度量


(b) AstroPh 上 *MSE* 度量

(c) Email-Enron 上 *MSE* 度量




(d) Facebook 上 MAE 度量 (e) AstroPh 上 MAE 度量 (f) Email-Enron 上 MAE 度量

图 5.3 满足 Edge-LDP 时不同三角计数序列发布算法的效用对比



(a) Facebook 上 MSE 度量 (b) AstroPh 上 MSE 度量 (c) Email-Enron 上 MSE 度量



(d) Facebook 上 MAE 度量 (e) AstroPh 上 MAE 度量 (f) Email-Enron 上 MAE 度量

图 5.4 满足 Node-LDP 时不同三角计数序列发布算法的效用对比

5.5.5 聚类系数效用对比与分析

本节将对比所提算法 GS-LDP 与算法 RNL, Local2Round $_{\Delta}$, IF-GDPR 在发布聚类系数时的效用差异。

由 5.5.2 节可知, 算法 GS-LDP 和 Local2Round $_{\Delta}$ 可满足 2 种隐私约束, 而算法 RNL 和 IF-GDPR 仅在 Edge-LDP 约束下具备实用性。因此, 对比实验中, 分别设置 2 组实验, 测试满足 Edge-LDP 时算法 GS-LDP 与 RNL, Local2Round $_{\Delta}$, IF-GDPR 的效用差异以及满足 Node-LDP 时 GS-LDP 与 Local2Round $_{\Delta}$ 的效用差异。

首先, 设置隐私预算为 $\varepsilon = [1, 2, 3, 4, 5, 6]$ 、 $L = 10$ 以及 $Level = 0.98$, 将所提基于 Edge-LDP 的分布式图数据聚类系数发布算法与算法 RNL-Edge, Local2Round

Δ -Edge, IF-GDPR-Edge 在表 2 中的 3 个真实数据集上进行效用的对比, 结果如图 5.5 所示; 其次, 由于真实数据集稀疏性, GS-LDP-Node 和 Local2Round Δ -Node 的效用差距也难以彰显。因此, 采取在生成数据集上测试算法 GS-LDP-Node 和 Local2Round Δ -Node 发布聚类系数的效用。实验设置 $\varepsilon=[5,10,15]$, $L=10$, $Level=0.5$, 生成数据集规模为 $n=10^3 \times [1,2,3,4,5,6,7,8,9,10,11,12,13,14,15]$, 将所提基于 Node-LDP 的分布式图数据聚类系数发布算法 GS-LDP-Node 与 Local2Round Δ -Node 的效用进行对比, 结果如图 5.6 所示。

由图 5.5 可知, 在不同的数据集上, GS-LDP-Edge 相较于其他算法效用表现各有不同。在数据集 Facebook 和 Email-Enron 上时, 如图 5.5(a)~(f)所示, IF-GDPR-Edge 的数据效用最优, GS-LDP-Edge 与 Local2Round Δ -Edge 的数据效用相近, 且大多数情况都比 RNL-Edge 的数据效用更优。特别是当隐私预算小于 5 时, 算法 GS-LDP-Edge 相比于 RNL-Edge 的数据效用优势更加明显。在数据集 AstroPh 上, 如图 5.5(b)和图 5.5(e)所示, 无论隐私预算如何取值, 算法 GS-LDP-Edge 的数据效用都比 RNL-Edge 和 Local2Round Δ -Edge 更优, *MSE* 和 *MAE* 分别降低了 0.3%~50%和 -1%~43%。同时, 与 IF-GDPR-Edge 的数据效用相比在隐私预算取值不同时各有优势, 当 $\varepsilon=[2,3,4]$, GS-LDP-Edge 相较于 IF-GDPR-Edge 在 *MSE* 和 *MAE* 上降低了 4%~13%和 4%~8%, 而当 $\varepsilon=[1,5,6]$ 时, GS-LDP-Edge 在 *MSE* 和 *MAE* 具有 -2%~-11%和 -4%~-10%的劣势。

整体而言, 随着数据集的规模和隐私预算的逐步增大, 算法 GS-LDP-Edge 相较于算法 RNL-Edge 和 Local2Round Δ -Edge 的数据效用优势越大, 且逐步与算法 IF-GDPR-Edge 的效用接近。具体原因与发布满足 Edge-LDP 约束下三角计数序列时大同小异, Prune 算法和 2 轮交互模型在一定程度上可以减少三角计数估计过程中的噪声量, 整体可提升聚类系数的估计精度。但与 IF-GDPR 相比, 该算法无法进一步引入度值优化机制, 因而最终的聚类系数估计精度较算法 IF-GDPR 优势各异。

进一步地, 由图 5.6 可知, 随着生成图数据集的规模逐步扩大, 无论隐私预算取值, 算法 GS-LDP-Node 的数据效用均优于 Local2Round Δ -Node, *MAE* 和 *MSE* 分别降低了 6%~23%和 5%~20%。与 5.5.4 节同理, Prune 算法可大幅限制噪声边的数量以及 Node-LDP 随机化过程隐私预算过小等问题; 且 GS-LDP-Node 可通过度分布算法获取阈值, 在一定程度上也可降低度值报告过程中所需添加的噪声量, 进而可提升估计精度




图 5.5 满足 Edge-LDP 时不同聚类系数发布算法的效用对比




图 5.6 满足 Node-LDP 时不同聚类系数发布算法的效用对比

5.5.6 通信代价分析

所提算法 GS-LDP 和 Local2Round Δ 在发布三角计数序列和聚类系数时，都应用 2 轮交互机制，在第 2 轮交互中需要数据收集者将噪声数据下发给各分布式用户，以使用户能对自身局部三角计数进行估计。算法 GS-LDP 引入算法 Prune 降低了噪声结构数据中的噪声边的数量，能够降低噪声图数据下发时的通信代价。为直观表明算法 GS-LDP 的通信优势，本节将算法 GS-LDP 与 Local2Round

Δ 进行通信代价实验对比分析。同时,本节进一步引入文献[33]中的算法 ARRTwoNS Δ 进行通信代价实验对比,其中算法 ARRTwoNS Δ 是 Imola 等人^[33]在 Local2Round Δ 基础上引入边采样方法所提出的一种低通信代价的三角计数发布算法,其通过对噪声图进行采样下载,从而减少通信代价和其他计算开销。因此,本节分别对比上述 3 个算法交互过程中下载所需的通信代价,结果如图 5.7 所示。

图 5.7 中,设置了 2 组实验。首先,在数据集 Facebook 上设置隐私预算 $\varepsilon = [1, 2, 3, 4, 5, 6, 7]$, $L = 10$, $Level = 0.98$, 验证算法 GS-LDP, Local2Round Δ , ARRTwoNS Δ 分别在满足 Node-LDP 和 Edge-LDP 时,在第 2 轮交互过程中噪声图数据下载的通信数据量,结果如图 5.7(a)和图 5.7(b)所示;其次,数据集规模为 $n = 10^3 \times [1, 2, 3, 4, 5]$ 的生成图设置隐私预算 $\varepsilon = 5$, $L = 10$, $Level = 0.5$, 验证算法 GS-LDP, Local2Round Δ , ARRTwoNS Δ 分别在满足 Node-LDP 和 Edge-LDP 时,在第 2 轮交互过程中噪声图数据下载的通信数据量,结果如图 5.7(c)和图 5.7(d)所示。

由图 5.7(a)和图 5.7(b)可知,算法 GS-LDP 在真实数据集上,无论满足 Node-LDP 还是满足 Edge-LDP 时,其通信代价都显著低于算法 Local2Round Δ ,特别是隐私预算越小,算法 GS-LDP 的优势越大;而相较于算法 ARRTwoNS Δ 而言,满足 Node-LDP 时 GS-LDP 仍旧具备显著的优势;但在满足 Edge-LDP 时,GS-LDP 仅在隐私预算较小时具备通信代价优势,但随着隐私预算的逐步上升,GS-LDP 则具备一定的劣势。进一步地,由图 5.7(c)和图 5.7(d)可知,在模拟的生成图数据集上,算法 GS-LDP 的通信代价依旧远小于算法 Local2Round Δ ,特别是数据规模越大,算法 GS-LDP 的优势越大。但相对于算法 ARRTwoNS Δ 而言,结果与真实数据集结果一致,即满足 Node-LDP 时 GS-LDP 具备显著优势,而满足 Edge-LDP 时 GS-LDP 所需的通信代价则多于算法 ARRTwoNS Δ 。

算法 GS-LDP 在满足 Node-LDP 时相较于算法 Local2Round Δ 和 ARRTwoNS Δ 具备显著通信代价优势的原因在于,GS-LDP 分配了部分隐私预算以通过度分布过程获得更小的度值扰动阈值,并以此对各个用户的子图邻接向量进行裁剪,大幅度减少添加的噪声边,降低通信代价。同理,在满足 Edge-LDP 时,算法 GS-LDP 相较于 Local2Round Δ 仍旧能够通过一定程度的通过裁剪算法优化随机化过程中存在的噪声边,降低下载过程中所需的通信代价。但是,由于在 Edge-LDP 下,噪声边缘的增加量相较于 Node-LDP 会弱化许多,且噪声边缘的增加程度与隐私预算成反比,因此仍需直接下载噪声图的 GS-LDP 相较于使用采样方法的 ARRTwoNS Δ 算法而言在满足 Edge-LDP 时,通信代价具备一定的劣势。





图 5.7 通信代价实验分析

5.5.7 其他参数影响

本文所提算法 GS-LDP 在发布度分布、三角计数序列及聚类系数时，均需设置合理的组距 L 和频率上限 $Level$ ，以达到更优的效用。因此，本节分别测试 L 和 $Level$ 对所提算法在 Edge-LDP 和 Node-LDP 下收集的统计指标的效用影响，主要分为 2 个部分。此处，本节采用 Facebook 数据集和生成数据集进行实验，并使用 MSE 作为度量指标。

第一，无论是发布度分布，还是发布三角计数序列和聚类系数时，组距 L 均需被调用。因此，设置 $L=[10,15,20,25,30]$ ，分别测试其对各统计指标的影响，实验结果如图 5.8 所示。首先，针对度分布发布，设置 $\varepsilon=[0.5,1,1.5,2,2.5,3]$ 进行实验，结果如图 5.8(a)所示。如图 5.8(a)所示，可直观看出，随着 L 的逐步上升，GS-LDP 在收集度分布时的效用随之降低。具体原因在于，更小的 L 对应于 SUE 扰动的阈值更小，可一定程度减少噪声输入量，进而提升发布精度。其次，设置 $\varepsilon=[1,2,3,4,5,6]$ 和 $Level=0.98$ 对 Edge-LDP 约束下发布三角计数序列和聚类系

数时的效用进行测试, 实验结果如图 5.8(b)和图 5.8(c)。与度分布同理, 二者的效用也随着 L 的逐步下降而上升。原因在于, 随着 L 的下降, 度分布效用逐步上升, 使得度阈值更精确, 从而可避免删除过多有效边。再次, 我们分别设置 $\varepsilon = [1, 2, 3, 4, 5, 6]$ 和 $Level = 0.8$, 在 Facebook 数据集上测试 GS-LDP 在 Node-LDP 约束下发布三角计数序列的效用, 并设置 $\varepsilon = 5$ 及 $Level = 0.5$ 在生成图上测试 Node-LDP 约束下 GS-LDP 发布聚类系数的效用, 其中生成图的大小为 $n = 10^3 \times [6, 8, 10, 12, 15]$, 实验结果分别为图 5.8(d)和图 5.8(e)。如图 5.8(d)和图 5.8(e)所示, GS-LDP 在满足 Node-LDP 时发布三角计数序列和聚类系数的效用与 L 不具备线性关系。同时, 随着隐私预算的逐步上升, 无论 L 为何值, GS-LDP 的效用均相近。具体原因为, GS-LDP 在 Node-LDP 下发布三角计数序列和聚类系数时, 随机化过程的噪声量更大, 尽管 L 会影响度分布的精度, 但相较于 Node-LDP 约束下随机化过程所产生的噪声量仍影响较小。最后, 由于 L 的值还对应于算法 5.1 中用户报告的噪声度向量的长度, 进而将会影响各分布式用户度向量报告过程所需的时间开销。因此, 在 Facebook 数据集上测试发布度分布时, L 对分布式用户的时间开销的影响, 实验结果如图 5.8(f)所示。如图 5.8(f)所示, 可直观看出, GS-LDP 发布度分布时, 用户所需的时间开销随着 L 的增大而上升。整体而言, 在条件允许的情况下, L 可相对设置较小, 以保证低时间开销的同时保证更优的效用。



(a) Node-LDP 下 L 对度分布效用影响 (b) Edge-LDP 下 L 对三角计数序列效用影响






图 5.8 L 的影响

第二, GS-LDP 发布三角计数序列和聚类系数时, 需通过频率上限 $Level$ 设定合理的度阈值 θ 。因此, 设置 $Level = [0.5, 0.6, 0.7, 0.8, 0.9, 0.98]$, 分别测试 $Level$ 对三角计数序列和聚类系数指标发布的影响。其中, 由于计算 θ 时使用的是度分布估计, 可能造成阈值溢出问题, 因此使用 $Level = 0.98$ 代替 $Level = 1$ 。实验结果如图 5.9 所示。首先, 设置 $\varepsilon = [1, 2, 3, 4, 5, 6]$ 和 $L = 10$, 测试 Edge-LDP 约束下 $Level$ 对 GS-LDP 发布三角计数序列和聚类系数的效用影响, 如图 5.9(a)和图 5.9(b)所示。可直观发现, 三角计数序列和聚类系数的效用随 $Level$ 的增大而逐步上升, 当 $Level = 0.98$ 时, 效用最优。具体原因为: θ 与 $Level$ 成正比, 随着 $Level$ 的逐步上升, θ 值越大。因此, 在满足 Edge-LDP 时, 其能够在通过剪枝算法弱化噪声量的同时避免删除过多有效边, 进而可将效用最大化。其次, 设置 $\varepsilon = [1, 2, 3, 4, 5, 6]$ 和 $L = 10$, 在 Facebook 数据集上测试 Node-LDP 约束下 $Level$ 对 GS-LDP 发布三角计数序列的效用影响; 同时, 设置 $\varepsilon = 5$ 和 $L = 10$, 在生成图上测试 Node-LDP 约束下聚类系数的发布效用, 其中生成图大小为 $n = 10^3 \times [6, 8, 10, 12, 15]$, 实验结果分别为图 5.9(c)和图 5.9(d)。如图 5.9(c)和图 5.9(d)所示, 在满足 Node-LDP 时,

GS-LDP 发布三角计数序列和聚类系数时的效用与 *Level* 成反比。具体原因为：在满足 Node-LDP 时，随机响应机制所产生的噪声量更高。此时，更小的 θ 可更好的限制噪声边的上限，进而可发布更高效用的指标。因此，可得出结论，当需要在 Edge-LDP 约束下发布统计时，可在条件允许的情况下将 *Level* 设置大一些（但不能设为 1，因为可能造成阈值溢出）；而当需要在 Node-LDP 约束下发布统计时，则可将 *Level* 设置小一些，以保证更优的发布效用。



(a) Edge-LDP 下 *Level* 对三角计数序列效用影响 (b) Edge-LDP 下 *Level* 对聚类系数效用影响



(c) Node-LDP 下 *Level* 对三角计数序列效用影响 (d) Node-LDP 下 *Level* 对聚类系数效用影响

图 5.9 *Level* 的影响

5.6 本章小结

本章提出一种基于 LDP 的分布式图数据统计指标发布算法(GS-LDP)，旨在满足不同隐私保护强度和数据效用需求的同时实现图数据多统计指标高效用发布。首先，针对特性单一且易泄露隐私的度分布，采取分组机制和对称一元编码机制进行扰动发布，使算法满足 Node-LDP 的同时发布数据效用更高的度分布。其次，针对强结构性统计指标(三角计数序列和聚类系数)，提出剪枝算法解决随机过程噪声边添加过多的问题。进一步地，根据分布式图场景不同的隐私性和安

全性需求，结合剪枝算法和 2 轮交互模型分别提出基于 Node-LDP 和 Edge-LDP 的三角计数序列和聚类系数发布算法，同时提高算法安全性和数据效用。最后，利用真实数据集和生成数据集对不同的图数据统计指标发布算法进行理论和实验对比，结果表明所提算法在发布度分布、三角计数序列和聚类系数时有显著的优势，同时大幅度降低了 2 轮交互发布算法的通信代价。

第6章 总结与展望

6.1 研究工作总结

在数据共享需求高速上升的时代下,图数据所具备的表示不同实体间复杂关系的特性使得其受到学术界和产业界的广泛关注,进而涌现出各类图数据的发布、存储和挖掘分析等研究。差分隐私因其具备可证明强度的隐私保护能力使得其在图数据发布共享领域备受关注,但差分隐私机制的特殊性以及图数据的特殊关联性导致实际方案均存在不可避免的安全威胁和数据效用矛盾,且研究对象相对单一。因此,如何均衡此类安全与效用问题,以及如何面向多对象发布成为了本文的研究重点。本文的研究工作在于如何实现差分隐私下的高效图数据发布,主要为:

(1)对基于差分隐私的图数据发布隐私保护模型的发展历程、研究现状和技术进展进行学习和整理,并梳理该研究领域现有的关键问题和解决方案。从已有的差分隐私保护模型和算法中探索可行的改进思路,并进一步研究差分隐私领域现有研究在图数据上的可行性。

(2)对新型混洗差分隐私机制进行研究,探索其在图数据场景下的可行路径。结合混洗差分隐私二项机制、方波噪声机制及 EM 算法,提升隐私保护后的度分布估计精度。

(3)探索高维图统计指标与混洗差分隐私的共性,提出混洗差分隐私保护的聚类系数发布算法。通过混洗扰动契形的方式平替直接边缘直接加噪,从而提升效用的同时避免切断数据关联性,实现高效的聚类系数发布算法,并证明隐私上限。

(4)面向多样化统计指标发布以及自适应差分隐私保护强度需求,设计基于本地差分隐私的图统计指标发布算法。引入分组对称一元编码和随机响应机制,设计剪枝算法,实现多样化统计指标发布。进一步地,基于本地差分隐私及点本地差分隐私机制及定义,构建分别满足二者的发布算法,以实现自适应隐私保护选择。

本文的研究工作可有效的提升分布式场景下的图统计发布精度,且能够在本地差分隐私约束下满足自适应隐私保护强度和多统计指标发布需求。相较于现有分布式差分隐私方案,所提混洗差分隐私下度分布及聚类发布算法具备显著效用优势,且所提本地差分隐私下多统计指标发布算法可实现不同隐私保护强度和数据效用需求的分布式多统计指标发布。

6.2 不足和展望

虽然围绕基于差分隐私的图数据发布隐私保护模型研究已取得了众多成果，但其面临的隐私保障和数据效用矛盾仍存在着不俗的挑战。本文从安全与效用矛盾出发，结合相关工作展开研究，分析发现当前领域仍旧留存不足，未来值得继续研究：

(1)现有本地差分隐私的效用仍旧难以实现真实数据服务场景下的使用，其更为核心的效用优化机制仍需探索。

(2)混洗差分隐私的提出虽极大的平衡了中心化和本地差分隐私间的矛盾，但洗牌操作在应用于图数据时，仍旧存在切断关联性、隐私保障过于宽泛等情况。因此，探索如何更有效的采用混洗差分隐私实现图数据各类发布仍旧存在较大的研究价值。

(3)现有基于差分隐私的图数据发布研究，其研究基础仍建立于常规线性数据保护基础之上，无法单独针对具体应用场景提出高适配性的差分隐私保护机制。因此，如何根据具体数据类型，提出独有且高效的差分隐私模型，仍亟待切实可行的解决方案。

参考文献

- [1] Heidari S, Simmhan Y, Calheiros R N, et al. Scalable graph processing frameworks: A Taxonomy and Open Challenges[J]. ACM Computing Surveys, 2018, 51(3):1-53.
- [2] Sharma V, You I, Jayakody D N K, et al. Cooperative trust relaying and privacy preservation via edge-crowdsourcing in social internet of things[J]. Future Generation Computer Systems, 2019, 92: 758-776.
- [3] Tian Y, Zhang Z, Xiong J, et al. Achieving graph clustering privacy preservation based on structure entropy in social IoT[J]. IEEE Internet of Things Journal, 2021, 9(4): 2761-2777.
- [4] National Research Council, Division on Engineering and Physical Sciences, Board on Mathematical Sciences and Their Applications, et al. Frontiers in massive data analysis[M]. Washington, D.C.: National Academies Press, 2013.
- [5] Ma S, Liu J, Zuo X, et al. Survey on Graph Neural Network[J]. Journal of Computer Research and Development, 2022, 59(1): 47-80. (in Chinese)
马帅, 刘建伟, 左信,等. 图神经网络综述[J]. 计算机研究与发展, 2022, 59(1): 47-80.
- [6] Sajadmanesh S, Shamsabadi A S, Bellet A, et al. GAP: differentially private graph neural networks with aggregation perturbation//Proceedings of the 32nd USENIX Security Symposium (USENIX Security 23). Berkeley, CA: USENIX Association, 2023: 3223-3240.
- [7] Jiang H, Pei J, Yu D, et al. Applications of differential privacy in social network analysis: A survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 35(1): 108-127.
- [8] Liu Y, Chen H, Liu Y, et al. State-of-the-art privacy attacks and defenses on graphs [J]. Chinese Journal of Computers, 2022, 45(4):702-734. (in Chinese)
刘宇涵, 陈红, 刘艺璇,等. 图数据上的隐私攻击与防御技术[J]. 计算机学报, 2022, 45(4):702-734.
- [9] Liu K, Terzi E. Towards identity anonymization on graphs[C]//Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2008: 93-106.
- [10] Zhou B, Pei J. Preserving privacy in social networks against neighborhood attacks[C]//2008 IEEE 24th International Conference on Data Engineering.

- Piscataway, NJ: IEEE, 2008: 506-515.
- [11]Zou L, Chen L, Özsu M T. K-automorphism: A general framework for privacy preserving network publication[J]. VLDB Endowment, 2009, 2(1): 946-957.
- [12]Dwork C. Differential privacy[C]//Proceedings of the 33rd International Colloquium on Automata, Languages, and Programming. Berlin: Springer, 2006: 1-12.
- [13]Kairouz P, Bonawitz K, Ramage D. Discrete distribution estimation under local privacy[C]//International Conference on Machine Learning. PMLR: New York, 2016: 2436-2444.
- [14]Nguyễn T T, Xiao X, Yang Y, et al. Collecting and analyzing data from smart device users with local differential privacy[J]. arXiv preprint arXiv:1606.05053, 2016.
- [15]Wang T, Blocki J, Li N, et al. Locally differentially private protocols for frequency estimation[C]//Proceedings of the 26th USENIX Security Symposium (USENIX Security 17). Berkeley, CA: USENIX Association, 2017: 729-745.
- [16]Ye Q, Meng X, Zhu M, et al. Survey on Local Differential Privacy[J] Journal of Software, 2018, 29(7): 1981-2005. (in Chinese)
叶青青, 孟小峰, 朱敏杰,等. 本地化差分隐私研究综述[J]. 软件学报, 2018, 29(7): 1981-2005.
- [17]Cormode G, Jha S, Kulkarni T, et al. Privacy at scale: Local differential privacy in practice[C]//Proceedings of the 2018 International Conference on Management of Data. New York: ACM, 2018: 1655-1658.
- [18]Wu N, Peng C, Tian Y, et al. Utility Optimal Model for Differential Privacy Based on the Rate[J]. Distortion Chinese Journal of Computers, 2020, 43(08): 1463-1478. (in Chinese)
吴宁博, 彭长根, 田有亮,等. 基于率失真的差分隐私效用优化模型[J]. 计算机学报, 2020, 43(08): 1463-1478.
- [19]Hay M, Li C, Miklau G, et al. Accurate estimation of the degree distribution of private networks[C]//Proceedings of the 9th IEEE International Conference on Data Mining. Piscataway, NJ: IEEE, 2009: 169-178.
- [20]Day W Y, Li N, Lyu M. Publishing graph degree distribution with node differential privacy[C]//Proceedings of the 35th ACM SIGMOD International Conference on Management of Data. New York: ACM, 2016: 123-138.
- [21]Jian X, Wang Y, Chen L. Publishing graphs under node differential privacy[J].

- IEEE Transactions on Knowledge and Data Engineering, 2023, 35(4): 4164-4177.
- [22]Zhang Y, Wei J, Li J, et al. Graph Degree Histogram Publication Method with Node-Differential Privacy[J]. Journal of Computer Research and Development, 2019, 56(3): 508-520. (in Chinese)
- 张宇轩, 魏江宏, 李霁,等. 点差分隐私下图数据的度直方图发布方法[J]. 计算机研究与发展, 2019, 56(3): 508-520.
- [23]Zhang S, Ni W, Fu N. Differentially private graph publishing with degree distribution preservation[J]. Computers & Security, 2021, 106(6):102285.
- [24]Zhan Q, Ting Y, Yin Y, et al. Generating synthetic decentralized social graphs with local differential privacy[C]//Proceedings of the 24th ACM SIGSAC Conference on Computer and Communications Security. New York: ACM, 2017: 425-438.
- [25]Ye Q, Hu H, Au M H, et al. LF-GDPR: A framework for estimating graph metrics with local differential privacy[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(10): 4905-4920.
- [26]Imola J, Murakami T, Chaudhuri K. Locally differentially private analysis of graph statistics[C]//Proceedings of the 30th USENIX Security Symposium (USENIX Security 21). Berkeley, CA: USENIX Association, 2021: 983-1000.
- [27]Sun H, Xiao X, Khalil I, et al. Analyzing subgraph statistics from extended local views with decentralized differential privacy[C]//Proceedings of the 26th ACM SIGSAC Conference on Computer and Communications Security. New York: ACM, 2019: 703-717.
- [28]Liu Y, Zhao S, Liu Y, et al. Collecting triangle counts with edge relationship local differential privacy[C]//2022 IEEE 38th International Conference on Data Engineering (ICDE). Piscataway, NJ: IEEE, 2022: 2008-2020.
- [29]Gao T, Li F, Chen Y, et al. Preserving local differential privacy in online social networks[C]//Wireless Algorithms, Systems, and Applications: 12th International Conference, WASA 2017. Berlin: Springer, 2017: 393-405.
- [30]Gao T, Li F, Chen Y, et al. Local differential privately anonymizing online social networks under hrg-based model[J]. IEEE Transactions on Computational Social Systems, 2018, 5(4): 1009-1020.
- [31]Wei C, Ji S, Liu C, et al. AsgLDP: collecting and generating decentralized attributed graphs with local differential privacy[J]. IEEE Transactions on Information Forensics and Security, 2020, 15: 3239-3254.

- [32]Liu Z, Xu H, Huang L, et al. Estimating clustering coefficient of multiplex graphs with local differential privacy[C]//Wireless Algorithms, Systems, and Applications: 16th International Conference, WASA 2021. Berlin: Springer, 2021: 390-398.
- [33]Imola J, Murakami T, Chaudhuri K. {Communication-efficient} triangle counting under local differential privacy[C]//Proceedings of the 31st USENIX Security Symposium (USENIX Security 22). Berkeley, CA: USENIX Association, 2022: 537-554.
- [34]Bittau A, Erlingsson Ú, Maniatis P, et al. Prochlo: strong privacy for analytics in the crowd[C]//Proceedings of the 26th symposium on operating systems principles. New York: ACM, 2017: 441-459.
- [35]Erlingsson Ú, Feldman V, Mironov I, et al. Amplification by shuffling: From local to central differential privacy via anonymity[C]//Proceedings of the Thirtieth Annual ACM-SIAM Symposium on Discrete Algorithms. New York: ACM, 2019: 2468-2479.
- [36]Balle B, Bell J, Gascón A, et al. The privacy blanket of the shuffle model[C]//Cryptology - CRYPTO 2019 - 39th Annual International Cryptology Conference. Santa Barbara, CA, USA: Springer, Cham, 2019: 638-667.
- [37]Wang T, Ding B, Xu M, et al. Improving utility and security of the shuffler-based differential privacy[J]. VLDB Endowment, 2020, 13(13): 3545-3558.
- [38]Li X, Liu W, Zi Y, et al. DUMP: a dummy-point-based framework for histogram estimation in shuffle model [J]. CoRR abs, 2020: 2009.13738.
- [39]Cheu A. Differential Privacy in the Shuffle Model: A Survey of Separations[J]. CoRR abs, 2021: 2107.11839.
- [40]Wang M, Meng X. ESA: a novel privacy preserving framework[J]. Journal of Computer Research and Development, 2022, 59(01): 144-171. (in Chinese)
王雷霞, 孟小峰. ESA:一种新型的隐私保护框架[J]. 计算机研究与发展, 2022, 59(01): 144-171.
- [41]Hou Lihe, Ni Weiwei, Zhang Sen, et al. Wdt-SCAN: Clustering decentralized social graphs with local differential privacy[J]. Computers & Security, 2023, 125: 103036.
- [42]Fu Nan, Ni Weiwei, Zhang Sen, et al. GC-NLDP: A graph clustering algorithm with local differential privacy[J]. Computers & Security, 2023, 124: 102967.
- [43]Kasiviswanathan S P, Nissim K, Raskhodnikova S, et al. Analyzing graphs with

- node differential privacy[C]//The 10th Theory of Cryptography Conference. Berlin: Springer, 2013: 457-476.
- [44]Raskhodnikova S, Smith A. Lipschitz extensions for node-private graph statistics and the generalized exponential mechanism[C]//2016 IEEE 57th Annual Symposium on Foundations of Computer Science (FOCS). Piscataway, NJ: IEEE, 2016: 495-504.
- [45]Liu Shang, Cao Yang, Murakami T, et al. A crypto-assisted approach for publishing graph statistics with node local differential privacy[C]//Proceedings of the 10th IEEE International Conference on Big Data (Big Data). Piscataway, NJ: IEEE, 2022: 5765-5774.
- [46]Chen X, Mauw S, Ramírez-Cruz Y. Publishing community-preserving attributed social graphs with a differential privacy guarantee[J]. arXiv preprint arXiv:1909.00280, 2019.
- [47]Sala A, Zhao X, Wilson C, et al. Sharing graphs using differentially private graph models[C]//Proceedings of the 2011 ACM SIGCOMM Conference on Internet Measurement Conference. New York: ACM, 2011: 81-98.
- [48]Karwa V, Raskhodnikova S, Smith A, et al. Private analysis of graph structure[J]. VLDB Endowment, 2011, 4(11): 1146-1157.
- [49]Li X, Yang J, Sun Z, et al. Differential privacy for edge weights in social networks[J]. Security and Communication Networks, 2017(2017): 4267921:1-4267921:10.
- [50]Li Y, Liu S, Li D, et al. Release connection fingerprints in social networks using personalized differential privacy[J]. Chinese Journal of Electronics, 2018, 27(5): 1104-1110.
- [51]Warner S L. Randomized response: a survey technique for eliminating evasive answer bias[J]. Journal of the American Statistical Association, 1965, 60(309): 63-69.
- [52]Cheu A, Smith A, Ullman J, et al. Distributed differential privacy via shuffling[C]//Advances in Cryptology–EUROCRYPT 2019: 38th Annual International Conference on the Theory and Applications of Cryptographic Techniques, Darmstadt, Germany, May 19–23, 2019, Proceedings, Part I 38. Berlin: Springer, 2019: 375-403.
- [53]Feldman V, McMillan A, Talwar K. Hiding among the clones: A simple and nearly optimal analysis of privacy amplification by shuffling[C]//2021 IEEE 62nd

Annual Symposium on Foundations of Computer Science (FOCS). Piscataway, NJ: IEEE, 2022: 954-964.

- [54]Zhang X, Xu Y, Xia Q et al. Histogram publication under shuffled differential privacy [J]. Chinese Journal of Software, 2022, 33(6):2348-2363. (in Chinese)
张啸剑, 徐雅鑫, 夏庆荣,等. 基于混洗差分隐私的直方图发布方法[J]. 软件学报, 2022, 33(6):2348-2363.
- [55]Meehan C, Chowdhury A R, Chaudhuri K, et al. Privacy implications of shuffling[C]//International Conference on Learning Representations. Washington DC: ICLR, 2021: 1 - 30.
- [56]Girgis A, Data D, Diggavi S, et al. Shuffled model of differential privacy in federated learning[C]//International Conference on Artificial Intelligence and Statistics. New York: PMLR, 2021: 2521-2529.
- [57]Liu R, Cao Y, Chen H, et al. Flame: Differentially private federated learning in the shuffle model[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Menlo Park, CA: AAAI, 2021, 35(10): 8688-8696.
- [58]Liu Y, Wang N, Wang Z, et al. Collecting and analyzing multidimensional categorical data under shuffled differential privacy [J]. Chinese Journal of Software, 2022, 33(3):1093-1110. (in Chinese)
刘艺菲, 王宁, 王志刚,等. 混洗差分隐私下的多维类别数据的收集与分析[J]. 软件学报, 2022, 33(3):1093-1110.
- [59]Imola J, Murakami T, Chaudhuri K. Differentially private triangle and 4-cycle counting in the shuffle model[C]//Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security. New York: ACM, 2022: 1505-1519.
- [60]Li Z, Wang T, Lopuhaä-Zwakenberg M, et al. Estimating numerical distributions under local differential privacy[C]//Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2020: 621-635.
- [61]Lin W, Li B, Wang C. Towards private learning on decentralized graphs with local differential privacy[J]. IEEE Transactions on Information Forensics and Security, 2022, 17: 2936-2946.
- [62]Mcsherry F D. Privacy integrated queries: An extensible platform for privacy preserving data analysis [C]//Proceedings of the 2009 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2009: 19-30.

- [63]Dwork C, Roth A. The algorithmic foundations of differential privacy[J]. Foundations and Trends[®] in Theoretical Computer Science, 2014, 9(3-4): 211-407.
- [64]Fu N, Ni W, Jiang Z, et al. Directed Graph Clustering Method with Edge Local Differential Privacy[J/OL]. Journal of Computer Research and Development: 1-12[2024-03-18]. (in Chinese)
付楠, 倪巍伟, 姜泽鹏等. 基于本地化边差分隐私的有向图聚类方法[J/OL]. 计算机研究与发展: 1-12[2024-03-18].
- [65]Ding H, Fu P, Peng C, et al. Histogram publishing algorithm for degree distribution via shuffled differential privacy[J/OL]. Journal of Xidian University, 2023, 50(06): 219-236. (in Chinese)
丁红发, 傅培旺, 彭长根等. 混洗差分隐私保护的度分布直方图发布算法[J]. 西安电子科技大学学报, 2023, 50(06): 219-236.
- [66]Fu P, Ding H, Liu H, et al. Statistics collecting algorithms of distributed graph via local differential privacy[J/OL]. Journal of Computer Research and Development: 1-27[2024-01-14]. (in Chinese)
傅培旺, 丁红发, 刘海等. 基于本地差分隐私的分布式图统计采集算法[J/OL]. 计算机研究与发展: 1-27[2024-01-14].