

doi:10.19665/j.issn1001-2400.20230207

混洗差分隐私保护的度分布直方图发布算法

丁红发^{1,2,3}, 傅培旺¹, 彭长根², 龙土工², 吴宁博¹

(1. 贵州财经大学 信息学院 贵州省大数据统计分析重点实验室, 贵州 贵阳 550025;

2. 贵州大学 公共大数据国家重点实验室, 贵州 贵阳 550025;

3. 贵安新区科创产业发展有限公司, 贵州 贵阳 550025)

摘要: 当前, 基于中心化或本地差分隐私的图数据度分布直方图发布算法无法有效平衡发布数据的隐私保护程度及其可用性, 且不能有效保护用户的身份隐私。针对该问题, 在编码-混洗-分析框架下提出一种混洗差分隐私保护的度分布直方图发布算法。首先, 设计混洗差分隐私图数据度分布直方图隐私保护框架, 采取交互式用户分组、混洗器及方波本地加噪扰动机制降低编码器对分布式用户本地差分隐私加噪的噪声影响, 并利用极大似然估计在分析器端对加噪后的度分布直方图进行数据矫正, 从而提高数据效用; 其次, 提出具体的分布式用户分组、混洗差分隐私加噪和数据矫正算法, 并证明其满足 (ϵ, σ) -混洗差分隐私。实验和对比结果表明, 所提算法能保护分布式用户隐私, 在 L_1 距离、 H 距离和 MSE 多个指标度量下的数据效用比已有算法提升了 26% 以上, 且具有较低的时间开销和稳定的数据效用表现, 适用不同规模的图数据度分布直方图发布共享应用。

关键词: 隐私保护技术; 图结构; 混洗差分隐私; 度分布直方图发布; 数据效用

中图分类号: TN918; TP309 **文献标识码:** A **文章编号:** 1001-2400(2023)06-0219-18

Histogram publishing algorithm for degree distribution via shuffled differential privacy

DING Hongfa^{1,2,3}, FU Peiwan¹, PENG Changgen², LONG Shigong², WU Ningbo¹

(1. College of Information, Guizhou Key Laboratory of Big Data Statistical Analysis, Guizhou University of Finance and Economics, Guiyang 550025, China;

2. State Key Laboratory of Public Big Data, Guizhou University, Guiyang 550025, China;

3. Guian Science and Technology Industry Development Co., Ltd., Guiyang 550025, China)

Abstract: At present, the existing histogram publishing algorithms based on centralized or local differential privacy for graph data degree distribution can neither balance the privacy and utility of published data, nor preserve the identity privacy of end users. To solve this problem, a histogram publishing algorithm for degree distribution via shuffled differential privacy (SDP) is proposed under the framework of Encode-Shuffle-Analyze. First, a privacy preserving framework for histogram publishing of degree distribution is designed based on shuffled differential privacy. In this framework, the noisy impact that the encoder brings to

收稿日期: 2022-11-01

网络出版时间: 2023-07-12

基金项目: 国家自然科学基金(62002080); 贵州财经大学校级项目(2021KYYB14)

作者简介: 丁红发(1988—), 男, 副教授, E-mail: hongfa.ding@foxmail.com

傅培旺(2000—), 男, 贵州财经大学硕士研究生, E-mail: 1145646736@qq.com

彭长根(1963—), 男, 教授, E-mail: peng_stud@163.com

龙土工(1965—), 男, 教授, E-mail: 526796467@qq.com

吴宁博(1989—), 男, 副教授, E-mail: hn_dragon@163.com

网络出版地址: <https://kns.cnki.net/kcms2/detail/61.1076.tn.20230711.1455.006.html>

distributed users is reduced by employing interactive user grouping, the shuffler and the square wave noise mechanism, while adding noise via local differential privacy. The noisy histogram of degree distribution is reconciled via the maximum likelihood estimation at the analyzer end, thus improving the utility of published data. Second, specific algorithms are proposed for concreting distributed user grouping, adding shuffled differential privacy noise and reconciling the noisy data, respectively. Furthermore, it is proved that these algorithms meet the requirement of (ϵ, σ) -SDP. Experiments and comparisons illustrate that the proposed algorithms can preserve the privacy of distributed users, and that the data utility is improved more than 26% with metrics in terms of L_1 distance, H distance and MSE in comparison with the existing related algorithms. The proposed algorithms also perform with a low overhead and stable data utility, and are suitable for publishing and sharing the histogram of degree distribution for different scales of graph data.

Key Words: privacy-preserving techniques; graph structures; shuffled differential privacy; degree distribution histogram publishing; data utility

1 引言

互联网、移动互联网和物联网(Internet of Things, IoT)等新兴技术的高速发展,产生了社交网络、移动位置信息、电信通信网络和生物蛋白等海量图结构数据^[1](简称图数据),并深刻影响了人们的生活和工作。图数据相较关系型、文本和图像等类型的数据,能天然表示不同实体间的复杂关系,在分析挖掘复杂关联关系时具有突出的优势,因而基于图数据的图计算在广告营销、反垃圾邮件、反电信诈骗和生物信息学等领域有着广泛的应用。图数据处理被美国国家科学研究委员会称为 21 世纪大数据处理的主要方法之一^[2],引发了学术界和产业界对图数据的广泛关注。近年来图神经网络的突出进展^[3],更是为图数据处理及应用带来了新的机遇。

各类图数据的广泛应用,使得图数据共享发布的需求变得尤为迫切。然而,社交网络、邮件网络、位置信息网络等图数据中包含大量的个人身份隐私、属性隐私和关系隐私,在共享发布此类图数据时极易造成隐私信息泄露。近年来,已发生多起图数据的安全事件,如 Facebook 数据泄漏和滴滴网络安全审查等,引发了人们对图上数据安全的广泛关注和担忧。依据我国《数据安全法》和《个人信息保护法》等法律法规要求,在对包含隐私信息的图数据进行共享发布时必须落实合规的隐私保护措施。因此,设计安全有效的图数据共享发布算法,成为产业界和学术界关注的热点^[4]。

目前,针对数据开放共享应用的数据隐私保护发布算法有匿名算法和差分隐私(Differential Privacy, DP)^[5-10]两类。随着图数据的大规模应用,这两类算法被改进扩展至图数据领域,并产生了诸多变形,如匿名算法有 k -度匿名、 k -邻居匿名和 k -同构匿名等算法,差分隐私有边差分隐私和点差分隐私算法^[4,7]。这些不同的隐私保护算法能够针对图数据的不同隐私进行有效的保护,其中差分隐私因其具备可证明强度的隐私保护能力而备受关注。但是,现有的差分隐私保护算法主要聚焦于集中式的图数据发布场景,无法适应分布式数据发布场景和数据发布者不可信场景。在社交网络、IoT 网络^[11]和位置服务网络中,每个图数据节点仅拥有与其自身相邻的一阶邻居子图,还有些场景中,不同主体拥有整个图数据的一部分子图,因各自互不信任而不愿意将原始图直接共享给其他主体。上述场景中图数据发布需要针对分布式环境和数据收集者不可信设计出安全有效的图数据共享发布方案。为解决该问题,面向分布式图数据发布的本地差分隐私(Local Differential Privacy, LDP)^[12-18]被提出,并扩展提出了基于混洗的差分隐私(Shuffled Differential Privacy, SDP)^[19-25],兼顾了图数据隐私和分布式用户身份隐私保护。然而,在实际应用中,分析图数据连通度、聚类及查找关键节点等数据挖掘工作需要度分布直方图和子图统计等图数据统计信息。对此,若利用经典差分隐私方案对图数据的所有结构信息进行保护并发布,容易造成额外的计算开销,更甚至会加剧图数据隐私的泄露风险。为此,有针对性的研究图数据统计信息的差分隐私保护模型与算法成为一种必然。

度分布直方图是图数据的一种重要统计信息,可应用于生成合成图,结合图数据其他统计信息分析图数据结构属性^[10,26]。在图数据度分布直方图发布过程中需要对图数据的结构隐私和用户(数据拥有者)的身份隐私进行保护。目前,在图数据度分布直方图发布研究中,中心化差分隐私^[7-10]和本地差分隐私^[15]备受关

注。两者均利用随机噪声机制实现隐私保护,其区别在于中心化差分隐私是数据收集者将用户的原始图数据统一收集并加噪后发布,而本地差分隐私则是分布式用户将自身的原始数据加噪后发送给数据收集者。当前使用差分隐私发布度分布直方图所面临的挑战便是中心化差分隐私需要可信第三方作为数据收集者,其安全假设太强。本地差分隐私需每个用户均向发布数据中添加随机噪声,使得数据效用不高。此外,在社交网络、IoT 网络^[11]和位置服务网络等分布式图数据度分布发布场景应用时,上述两种方法都无法保护分布式用户的身份隐私。

为解决上述图数据度分布直方图发布场景下中心化差分隐私和本地差分隐私存在的安全问题与数据效用问题,文中提出一种面向分布式场景的混洗差分图数据度分布直方图发布算法。首先,结合混洗差分和对称加密提出一种新型图数据度分布直方图隐私保护框架;其次,设计分布式节点度的随机响应机制和分组扰动混洗机制,实现保护用户身份隐私的同时减少噪声量;再次,基于期望最大(Expectation Maximum, EM)算法对混洗后的度分布数据进行分组修正,提高最终图数据度分布的数据效用;最后,基于大规模数据集进行实验,与相关算法进行对比,表明所提算法具有隐私保护和数据效用双重优势。文中的主要贡献有:

(1) 提出一种混洗差分隐私保护的度分布直方图发布框架,通过设计分组扰动混洗的模式收集用户度分布信息。

(2) 提出实现混洗差分隐私下分布式图数据度直方图发布的具体算法(Graph-SDP),并理论证明其有效性且满足混洗差分隐私。

(3) 基于 SNAP 上的多个真实数据集进行实验验证与对比。结果表明,Graph-SDP 算法与其他已有算法相比,在 L_1 距离、 H 距离及 MSE 三个不同指标方面都有显著提升,数据效用提升了约 26%~99%。

2 相关工作

自差分隐私被应用于图数据隐私保护以来,取得了重要的进展,在图数据的各类发布场景中得到了广泛的推广,如图的邻接矩阵发布^[17-18]、子图统计发布^[18]、度分布直方图发布^[7-10,15]和合成图发布^[14-15,26]等。节 2 仅围绕基于差分隐私的图数据度分布直方图发布和混洗差分隐私进行相关工作分析。

2.1 基于差分隐私的图数据度分布直方图发布

针对图数据度分布直方图发布的隐私问题,HAY 等^[7]最早利用后置噪声优化处理机制,提出图数据的边差分隐私和点差分隐私机制。进一步,KASIVISWANATHAN 等^[8]结合点差分隐私机制,利用去除原始图中度大于 θ 的顶点的投影方法,降低了敏感度,但该方法会误删许多非必要的信息,造成了大量有效信息的损失。为了解决此问题,DAY 等^[9]提出一种加边机制 π_θ 对原始图进行投影,进而在投影图的基础上统计度分布并添加噪声,但该方法的度排序过程存在不稳定性,不能最大程度保留原始图的有效信息。对此,张宇轩等^[10]提出一种基于度排序的边移除(Sequence Edge Removal, SER)投影方法,通过设置节点度的上限并依据度大小顺序进行删边,实现了在降低敏感度的同时尽可能保留原始图更多的边信息。鉴于上述方案不能适应分布式场景的问题,WEI 等^[15]基于本地差分隐私模型提出了随机跳转(Random Jump, RJ)算法,对子图节点度进行本地差分隐私扰动,保护了不可信场景下的图数据隐私。但分析发现,该方法在分布式原始数据端加噪降低了数据可用性,还泄漏了分布式用户的身份隐私。

2.2 混洗差分隐私模型

混洗差分隐私模型^[19-25,27]能有效平衡中心化差分隐私及本地差分隐私的缺点,其核心为 ESA 框架^[19],由编码器(Encoder)、混洗器(Shuffler)及分析器(Analyzer)组成。该模型通过混洗器将分布式用户输入的带噪数据进行混洗,切断数据与发送者的关联,在实现差分隐私的同时保护用户身份隐私。BALLE 等^[20]讨论了混洗机制所带来的隐私收益,并通过理论证明了使用隐私预算为 ϵ 的广义随机响应(Generalized Random Response, GRR)机制扰动分布式用户数据,隐私保护程度可提升至 $[14\ln(2/\sigma)(\exp(\epsilon)+d-1)/(n-1)]^{1/2}$,其中 d 为 GRR 机制的扰动域大小。该理论分析即隐私放大理论,当 d 过大时,仍会影响发布数据的有效性。在此基础之上,WANG 等^[21]基于优化一元编码(Optimal Unary Encoding, OUE)和优化本地哈希(Optimal Local Hash, OLH)分别提出了混洗差分隐私模型 SOUE 与

SOLH,用以发布分布式用户数据;这在一定程度上提高了发布后的数据效用,但若原始数据值域过大,则数据效用和开销仍会受到影响。为了进一步降低原始数据值对数据效用的影响,LI 等^[22]在混洗差分隐私的基础上,提出让分布式用户向混洗器发送 s 条假数据和 1 条加噪数据,并结合隐私放大理论提高了数据效用,但通信开销也随之增加。

鉴于上述分析,现有的图数据发布的隐私保护方案存在分布式用户身份隐私难以保护以及数据效用和隐私泄露权衡的突出问题。在社交网络、IoT 网络和位置服务网络等分布式图数据应用场景中,如何安全且高效地发布度分布直方图,仍亟待切实可行的解决方案。为此,在上述文献的工作基础上,开展混洗差分隐私模型的分布式图数据度分布直方图隐私保护发布方法研究,旨在保护分布式用户身份隐私的同时提升发布数据效用。

3 预备知识

节 3 主要介绍本地差分隐私和混洗差分隐私相关概念,为构建面向图数据度分布直方图发布的差分隐私保护算法提供支撑。

3.1 本地差分隐私

定义 1 (ϵ, σ) -LDP^[13]。设 x 和 x' 为任意两条本地端的真实记录,给定扰动算法 $\mathcal{A}$,其中 $\text{Range}(\mathcal{A})$ 为算法 $\mathcal{A}$ 的输出取值范围。当将扰动算法 $\mathcal{A}$ 作用于 x 及 x' 上,若算法 $\mathcal{A}$ 满足 (ϵ, σ) -LDP,则对任意 $y' \in \text{Range}(\mathcal{A})$,则有

$$\Pr[\mathcal{A}(x) \in y'] \leq \exp(\epsilon) \Pr[\mathcal{A}(x') \in y'] + \sigma, \quad (1)$$

其中, ϵ 为隐私预算,用于衡量模型保护程度; σ 为隐私泄露概率,且 $\epsilon \geq 0, \sigma \in (0, 1]$,一般情况下, $\sigma = 0$ 。

定义 2 SW 机制^[16]。用户对输入域为 $\mathbf{D} = \{0, 1, \dots, d-1\}$ 中的数据进行随机化,输出域为 $\mathbf{D}' = \{-R, 1-R, \dots, 0, 1, \dots, d, d+1, \dots, d+R-1\}$ 。对任意的输入值 $x \in \mathbf{D}$,若 SW 满足 ϵ -LDP,则有

$$\Pr[\text{SW}(x) = x'] \begin{cases} p = \frac{\exp(\epsilon)}{(2R+1)\exp(\epsilon) + d-1}, & |x - x'| \leq R \\ q = \frac{1}{(2R+1)\exp(\epsilon) + d-1}, & |x - x'| > R \end{cases}, \quad (2)$$

其中, $x' \in \mathbf{D}'$, R 称为加噪跳转半径, $|\mathbf{D}| = d$, $|\mathbf{D}'| = d + 2R$ 。

3.2 混洗差分隐私

定义 3 (ϵ, σ) -SDP^[25]。任意分布式用户 i 在本地端对其所持有的数据 d_i (其中 $d_i \in \mathbf{D} = \{1, 2, \dots, d\}$) 使用满足 ϵ_1 的本地差分隐私算法 $\mathcal{RR}$ 扰动,即 $\mathcal{RR}(d_i) = y_i$, $\mathbf{T} = \{y_1, y_2, \dots, y_n\}$ 为 n 个用户的扰动结果, y_i 则表示为第 i 个用户的扰动后的结果。假设 S 为洗牌机制,即 $S: \mathbf{Y}^n \rightarrow \mathbf{Y}^n$ 表示洗牌器对 n 个用户的输出数据进行混洗打乱,消除数据与用户间的关联。

设协议 $\mathcal{P} = \mathcal{RR} \circ S$ 为上述扰动及混洗的结合,若协议 $\mathcal{P}$ 满足 (ϵ, σ) -混洗差分隐私,则仅当对任意两个相邻数据集 $\mathbf{D}$ 和 $\mathbf{D}^*$,其任意输出集 $y' \subset \mathbf{Y}^n$,有

$$\Pr[\mathcal{P}(\mathbf{D}) \in y'] \leq \exp(\epsilon) \Pr[\mathcal{P}(\mathbf{D}^*) \in y']。 \quad (3)$$

定义 4 二项机制^[20-21]。在混洗差分隐私模型中,通过将 $\text{Bin}(n, q)$ 的噪声独立添加到直方图的每个分量中,二项机制满足 (ϵ, σ) -DP,其中:

$$\epsilon = \lceil 14 \ln(2/\sigma) / (nq) \rceil^{1/2}。 \quad (4)$$

4 混洗差分隐私保护的度分布直方图发布算法

面向分布式图数据的度分布直方图发布,提出混洗差分隐私保护框架,阐述核心部分所改进的分组加噪编码器、分组混洗器和 EM 估计算法校正的分析器,并给出混洗差分算法和具体分析与证明。

场景假设是在分布式端收集各用户度值 d_i 以发布度分布直方图,而分布式端各用户所持有的度值在一

般情况下仅用户自身知晓。因此对分析器端而言,最大度值甚至可能接近 n , 过大的值域将严重影响发布数据的效用, 因此本文提出将用户进行分组, 进一步保证发布数据的精确性。

4.1 图数据度分布直方图发布的混洗差分隐私保护框架

图1揭示了围绕图数据度分布直方图所提出的混洗差分隐私保护模型, 主要包含改进的编码器、混洗器和分析器。主要思想是: 首先, 分布式用户拥有完整图数据某一节点的一跳邻居子图, 所有用户通过编码器分组将各用户拥有的节点度值进行本地差分隐私扰动, 再经过混洗器对用户输入数据分组洗牌, 切断分布式用户与输入数据间的关联, 隐藏用户身份隐私; 其次, 分析器估值校正所有用户发布的度分布直方图数据; 最后, 发布隐私保护后的图数据度分布直方图。

在该模型中, 所有用户根据自身持有图数据节点的度值 d_i 和分组距离 d , 将自身划分到对应的分组 Group j 中, 编码器根据分组数量 $S+1$ 生成 $S+1$ 个子编码器(其中 $j \in \{0, 1, \dots, S\}$), 每个子编码器对相应分组的度数据进行隐私预算为 ϵ_j 的 SW 机制差分隐私加噪。混洗器生成 $S+1$ 个子混洗器, 分别对 $S+1$ 个分组内加噪后的节点度值进行混洗, 保护分布式用户的身份隐私。首先分析器对各混洗器混洗后的节点度值数据进行汇总, 形成加噪和用户身份隐私保护后的分组度分布直方图数据, 然后利用 EM 算法对各组度分布直方图数据进行校正, 聚合得到最终发布的图数据度分布直方图。




图1 图数据度分布直方图的混洗差分隐私保护框架

图1所示的图数据度分布直方图发布的混洗差分隐私保护框架需要根据图数据的实际情况适当选择用户子图节点度分组的组距 d 和隐私预算 ϵ 。为有效降低差分隐私的噪音量, 需要用户从分析器端获取子图节点度值的分组组距、隐私预算以及分组后各组用户数量。文中设计了两轮交互机制来实现这一目标, 具体流程包含 10 个交互迭代步骤, 如图2所示。

第一轮交互, 主要在保障用户身份隐私的同时获取各组用户数量以计算各组实际扰动所需的隐私预算 ϵ_j , 包含步骤①~⑤。

- ① 分析器根据当前图数据分布式规模及经验获取并向用户发送组距 d 及隐私预算 ϵ, σ 等参数;
- ② 用户结合组距 d 及自身度 d_i 计算对应的组号 g_i , 其中 $(g_i = \lfloor d_i/d \rfloor, i \in \{1, 2, \dots, n\})$;
- ③ 用户通过对称密钥将组号 g_i 加密并发送至混洗器;

④ 混洗器对所有用户的密文数据进行混洗后发送至分析端；

⑤ 分析器解密用户密文,统计分组数量 $S+1$ (其中 $S = \max_{1 \leq i \leq n} (g_i)$), 后续依次统计各组用户数量 $\{n_0, n_1, \dots, n_S\}$ 并发送至各用户。

第二轮交互,主要确定各组子图节点度扰动所需的参数 ϵ_j 及 R_j , 并进行 ϵ_j -本地差分隐私扰动、子图节点度值混洗和加噪后的度分布直方图校正,包括步骤 ⑥ ~ ⑩。

⑥ 用户从分析器获取当前组的用户数量 n_j , (其中 n_j 为第 j 组的用户数量,即 $g_i = j$ 的数量, $j \in \{0, 1, \dots, S\}$);

⑦ 用户结合所获取的参数 ϵ, σ, d 及 n_j 计算实际扰动所需的隐私预算 ϵ_j 及加噪跳转半径 R_j ;

⑧ 各组用户通过编码器对度值 d_{j_s} 进行 ϵ_j -SW 扰动,得到加噪后的度值数据 d'_{j_s} , 并将噪声数据发送至对应组号的混洗器 (其中 d_{j_s} 为第 j 组中用户 s 的度, d'_{j_s} 为第 j 组中用户 s 的噪声度 ($s \in \{1, 2, \dots, n_j\}$);

⑨ 混洗器分别混洗各组噪声数据并发送至分析器;

⑩ 分析器统筹各组度数据的噪声分布并通过 EM 算法校正各组的度分布,随后分析器聚合具备混洗差分隐私保护的度分布直方图 F' 。




图2 图数据度分布直方图的混洗差分隐私保护流程

4.2 相关参数计算及混洗差分算法

图2所示的图数据度分布直方图的混洗差分隐私保护流程中,用户、编码器和分析器在不同的步骤中需要计算不同的参数,并进行混洗差分隐私加噪、加噪数据矫正等操作。针对图2所示流程的步骤⑤、⑦、⑧、⑩中的计算任务及相应算法进行详细阐述。

4.2.1 各用户组的用户数量计算算法

后续参数计算过程需知晓各组用户数量,然而各分布式用户无法直接获取其所在分组的用户数量。因此,各用户需要利用自身的子图节点度 d_i , 根据分析器广播的组距 d 计算其对应的组号 $g_i = \lfloor d_i/d \rfloor$, 并进一步通过混洗器与分析器进行交互发送自身加密过后的用户组号 $e_{\kappa}(g_i)$, 最后由分析器进行统计, 获取各个组的用户数量 $\mathbf{N} = \{n_0, n_1, \dots, n_S\}$ 。具体交互计算过程如算法1所示。

算法 1 各用户组的用户数量计算算法。

输入:各个组的扰动范围(组距) d

输出:各组用户数 $\mathbf{N}$

用户端:

① for i in $\{1, 2, \dots, n\}$ do # n 为整个 $G = (V, E)$ 中的用户数量, $n = |V|$

② $g_i = \lfloor d_i/d \rfloor$ # 组号从 0 开始

③ $C_i = e_{nc}(g_i)$ # 将组号加密

④ Send C_i to Shuffler

⑤ end

混洗器:

⑥ $(C'_1, C'_2, \dots, C'_n) = \mathcal{S}_{\text{shuffle}}(C_1, C_2, \dots, C_n)$ # Shuffler 打乱所有密文数据

分析器:

⑦ for i in $\{1, 2, \dots, n\}$ do

⑧ $g'_i = d_{\text{decrypt}}(C'_i)$

⑨ end

⑩ Calculate maximum group number by $\{g'_1, g'_2, \dots, g'_n\}$: $S = \max_{1 \leq i \leq n} (g'_i)$

组号从 0 开始,最大的 g'_i 则为最后一组组号 S ,分组数量为 $S+1$

⑪ for j in $\{0, 1, \dots, S\}$ do

⑫ $n_j = \sum_{i=1}^n (\text{if } g'_i = j)$

⑬ end

⑭ $\mathbf{N} = \{n_0, n_1, \dots, n_S\}$

⑮ return $\mathbf{N}$

算法 1 中,步骤 ① 至步骤 ⑥ 操作由用户端和混洗器完成。首先,用户端完成自身所在用户组组号的计算,并对组号进行加密,发送给混洗器;其次,混洗器将所有用户加密后的组号进行混洗,随后发送至分析器。步骤 ⑦ 至步骤 ⑮ 操作由分析器完成,分析器对收到的所有加密组号进行解密,并对各相同明文组号的数量,即各用户分组的用户数量进行汇总。

在算法 1 中,每个用户仅需调用一次对称加密机制(如 AES 算法)将自己计算的组号进行加密,用户时间复杂度和空间复杂度均为 $O(1)$ 。混洗器打乱 n 个用户输入数据顺序整体所需的时间复杂度为 $O(1)$,空间复杂度为 $O(n)$ 。对于混洗器发送的 n 个用户的组号,数据收集者需要统计总共有多少组并计算各组内用户数量,因此在分析器端,分析器统计过程所需的时间复杂度为 $O(n)$,空间复杂度为 $O(S)$ (S 为分组数量)。

4.2.2 各组用户的隐私预算及加噪跳转半径计算算法

在节 4.1 图 2 所示的步骤 ⑦ 中,需计算各组用户扰动所需的隐私预算 ϵ_j 及加噪跳转半径 R_j (对任意组 j 中的任意两个用户 i 和 t ,有 $j = g_i = g_t, \epsilon_j = \epsilon_{g_i} = \epsilon_{g_t}$)。因此,在编码器对各用户度数据加噪扰动前,需由各分布式用户结合分析器发布的参数 ϵ, σ, d 及 n_j 计算当前组实际扰动所需的隐私预算 ϵ_j 及加噪跳转半径 R_j ,后续依次由编码器及混洗器对各组度数据进行 ϵ_j -SW 扰动及混洗操作。

为了完成上述计算,首先论证 SW 扰动及混洗过程满足 (ϵ, σ) -SDP 时,各组用户实际扰动所需的隐私预算 ϵ_j ;其次,提出各分组用户扰动所需隐私预算 ϵ_j 及加噪跳转半径 R_j 等参数的计算步骤。为避免 ϵ_j 及 R_j 选取相互依赖的问题,提出一种 R_j 选取方法,并基于该方法提出各分布式用户在本地端所需进行的计算操作算法。

定理 1 在混洗差分隐私模型中,给定 ϵ_1 -LDP 的 SW 算法扰动本地数据,则这些加噪扰动后的数据经过混洗后满足 (ϵ, σ) -SDP,且

$$\epsilon = \{ \{ 14 \ln(2/\sigma) [(2R+1) \exp(\epsilon_1) + d - 1] \} / (n-1) \}^{1/2}, \quad (5)$$

其中, R 为本地数据进行 SW 扰动所需的加噪跳转半径。

证明 在混洗差分隐私模型中,对任意 $d_i \in \mathbf{D}$,经过 ϵ_1 -LDP 的 SW 算法扰动后,噪声服从二项分布:

$$B_{\text{in}}\left(n-1, q = \frac{1}{(2R+1)\exp(\epsilon_1) + d-1}\right), \quad (6)$$

其中, $\mathbf{D} = \{0, 1, \dots, d-1\}$ 。由定义 4, 利用上述二项分布噪声机制对原始数据 $\mathbf{D}$ 加噪, 洗牌后该协议满足 (ϵ, σ) -SDP, 其中 $\epsilon = \{\{14\ln(2/\sigma)[(2R+1)\exp(\epsilon_1) + d-1]\}/(n-1)\}^{1/2}$ 。证毕。

定理 2 对任意数据集 $\mathbf{D} = \{0, 1, \dots, d-1\}$ 进行 ϵ -SW 扰动时, 最优加噪跳转半径为

$$R = \left\lfloor \frac{(\epsilon \exp(\epsilon) - \exp(\epsilon) + 1)d}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)} \right\rfloor. \quad (7)$$

证明 参照文献[16]中所提出的理论知识, 假设 U 为 Graph-SDP 输入的随机变量, U' 为 Graph-SDP 输出的变量, U 与 U' 之间的互信息可以用 U 与 U' 的微分熵以及条件微分熵之间的差来进行表示, 即

$$I(U, U') = g(U) - g(U | U') = g(U') - g(U' | U). \quad (8)$$

由于 $I(U, U')$ 的数量取决于输入数据的分布, 该部分信息无法在执行过程中获取, 因此可以选取 $I(U, U')$ 的一个上界, 即 U' 均匀分布在 $\mathbf{D}'(\{-R, 1-R, \dots, 0, \dots, d+R-1\})$ 上。此时, 假设 W 为均匀分布在 $\mathbf{D}'$ 上的随机变量, 依据文献[16]有 $g(U') \leq g(W)$ 。因此

$$I(U, U') = g(U') - g(U' | U) \leq g(W) - g(U' | U).$$

同时, W 为均匀分布在 $\mathbf{D}'$ 上的随机变量, 而 $\mathbf{D}'$ 的大小为 $2R+d$ ($|\mathbf{D}'| = 2R+d$), 故有 $g(W) = \ln(2R+d)$ 。而 $g(U' | U)$ 取决于 Graph-SDP 扰动机制, 即

$$\begin{aligned} g(U' | U) &= - \int_v PR(U=v) [(2R+1)p \ln p + (d-1)q \ln q] = - [(2R+1)p \ln p + (d-1)q \ln q] = \\ &= -(2R+1) \frac{\exp(\epsilon)}{(2R+1)\exp(\epsilon) + d-1} \ln \left(\frac{\exp(\epsilon)}{(2R+1)\exp(\epsilon) + d-1} \right) - \\ &= (d-1) \frac{1}{(2R+1)\exp(\epsilon) + d-1} \ln \left(\frac{\exp(\epsilon)}{(2R+1)\exp(\epsilon) + d-1} \right) = \\ &= - \frac{(2R+1)\epsilon \exp(\epsilon)}{(2R+1)\exp(\epsilon) + d-1} + \ln[(2R+1)\exp(\epsilon) + d-1]. \end{aligned}$$

因此整体的互信息是依据参数 R 构成的一个函数, 即

$$\frac{(2R+1)\epsilon \exp(\epsilon)}{(2R+1)\exp(\epsilon) + d-1} + \ln \left[\frac{2R+d}{(2R+1)\exp(\epsilon) + d-1} \right].$$

对该函数进行求导并设其为 0, 可以得到

$$R = \frac{(\epsilon \exp(\epsilon) - \exp(\epsilon) + 1)d}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)} - \frac{(\exp(\epsilon) - 1)^2}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)}.$$

由于 ϵ 一般为小于 1 的数, 其变化对 $\frac{(\exp(\epsilon) - 1)^2}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)}$ 的影响相对较小, 且用户度均为整数, 因此

不失一般性, 当隐私预算及组距为 ϵ 及 d 时, $R = \left\lfloor \frac{(\epsilon \exp(\epsilon) - \exp(\epsilon) + 1)d}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)} \right\rfloor$ 。证毕。

由定理 1, 任意组 j 中的所有用户通过 SW 机制及混洗器加噪混洗子图度值时, 若该混洗差分隐私模型满足 (ϵ, σ) -SDP, 则当前组用户实际加噪扰动其度值所需的隐私预算为

$$\epsilon_j = \ln \left\{ \left[(n_j - 1) \frac{\epsilon^2}{14 \ln \left(\frac{2}{\sigma} \right)} - d + 1 \right] / (2R_j + 1) \right\}. \quad (9)$$

类似地, 依据定理 2, 任意组 j 中的用户使用 ϵ_j -SW 机制所需的加噪跳转半径为

$$R_j = \left\lfloor \frac{(\epsilon_j \exp(\epsilon_j) - \exp(\epsilon_j) + 1)d}{2\exp(\epsilon_j)(\exp(\epsilon_j) - 1 - \epsilon_j)} \right\rfloor. \quad (10)$$

易知各组实际所需的隐私预算 ϵ_j 及加噪跳转半径 R_j 计算相互依赖。为保证所提模型仍能提供一定的隐私收益, 文中首先提出各分布式用户均利用分析器给定的初始参数 ϵ 及 d 计算初始加噪跳转半径 $\tilde{R}$; 然后, 当前组用户利用 $\tilde{R}$ 计算当满足 (ϵ, σ) -SDP 时, 加噪扰动其度值实际所需的隐私预算 ϵ_j ; 最后, 再利用隐私预算 ϵ_j 计算各自实际的加噪跳转半径 R_j 。具体分为如下 3 个步骤。

(1) 所有分布式用户通过初始隐私预算 ϵ, σ 及组距 d 计算初始加噪跳转半径 $\tilde{R}$, 保持初始参数均一

致,即

$$\tilde{R} = \left\lfloor \frac{(\epsilon \exp(\epsilon) - \exp(\epsilon) + 1)d}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)} \right\rfloor. \quad (11)$$

(2) 任意组 j 中的用户可结合 $\tilde{R}$ 、 ϵ 及 n_j 等参数计算满足 ϵ -SDP 条件下的各用户实际加噪扰动其度值所需的隐私预算 ϵ_j , 即

$$\epsilon_j = \ln \left\{ \frac{\left[(n_j - 1) \frac{\epsilon^2}{14 \ln\left(\frac{2}{\sigma}\right)} - d + 1 \right]}{2\tilde{R} + 1} \right\}. \quad (12)$$

(3) 各用户分别依据计算出的隐私预算 ϵ_j 计算实际加噪扰动时的加噪跳转半径 R_j , 即

$$R_j = \left\lfloor \frac{(\epsilon_j \exp(\epsilon_j) - \exp(\epsilon_j) + 1)d}{2\exp(\epsilon_j)(\exp(\epsilon_j) - 1 - \epsilon_j)} \right\rfloor. \quad (13)$$

由此,各用户便可在本地端计算对应扰动所需的参数,具体如算法2所示。其中,分布式用户 i ($i \in \{1, 2, \dots, n\}$) 在确立自身组号为 g_i ($g_i \in \{0, 1, \dots, S\}$) 后,首先将自身的度 d_i 归一化为 $\tilde{d}_i$ ($\tilde{d}_i = d_i - g_i d$),保持各组的输入域 $\mathbf{D}'$ 均为 $\{0, 1, \dots, d-1\}$ ($|\mathbf{D}| = d$)。然后结合组内用户数量 n_{g_i} 、隐私预算 ϵ 、 σ 及组距 d 等参数计算当前组 Group g_i 扰动所需的隐私预算 ϵ_{g_i} 以及加噪跳转半径 R_{g_i} (对任意两个用户 i, t ,若二者同处于组 j ,即 $j = g_i = g_t$,则 $\epsilon_j = \epsilon_{g_i} = \epsilon_{g_t}$, $R_j = R_{g_i} = R_{g_t}$)。各分布式用户各自执行完算法2后,将计算好的参数 ϵ_{g_i} 、 R_{g_i} 及归一化后的度 $\tilde{d}_i$ 发送至对应编码器,由编码器对度值 $\tilde{d}_i$ 进行 ϵ_{g_i} -SW 扰动。

算法2 分布式用户参数计算算法。

输入:隐私预算 ϵ 、 σ 、度的分组范围 d 、各组用户数量 $\mathbf{N} = \{n_0, n_1, \dots, n_S\}$

输出: $\{m_1, m_2, \dots, m_n\}$ # 各用户参数列表(用于编码器对度值扰动加噪)

① for i in $\{1, 2, \dots, n\}$ do

② $\tilde{d}_i = d_i - g_i d, g_i = \left\lfloor \frac{d_i}{d} \right\rfloor$

③ Calculate $\tilde{R}$ by ϵ : $\tilde{R} = \left\lfloor \frac{(\epsilon \exp(\epsilon) - \exp(\epsilon) + 1)d}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)} \right\rfloor$

④ Calculate ϵ_{g_i} : $\epsilon_{g_i} = \ln \left\{ \frac{\left[(n_{g_i} - 1) \frac{\epsilon^2}{14 \ln\left(\frac{2}{\sigma}\right)} - d + 1 \right]}{2\tilde{R} + 1} \right\}$

其中 n_{g_i} 是指第 i 个用户所处 group 中用户的数量,若 $g_i = g_j$,则 $n_{g_i} = n_{g_j}$

⑤ Calculate R_{g_i} : $R_{g_i} = \left\lfloor \frac{(\epsilon_{g_i} \exp(\epsilon_{g_i}) - \exp(\epsilon_{g_i}) + 1)d}{2\exp(\epsilon_{g_i})(\exp(\epsilon_{g_i}) - 1 - \epsilon_{g_i})} \right\rfloor$

对任意用户 i 和 j ,若 $g_i = g_j$,则有 $\epsilon_{g_i} = \epsilon_{g_j}$ 、 $R_{g_i} = R_{g_j}$

⑥ $m_i = (\tilde{D}_i, \epsilon_{g_i}, R_{g_i}, g_i)$ # 用户 i 参数列表

⑦ end

⑧ return $\{m_1, m_2, \dots, m_n\}$

算法2主要由各分布式用户端进行操作。步骤①至步骤②,各用户计算所处组号 g_i ($g_i \in \{0, 1, \dots, S\}$) 并将度值归一化,以保证分组后各组输入域大小一致;步骤③至步骤⑧,用户首先结合初始隐私预算 ϵ 及分组距离 d 计算初始加噪跳转半径 $\tilde{R}$,后依据参数 ϵ 、 σ 、 n_{g_i} 、 d 及初始加噪跳转半径 $\tilde{R}$ 计算当前组 Group g_i 对本地度值数据进行 SW 扰动及混洗过程满足 (ϵ, σ) -SDP 时实际扰动所需的隐私预算 ϵ_{g_i} 及加噪跳转半径 R_{g_i} 等参数。算法2中,各分布式用户仅需在本地端将各项参数计算好后发送给分析器;在此过程中,用户所需的时间复杂度及空间复杂度均为 $O(1)$ 。

执行完算法2后,各分布式用户将归一化后的度 $\tilde{d}_i$ 、隐私预算 ϵ_{g_i} 和加噪跳转半径 R_{g_i} 统一为 $m_i = (\tilde{d}_i, \epsilon_{g_i}, R_{g_i}, g_i)$,并发送 m_i 至编码器。编码器进行具体的本地差分隐私加噪扰动操作,详见节4.2.3。

4.2.3 混洗差分隐私保护的图数据度分布加噪算法

在节 4.1 图 2 所示的步骤 ⑧ 中,编码器根据各用户组的隐私预算和子图度值加噪跳转半径,以组为单位对各用户组中用户的原始度值数据进行 SW 机制本地加噪。在步骤 ⑨ 中由混洗器对加噪后的各组度值数据分别进行混洗。这里首先按照 SW 加噪机制给出各组原始度值数据的本地差分隐私加噪模型,其次给出具体的本地差分隐私和混洗算法,最后给出该算法满足混洗差分隐私的证明。

设任意组 j 中各用户混洗扰动度值时满足 (ϵ, σ) -SDP 实际所需的隐私预算和 SW 机制加噪跳转半径分别为 ϵ_j 和 R_j ,则该组度值数据的加噪模型为:对任意 $d_{j_s} \in \mathbf{D} (\mathbf{D} = \{0, 1, \dots, d-1\})$,有

$$\Pr[\text{SW}(d_{j_s}) = d'_{j_s}] = \begin{cases} p_j, & |d_{j_s} - d'_{j_s}| \leq R_j \\ q_j, & |d_{j_s} - d'_{j_s}| > R_j \end{cases}, \quad (14)$$

其中, $p_j = \frac{e^{\epsilon_j}}{(2R_j + 1)e^{\epsilon_j} + d - 1}$, $q_j = \frac{1}{(2R_j + 1)e^{\epsilon_j} + d - 1}$, $d'_{j_s} \in \mathbf{D}' (\mathbf{D}' = \{-R_j, \dots, 0, \dots, d + R_j - 1\})$, d_{j_s} 为第 j 组中用户 s 的度 ($s \in \{1, 2, \dots, n_j\}$)。

算法 3 为混洗差分隐私保护的图数据度分布直方图发布模型的混洗加噪算法,基于算法 2 的输出参数以组为单位对各用户度值进行混洗扰动。具体而言,如对第 j 组,编码器分别对组内所有分布式用户的子图节点度 d_{j_s} 进行本地差分隐私加噪,加噪模型如前文所述。加噪后由混洗器收集当前组所有用户的噪声数据 $\bar{\mathbf{D}}_j = \{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$,并对 $\bar{\mathbf{D}}_j$ 中数据进行统一混洗,即 $\tilde{\mathbf{D}}_j = \mathcal{S}_{\text{shuffle}}(\bar{\mathbf{D}}_j)$ (其中 $\tilde{\mathbf{D}}_j$ 与 $\bar{\mathbf{D}}_j$ 中仍为同一批数据,仅初始顺序被混洗打乱,以此消除输入数据与用户间的关联,达到保护分布式用户身份隐私的作用)。算法 3 执行结束后,混洗器统一将各组扰动混洗后的数据 $\tilde{\mathbf{D}} = (\tilde{\mathbf{D}}_0, \tilde{\mathbf{D}}_1, \dots, \tilde{\mathbf{D}}_S)$ 发送至分析器。

算法 3 混洗差分隐私保护的图数据度分布直方图加噪算法。

输入: $\{m_1, m_2, \dots, m_n\}$

输出: $\tilde{\mathbf{D}} = (\tilde{\mathbf{D}}_0, \tilde{\mathbf{D}}_1, \dots, \tilde{\mathbf{D}}_S)$ # 混洗后各组的带噪数据

编码器:

① for j in $\{0, 1, \dots, S\}$.

② Collect current group user data by $\{m_1, m_2, \dots, m_n\}$: $\mathbf{H}_j = \{m_{j_1}, m_{j_2}, \dots, m_{j_{n_j}}\}$

$\mathbf{H}_j = \{m_{j_1}, m_{j_2}, \dots, m_{j_{n_j}}\}$ 为 $\{m_1, m_2, \dots, m_n\}$ 中组号为 j 的用户数据

③ get ϵ_j, R_j by $\mathbf{H}_j = \{m_{j_1}, m_{j_2}, \dots, m_{j_{n_j}}\}$: $\epsilon_j, R_j = m_{j_1}(\epsilon_j, R_j)$

对任意组,组内所有用户扰动所需的隐私预算及加噪跳转半径 ϵ_j, R_j 均相等

④ for s in $\{0, 1, \dots, n_j\}$

⑤ $d_{j_s} = \mathbf{H}_{j_s}(d_{j_s}) = m_{j_s}(d_{j_s})$ # 当前组第 s 个用户归一化后的度

⑥ ϵ_j -SW perturbation of data d_{j_s}

$$\Pr[\text{SW}(d_{j_s}) = d'_{j_s}] = \begin{cases} p_j, & |d_{j_s} - d'_{j_s}| \leq R_j \\ q_j, & |d_{j_s} - d'_{j_s}| > R_j \end{cases}$$

⑦ end

⑧ send $\{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$ to j -th Shuffler

⑨ end

混洗器:

⑩ for j in $\{0, 1, \dots, S\}$

⑪ $\bar{\mathbf{D}}_j = \{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$ # $\bar{\mathbf{D}}_j = \{d'_{j_1}, d'_{j_2}, \dots, d'_{j_{n_j}}\}$ 为第 j 组的带噪数据, n_j 为该组的用户数量

⑫ $\tilde{\mathbf{D}}_j = \mathcal{S}_{\text{shuffle}}(\bar{\mathbf{D}}_j)$

⑬ end

⑭ return $\tilde{\mathbf{D}} = (\tilde{\mathbf{D}}_0, \tilde{\mathbf{D}}_1, \dots, \tilde{\mathbf{D}}_S)$

算法 3 用以实现混洗差分隐私保护,其由编码器进行本地差分隐私加噪扰动,并由混洗器进行加噪后的

数据混洗。步骤①至步骤⑨,编码器对各组用户归一化后的度值数据分别进行 ϵ_j -SW 扰动并将带噪度数据发送至混洗器;步骤⑩至步骤⑭,混洗器收集编码器发送的带噪数据,利用混洗机制消除数据与分布式用户间的关联,并发送至分析器。该算法执行过程中,混洗机制与 SW 扰动机制的结合能保障各组用户的身份隐私不被分析器获取,且整个过程满足 (ϵ, σ) -混洗差分隐私,具体证明见定理3。算法3中,编码器以组为单位对各组用户归一化后的度值进行加噪,其中 SW 机制的时间复杂度和空间复杂度为 $O(1)$,因此整个算法3中编码器所需的时间复杂度和空间复杂度均为 $O(n)$ 。同时,混洗器需对每组噪声数据进行依次混洗,混洗的时间复杂度为 $O(1)$,但混洗器需对 $S+1$ 组用户数据进行混洗,因此混洗器所需的时间复杂度为 $O(S+1)$,空间复杂度为 $O(n)$ (其中, n 为图 G 中用户数量,即顶点数)。

定理3 算法3满足 (ϵ, σ) -SDP。

证明 对任意组 group j 中任意两个输入值 $d_{j_1}, d_{j_2} \in \mathbf{D}$, 及任意输出 $z \in \mathbf{D}'$, 有

$$\frac{\Pr[z | d_{j_1}]}{\Pr[z | d_{j_2}]} \leq \frac{p}{q} = \frac{\frac{e^{\epsilon_j}}{(2R_j + 1)\exp(\epsilon_j) + d - 1}}{1} = \exp(\epsilon_j) \quad \circ$$

因此,任意组 group j 中用户通过的 ϵ_j -SW 扰动的度值满足 ϵ_j -LDP。依据节4.2.2的定理1可知,任意组 n_j 个用户在大小为 d 的取值范围上进行 SW 扰动时,若扰动算法满足 ϵ_j -LDP,则经过混洗器洗牌后满足 (ϵ, σ) -SDP,其中:

$$\epsilon = \{ \{ 14 \ln(2/\sigma) [(2R_j + 1)\exp(\epsilon_j) + d - 1] / (n_j - 1) \}^{1/2} \} \quad \circ \quad (15)$$

虽各组内用户根据分析器发送的 ϵ, σ 及组内用户数量 n_j 计算的 ϵ_j 不一定相等,但其初始隐私预算 ϵ, σ 相等,所以任意 group j 扰动混洗后的数据均满足 (ϵ, σ) -SDP。

由于 DP 具有并行性^[28],且该性质适用于 LDP 及 SDP^[27],因此,Graph-SDP 同样具有并行性。故,根据 DP 的并行性, $S+1$ 组的扰动混洗算法 $(\mathcal{S} \circ \mathcal{R}_0(\mathbf{D}_0), \mathcal{S} \circ \mathcal{R}_1(\mathbf{D}_1), \dots, \mathcal{S} \circ \mathcal{R}_S(\mathbf{D}_S))$ 满足 $\max_{0 \leq i \leq S} \{(\epsilon_i, \sigma_i)\}$ -SDP,且前述已证明任意 group j 扰动混洗后的数据均满足 (ϵ, σ) -SDP,即 $\max_{0 \leq i \leq S} \{(\epsilon_i, \sigma_i)\} = (\epsilon, \sigma)$ 。因此,Graph-SDP 中混洗加噪算法(算法3)满足 (ϵ, σ) -SDP。证毕。

4.2.4 混洗差分隐私保护的图数据度分布校正算法

在节4.1图2所示的步骤⑩中,分析器接收到混洗后的噪声数据,将对数据进行统计校正以提升最终发布的图数据度分布直方图数据的效用。

首先,分析器收集各组带噪数据 $\tilde{\mathbf{D}} = (\tilde{\mathbf{D}}_0, \tilde{\mathbf{D}}_1, \dots, \tilde{\mathbf{D}}_S)$ 后,对每组带噪度分布进行汇总。例如:对组 j 中的带噪数据 $\tilde{\mathbf{D}}_j$,统计噪声数据中 $\{0, 1, \dots, d-1\}$ 的分布 $\tilde{f}_j = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$,并计算该组用户扰动时使用的参数 p_j, q_j 及转换概率矩阵 $\mathbf{M}_j \in [0, 1]^{d' \times d}$ 。其中 $\mathbf{M}_j$ 用于描述当前组中数据的随机化过程, $\mathbf{M}_{j_{l,s}}$ 表示当前组用户输出值为 l ,输入值为 s 的概率,即 p_j 或 $q_j, s \in \{0, 1, \dots, d-1\}, l \in \{-R_j, \dots, 0, \dots, d+R_j-1\}, j \in \{0, 1, \dots, S\}, d' = d + 2R_j$ 。

其次,结合 $\mathbf{M}_j$ 及 $\tilde{f}_j = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$,通过极大似然估计(Maximum Likelihood Estimation, MLE)方法对每组带噪分布 $\tilde{f}_j$ 进行聚合校正。具体而言,构建 EM 算法重构分布 $f'_j = \{f'_{j_0}, f'_{j_1}, \dots, f'_{j_{d-1}}\} = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$,并结合对数似然函数 $L(f'_j) = \ln \Pr[\tilde{\mathbf{D}}_j | f'_j]$ 找到最优分布 f'_j ,最优 f'_j 便为第 j 组校正后的分布。

如上所述,分析器可通过依次校正各组的分布得到最优分布 $\{f'_0, f'_1, \dots, f'_S\}$ 。最后,分析器归一化各组校正后的分布聚合得到具备混洗差分隐私保护的度分布直方图估计 $\mathbf{F}' = \{f_0^*, f_1^*, \dots, f_S^*\}$ 。具体如算法4所示。

算法4 混洗差分隐私保护的图数据度分布直方图校正算法。

输入:隐私预算 ϵ ,组距 $d, \tilde{\mathbf{D}} = (\tilde{\mathbf{D}}_0, \tilde{\mathbf{D}}_1, \dots, \tilde{\mathbf{D}}_S), \mathbf{N} = \{n_0, n_1, \dots, n_S\}$

输出:度分布直方图 $\mathbf{F}'$ # 该分布为对原始分布的估计

- ① for j in $\{0, 1, \dots, S\}$ do # 分别对每个组内的数据进行校正
- ② calculate $\tilde{f}_j$ by $\tilde{\mathbf{D}}_j: \tilde{f}_j = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$ # 其中, $\tilde{f}_j$ 为 $\tilde{\mathbf{D}}_j$ 中 $\{0, 1, \dots, d-1\}$ 的分布情况
- ③ calculate p_j, q_j by ϵ, d and n_j

$$\tilde{R} = \left\lfloor \frac{(\epsilon \exp(\epsilon) - \exp(\epsilon) + 1)d}{2\exp(\epsilon)(\exp(\epsilon) - 1 - \epsilon)} \right\rfloor \quad \epsilon_j = \ln \left\{ \left[(n_j - 1) \frac{\epsilon^2}{14 \ln \left(\frac{2}{\sigma} \right)} - d + 1 \right] / (2\tilde{R} + 1) \right\}$$

$$R_j = \left\lfloor \frac{(\epsilon_j \exp(\epsilon_j) - \exp(\epsilon_j) + 1)d}{2\exp(\epsilon_j)(\exp(\epsilon_j) - 1 - \epsilon_j)} \right\rfloor$$

$$p_j = \frac{\exp(\epsilon_j)}{(2R_j + 1)\exp(\epsilon_j) + d - 1} \quad q_j = \frac{1}{(2R_j + 1)\exp(\epsilon_j) + d - 1}$$

④ calculate $\mathbf{M}_j$

$$\mathbf{f}'_j = \{f'_{j_0}, f'_{j_1}, \dots, f'_{j_{d-1}}\} = \{\tilde{f}_{j_0}, \tilde{f}_{j_1}, \dots, \tilde{f}_{j_{d-1}}\}$$

⑥ While not converge do

⑦ E-step: $\forall i \in \{0, 1, \dots, d-1\}$

$$\textcircled{8} \quad P_{j_i} = f'_{j_i} \sum_{l \in [d']} n_{j_l} \frac{\Pr[x' \in B'_l | x \in B_i, f'_j]}{\Pr[x' \in B'_l | f'_j]} = f'_{j_i} \sum_{l \in [d']} n_{j_l} \frac{\mathbf{M}_{j_{l,i}}}{\sum_{s=0}^{d-1} \mathbf{M}_{j_{l,s}} f'_{j_s}}$$

其中 n_{j_l} 为 $\tilde{\mathbf{D}}_j$ 中值为 l 的数量, $x \in B_i$ 表示用户输入值为 $i (i \in [d] = [0, 1, \dots, d-1])$, $x' \in B'_l$ 表示输出值为 $l (l \in [d'] = [-R_j, \dots, 0, \dots, d+R_j-1])$

⑨ M-step: $\forall i \in \{0, 1, \dots, d-1\}$

$$\textcircled{10} \quad f'_{j_i} = \frac{P_{j_i}}{\sum_{s=0}^{d-1} P_{j_s}}$$

⑪ end while

$$\textcircled{12} \quad \mathbf{f}'_j = \{f'_{j_0}, f'_{j_1}, \dots, f'_{j_{d-1}}\}$$

⑬ for i in $\{0, 1, \dots, d-1\}$ do

$$\textcircled{14} \quad f_{j_i}^* = \frac{f'_{j_i} n_j}{n} \quad \# \text{ 归一化 } \# f'_{j_i} \text{ 为第 } j \text{ 组中度为 } i \text{ 的频率}$$

⑮ end

$$\textcircled{16} \quad \mathbf{f}_j^* = \{f_{j_0}^*, f_{j_1}^*, \dots, f_{j_{d-1}}^*\}$$

⑰ end

$$\textcircled{18} \quad \mathbf{F}' = \{f_0^*, f_1^*, \dots, f_s^*\}$$

⑱ return $\mathbf{F}'$ # 度分布直方图估计

算法 4 用以分析器对接收到的各组加噪混洗度值分布数据进行矫正,进而聚合得到效用更高的图数据度分布直方图估计结果数据。步骤①至步骤④,统计各组噪声数据 $\tilde{\mathbf{D}}_j$ 中 $\{0, 1, \dots, d-1\}$ 的分布 $\tilde{f}_j$,并计算该组用户扰动所使用的参数 p_j, q_j 及转换概率矩阵 $\mathbf{M}_j$ 。步骤⑤至步骤⑫,结合 $\mathbf{M}_j$ 及 $\tilde{f}_j$,构建 EM 算法对带噪声分布 $\tilde{f}_j$ 进行聚合校正,结合对数似然函数计算最优分布 $\mathbf{f}'_j$ 。步骤⑬至步骤⑱,分析器对各组校正后的度分布估计 $\mathbf{f}'_j$ 进行归一化 ($f_j^* = \frac{n_j}{n} f'_j$),聚合得到具备混洗差分隐私保护的度分布直方图估计 $\mathbf{F}' = \{f_0^*, f_1^*, \dots, f_s^*\}$ 。其中,步骤⑤至步骤⑫中由 EM 算法校正获得的分布 $\mathbf{f}'_j$ 收敛于真实分布 $\mathbf{f}_j$,具体证明见定理 4。

在此过程中,分析器仅能获取近似原始图度分布的直方图估计,无法知晓各组中数据来源于哪位用户,同时也无法获晓数据原始值,因此在该过程中分布式用户的身份隐私和度值数据均得到了安全保障。即便混洗器与分析器共谋,各组数据仍能得到 ϵ_j -LDP 的隐私保护。此外,由于分析器获取 $S+1$ 组中所有用户(即图 G 中 n 个用户)的噪声数据,并对其进行合并校正,所以算法 4 的时间复杂度和空间复杂度均为 $O(n)$ 。

定理 4 对于任意组带噪数据 $\tilde{\mathbf{D}}_j$,经过算法 4 校正后的分布 $\mathbf{f}'_j$ 收敛于真实分布 $\mathbf{f}_j$ 的极大似然估计。

证明 算法 4 实则是通过 EM 算法构建极大似然估计对带噪声分布进行聚合校正,若证明校正后的分布 $\mathbf{f}'_j$ 收敛于真实分布 $\mathbf{f}_j$ 的极大似然估计,即证明 EM 算法收敛于 $\mathbf{f}_j$ 的极大似然估计。因此,证明对数似然函

数为凹函数^[16]即可。

对任意组带噪数据 $\tilde{\mathbf{D}}_j$ 及其初始数据真实分布 $\mathbf{f}_j$,其对数似然函数有

$$L(\mathbf{f}_j) = \ln \Pr[\tilde{\mathbf{D}}_j | \mathbf{f}_j] = \ln \left(\prod_{t=1}^{N_j} \Pr[\tilde{D}_{j_t} | \mathbf{f}_j] \right) = \sum_{t=1}^{N_j} \ln \left(\sum_{i=1}^d f_{j_t} \Pr[\tilde{d}_{j_t} | x \in B_i] \right),$$

其中, $\Pr[\tilde{d}_{j_t} | x \in B_i]$ 是由算法 Graph-SDP 确定的常数,即 p_j 或者 q_j ; $\tilde{d}_{j_t}$ 表示 $\tilde{\mathbf{D}}_j$ 中第 t 位数据, $t \in \{1, 2, \dots, N_j\}$; $\tilde{\mathbf{D}}_j = \{\tilde{d}_{j_1}, \tilde{d}_{j_2}, \dots, \tilde{d}_{j_{N_j}}\}$, 为第 j 组的噪声数据, N_j 为 $\tilde{\mathbf{D}}_j$ 中数据数量; $f_{j_t} \in \mathbf{f}_j = \{f_{j_0}, f_{j_1}, \dots, f_{j_{d-1}}\}$; R 表示用户输入值为 i 。

可知, 对数似然函数 $L(\mathbf{f}_j)$ 是一个凹函数。故, EM 算法校正后的分布 $\mathbf{f}'_j$ 收敛于真实分布 $\mathbf{f}_j$ 的极大似然估计。证毕。

5 实验与分析

为评估所提混洗差分隐私保护算法在分布式图数据度分布直方图发布场景下的效用, 选取多个公开真实数据集进行实验对比分析。首先, 在相同隐私预算条件下, 利用不同指标进行度量, 对比分析所提算法与其他度分布隐私保护算法的效用。其次, 分析所提算法在组距 d 设置不同时对运行时间、效用的影响。最后, 分析其他参数(σ, R)对所提算法效用的影响。所有实验均在 Inter Core i5-6200U CPU、Windows 10 上运行, 利用 Python3.8 进行实现, 代码见 <https://gitee.com/fpw-gufe/graph-sdp-algorithm>。

5.1 实验数据集及算法效用度量指标信息

实验数据集选取了 Stanford Large Network Dataset Collection 网站上 5 个具有代表性的真实图数据集, 这些数据集也被应用于图数据隐私保护的相关研究中^[10, 15]。这些数据集分别为 Twitter、Amazon、gemsec-facebook_artist、com-dblp_ungraph 和 gemsec_deezer_HU, 表 1 简要分析了实验数据集的节点 ($|V|$)、边 ($|E|$) 和最大度 ($d_{\max}$) 等特征信息。

表 1 数据集信息

数据集	$ V $	$ E $	$d_{\max}$
Twitter	81 306	1 768 149	3 383
Amazon	262 111	1 234 877	420
com-dblp_ungraph	317 080	1 049 866	343
gemsec-facebook_artist	50 515	819 306	1 469
gemsec_deezer_HU	47 538	222 887	112

为对比分析不同隐私保护算法的效用, 采用 L_1 距离^[9-10]、 H 距离 (Hellinger Distance)^[15] 以及均方差 (Mean Square Error, MSE)^[24] 3 个指标进行效用量化。具体而言, 针对于两个度分布 $\mathbf{F}$ 及 $\mathbf{F}'$, 其中 $\mathbf{F}$ 为真实度分布直方图, $\mathbf{F}'$ 为隐私保护后的度分布直方图, 设 $\mathbf{F}$ 和 $\mathbf{F}'$ 的长度为 $l = d \times S$ (其中, d 为组距, S 为分组数量), 则 $\mathbf{F}$ 与 $\mathbf{F}'$ 之间的 L_1 距离记为 $L_1 = \sum_{i=0}^{l-1} |\mathbf{F}_i - \mathbf{F}'_i|$, H 距离记为 $H(\mathbf{F}', \mathbf{F}) = 2^{-1/2} \|(\mathbf{F}')^{1/2} - (\mathbf{F})^{1/2}\|_2$, 用

以计算两个度分布之间的距离, 衡量两个分布间的相似性, MSE 的计算方式则为 $R_{\text{MSE}} = \frac{1}{l} \sum_{i=0}^{l-1} (\mathbf{F}_i - \mathbf{F}'_i)^2$ 。其中 $\mathbf{F}_i$ 表示分布 $\mathbf{F}$ 中度为 i 的频率, L_1 距离、 H 距离及 MSE 越小, 即表明度分布越相似, 度分布之间的差异性越小。

5.2 效用分析

将文中所提出的 Graph-SDP 算法与文献[12, 15]中提出的算法进行对比。其中, 文献[15]的 RJ 算法是一种基于本地差分隐私的图数据度分布直方图发布算法, 文献[12]的 GRR 和 SUE 算法都为本地差分隐私算法。由于扰动域过大时, GRR 会引入过多噪声, SUE 的计算代价过大, 从而将造成两种算法发布的数据效用不理想。因此, 实验中对 GRR 和 SUE 也进行了数据分组, 避免每组数据扰动域过大, 以减少算法的计算复杂度并提升效用。




图 3 不同图数据集分布直方图发布算法的效用分析

4 种算法的效用对比结果如图 3 所示。图 3(a)~(e)分别为隐私预算 $\epsilon=[0.15, 0.25, 0.5, 0.75, 0.85, 1]$, Graph-SDP、RJ、GRR 及 SUE 算法在表 1 所示的不同数据集上的实验效果,图 3(a)~(e)各个子图分为左中右 3 列,分别表示 L_1 距离、 H 距离和 MSE 三个指标的实验结果。由图 3 可知,针对不同的数据集,Graph-SDP 算法的数据效用在 3 个不同的指标纬度上均优于其他算法。具体地,如图 3(a)所示,在 Twitter 数据集上,随着隐私预算的增大,4 种算法的数据效用都随之变高。GRR、SUE、RJ 和 Graph-SDP 四种算法的数据效用依次变高,相比于 GRR、SUE 和 RJ 算法,Graph-SDP 在 L_1 距离和 H 距离维度的效用优势随隐私预算的变大而提升,在 MSE 维度具有一定优势,但不及其他两个指标明显,总体数据效用提升了约

30%~92%。如图3(b)所示,在数据集 Amazon 上,类似地,随着隐私预算的增大,4种算法的数据效用都随之提升,但是,数据效用大小顺序变为 RJ、GRR、SUE 和 Graph-SDP 依次变高,Graph-SDP 在 L_1 距离和 H 距离维度的效用优势随隐私预算的增大而减小,在 MSE 维度上优势不再明显,总体数据效用提升了约 60%~99%。如图3(c)~(e),同样地,相较于其他3种算法,Graph-SDP 算法在 com-dblp、ungraph、gemsec-facebook_artist 和 gemsec_deezer_HU 三个数据集上的数据效用在3个不同指标维度上都有不同程度的稳定优势,且该优势不随数据集中图数据的节点数量、边数量和度值数据变化而发生太大变化。

文中所提混洗差分隐私保护的度分布直方图发布算法 Graph-SDP 数据效用优于其他算法的原因有两方面。其一,Graph-SDP 算法基于 ESA 框架设计了混洗差分隐私模型,利用混洗器提升了数据到达分析端的整体安全性,可以适当放宽用户端所需的隐私预算,进而减少了噪声量;其二,在分析端对各分组噪声数据构建 EM 算法进而校正,使得最终发布的数据效用得到提升。通过两个层面的改进与设计,保证了同等隐私预算下隐私保护后的图数据度分布直方图数据效用得到提升。

5.3 用户分组影响分析

文中所提 Graph-SDP 算法在本地差分隐私加噪时,根据所有分布式用户的子图度值数据对用户进行了分组,不同组距将使各组初始数据输入域大小不同,进而影响算法的效率和最终的数据效用。为了进一步考察该算法在不同组距时所呈现的算法效率和数据效用,先后将组距 d 分别设置为[10, 15, 20, 25, 30, 35, 40],在相同组距设置下算法运行20次取其平均值,观察不同组距条件下的时间开销和3个效用指标的变化,实验结果如图4所示。由图4(a)可知,Graph-SDP 算法的时间开销与图数据的顶点和边的数量呈正相关,同时随着分组的组距增大而增大,200 s 时间开销内可以完成百万级边数量的图数据度分布直方图发布。由图4(b)~(d)可知,同一数据集中,Graph-SDP 算法效用受组距变动的影响相对较小,其效用随着组距的增加有略微的降低。所有数据集中,随着组距的改变, L_1 距离和 H 距离的波动都保持在 0.05 以内,MSE 的影响则整体保持在 1×10^{-6} 以内。




图4 组距变化对 Graph-SDP 的时间与效用影响

可见,在适当的分组范围内,Graph-SDP 算法的数据效用与图数据的规模 and 用户分组的组距关系相对较小,该算法总能保证较高的数据效用,实现高效用的度分布直方图发布隐私保护。因此,在条件允许的情况下,组距可相对设置较小,在保证低时间开销的同时达到更好的效用。

5.4 其他参数影响分析

依据前述定理 1 及定理 2 可知,文中所提 Graph-SDP 算法在发布度分布直方图的过程中需要各组用户依据分组情况及各项参数(如 ϵ, σ)计算实际所需的隐私预算。同时,编码器在通过 SW 机制扰动混淆数据的同时也需引入加噪跳转半径 R 。因此,为进一步分析各项参数对算法 Graph-SDP 发布数据效用的影响,在上述真实数据集上进一步对比隐私泄露率 σ 及加噪跳转半径 R 对发布数据的效用影响。实验效用度量方法依旧采用 L_1 距离、 H 距离以及 MSE。

5.4.1 隐私泄露率 σ 对发布数据的效用影响

在计算各组实际隐私预算 ϵ_j 的过程中, σ 是必不可少的参数之一,同时 σ 也反映了算法可能遭受泄露的概率。因此在表 1 所示的 5 个真实数据集上,进一步测试 σ 的设置对算法 Graph-SDP 最终发布度分布直方图效用的影响。首先将初始隐私预算和组距进行设定,即 $\epsilon=1, d=10$ 。后续依次选取隐私泄露率 $\sigma=[10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}, 10^{-5}, 10^{-6}, 10^{-7}]$,对比 Graph-SDP 算法在 5 个数据集上的效用。实验结果在相同泄露率的情况下均运行 10 次取平均值,具体如图 5 所示。

由图 5 可知,随着 σ 的值依次从 10^{-1} 下降至 10^{-7} ,算法 Graph-SDP 在 5 个数据集上均呈现上升趋势。如 Twitter 数据集,随着 σ 的下降, L_1 距离指标整体上升了约 0.002, H 距离指标约上升了 0.02,MSE 指标也随之约上升了 1.8×10^{-8} 。同理,文中所提算法在其余 4 个数据集上的效用指标也随着 σ 的下降而上升。

可见, σ 的值与 Graph-SDP 的最终效用呈负相关,但整体影响相对较小。由此,在条件允许的情况下可进一步将 σ 的值设置更小一些,从而降低泄露风险。




图 5 σ 变化对 Graph-SDP 的效用影响

5.4.2 加噪跳转半径 R 对发布数据的效用影响

文中所提 Graph-SDP 算法扰动过程中需要使用加噪跳转半径 R ,从而合理地添加噪声,保证数据安全。但 R 的不合理设置也可能影响到发布数据的实际效用。在节 4.2 中提出最优 R 的计算方式,即各组应结合实际隐私预算 ϵ_j 对 R_j 进行计算。为进一步评估 R 的计算方式是否更优以及 R 的设置对发布数据精度的影响,以 Twitter 数据集为例进行实验,在 $\epsilon=[0.25, 0.35, 0.5, 0.75, 0.85, 1.00]$ 以及 $d=10$ 时,分别测试 $R=[1, 2, 3, 4, 5]$ 和最优 R 在真实数据集上发布度分布直方图的效用,具体结果如图 6 所示。其中,最优 R 为所提最优加噪跳转半径计算方式。




图 6 加噪跳转半径 R 对 Graph-SDP 的效用影响

图6表明,在大多数情况下,文中所提选取方法得到的最优加噪跳转半径 R 在 L_1 距离、 H 距离、MSE三个效用指标方面均达到最低。具体而言,随着初始隐私预算 ϵ 的逐步上升,最优 R 的效用在3个效用指标基本上优于 $R=[1,2,3,4,5]$ 。其中存在相对较差一些的情况,如当 $\epsilon=0.25$ 时, R 相较于最优 R 在 L_1 距离和MSE两个指标上略微优一些。但整体而言,最优 R 在整体效用上要比其余5个值更为出色。

因此,文中所提 Graph-SDP 算法设置的 R 计算方式能更为优秀地发布更精确的度分布直方图。

6 结束语

围绕分布式图数据度分布直方图发布场景,研究高效的差分隐私保护机制,解决了已有算法存在的数据效用低下和隐私保护效用不高的问题。基于 ESA 混洗差分隐私框架设计了面向图数据度分布直方图发布的混洗差分隐私保护模型,设计了交互式参数计算协议,重构了 ESA 混洗差分隐私保护框架的编码器和析器。通过混洗差分机制保护分布式用户的身份隐私,通过用户分组降低数据加噪的加噪跳转半径并利用极大似然估计矫正提高数据效用。在所设计的图数据度分布直方图发布混洗差分隐私保护模型的基础上,提出了具体的隐私保护数据发布算法并证明了其满足 (ϵ, σ) -SDP。利用真实数据集进行实验并与已有算法进行对比,大量实验结果表明了所提出的算法具有更高的数据效用,其数据效用相较已有算法有了显著提升;同时,该算法具有较低的时间开销,能适用于不同规模的图数据直方图发布隐私保护需求。

参考文献:

- [1] HEIDARI S, SIMMHAN Y, CALHEIROS R N, et al. Scalable Graph Processing Frameworks: A Taxonomy and Open Challenges[J]. ACM Computing Surveys, 2018, 51(3): 1-53.
- [2] NATIONAL RESEARCH COUNCIL, DIVISION ON ENGINEERING AND PHYSICAL SCIENCES, BOARD ON MATHEMATICAL SCIENCES AND THEIR APPLICATIONS, et al. Frontiers in Massive Data Analysis [R]. Washington: National Academies Press, 2013.
- [3] 马帅, 刘建伟, 左信, 等. 图神经网络综述[J]. 计算机研究与发展, 2022, 59(1): 47-80.
MA Shuai, LIU Jianwei, ZUO Xin, et al. Survey on Graph Neural Network[J]. Chinese Journal of Computer Research and Development, 2022, 59(1): 47-80.
- [4] 刘宇涵, 陈红, 刘艺璇, 等. 图数据上的隐私攻击与防御技术[J]. 计算机学报, 2022, 45(4): 702-734.
LIU Yuhuan, CHEN Hong, LIU Yixuan, et al. State-of-the-Art Privacy Attacks and Defenses on Graphs [J]. Chinese Journal of Computers, 2022, 45(4): 702-734.
- [5] DWORK C. Differential Privacy [C] // International Colloquium on Automata, Languages, and Programming. Berlin: Springer, 2006: 1-12.
- [6] 徐花, 田有亮. 差分隐私下的权重社交网络隐私保护[J]. 西安电子科技大学学报, 2022, 49(1): 17-25.
XU Hua, TIAN Youliang. Protection of Privacy of the Weighted Social Network under Differential Privacy [J]. Journal of Xidian University, 2022, 49(1): 17-25.
- [7] HAY M, LI C, MIKLAU G, et al. Accurate Estimation of the Degree Distribution of Private Networks [C] // 2009 Ninth IEEE International Conference on Data Mining. Piscataway: IEEE, 2009: 169-178.
- [8] KASIVISWANATHAN S P, NISSIM K, RASKHODNIKOVA S, et al. Analyzing Graphs with Node Differential Privacy [C] // The 10th Theory of Cryptography Conference. Berlin: Springer, 2013: 457-476.
- [9] DAY W Y, LI N, LYU M. Publishing Graph Degree Distribution with Node Differential Privacy [C] // The 2016 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2016: 123-138.
- [10] 张宇轩, 魏江宏, 李霁, 等. 点差分隐私下图数据的度直方图发布方法[J]. 计算机研究与发展, 2019, 56(3): 508-520.
ZHANG Yuxuan, WEI Jianghong, LI Ji, et al. Graph Degree Histogram Publication Method with Node-Differential Privacy [J]. Chinese Journal of Computer Research and Development, 2019, 56(3): 508-520.
- [11] AMIN F, MAJEED A, MATEEN A, et al. A Systematic Survey on the Recent Advancements in the Social Internet of Things [J]. IEEE Access, 2022, 10: 63867-63884.
- [12] WANG T, BLOCKI J, LI N, et al. Locally Differentially Private Protocols for Frequency Estimation [C] // 26th USENIX

- Security Symposium(USENIX Security 17). Berkeley:USENIX, 2017:729-745.
- [13] 叶青青, 孟小峰, 朱敏杰, 等. 本地化差分隐私研究综述[J]. 软件学报, 2018, 29(7):1981-2005.
YE Qingqing, MENG Xiaofeng, ZHU Minjie, et al. Survey on Local Differential Privacy[J]. Chinese Journal of Software, 2018, 29(7):1981-2005.
- [14] QIN Z, YU T, YANG Y, et al. Generating Synthetic Decentralized Social Graphs with Local Differential Privacy [C]// 2017 ACM SIGSAC Conference on Computer and Communications Security. New York:ACM, 2017:425-438.
- [15] WEI C, JI S, LIU C, et al. AsgLDP: Collecting and Generating Decentralized Attributed Graphs with Local Differential Privacy[J]. IEEE Transactions on Information Forensics and Security, 2020, 15:3239-3254.
- [16] LI Z, WANG T, LOPUHAÄ-ZWAKENBERG M, et al. Estimating Numerical Distributions under Local Differential Privacy [C]// The 2020 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2020: 621-635.
- [17] YE Q, HU H, AU M H, et al. LF-GDPR: A Framework for Estimating Graph Metrics with Local Differential Privacy[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(10):4905-4920.
- [18] IMOLA J, MURAKAMI T, CHAUDHURI K. Locally Differentially Private Analysis of Graph Statistics [C]// The 30th USENIX Security Symposium(USENIX Security 21). Berkeley:USENIX, 2021:983-1000.
- [19] BITTAU A, ERLINGSSON Ú, MANIATIS P, et al. Prochlo: Strong Privacy for Analytics in the Crowd [C]// The 26th Symposium on Operating Systems Principles. New York:ACM, 2017:441-459.
- [20] BALLE B, BELL J, GASCÓN A, et al. The Privacy Blanket of the Shuffle Model [C]// Cryptology-CRYPTO 2019-39th Annual International Cryptology Conference. Berlin:Springer, 2019:638-667.
- [21] WANG T, DING B, XU M, et al. Improving Utility and Security of the Shuffler-Based Differential Privacy[J]. VLDB Endowment, 2020, 13(13):3545-3558.
- [22] LI X, LIU W, ZI Y, et al. DUMP: A Dummy-Point-Based Framework for Histogram Estimation in Shuffle Model[J]. CoRR abs, 2020:2009.13738.
- [23] CHEU A. Differential Privacy in the Shuffle Model: A Survey of Separations[J]. CoRR abs, 2021:2107.11839.
- [24] 张啸剑, 徐雅鑫, 夏庆荣, 等. 基于混洗差分隐私的直方图发布方法[J]. 软件学报, 2022, 33(6):2348-2363.
ZHANG Xiaojian, XU Yaxin, XIA Qingrong et al. Histogram Publication under Shuffled Differential Privacy[J]. Chinese Journal of Software, 2022, 33(6):2348-2363.
- [25] 刘艺菲, 王宁, 王志刚, 等. 混洗差分隐私下的多维类别数据的收集与分析[J]. 软件学报, 2022, 33(3):1093-1110.
LIU Yifei, WANG Ning, WANG Zhigang, et al. Collecting and Analyzing Multidimensional Categorical Data Under Shuffled Differential Privacy[J]. Chinese Journal of Software, 2022, 33(3):1093-1110.
- [26] ZHANG S, NI W, FU N. Differentially Private Graph Publishing with Degree Distribution Preservation[J]. Computers & Security, 2021, 106(6):102285.
- [27] IMOLA J, MURAKAMI T, CHAUDHURI K. Differentially Private Triangle and 4-Cycle Counting in the Shuffle Model [C]// The 2022 ACM SIGSAC Conference on Computer and Communications Security. New York: ACM, 2022: 1505-1519.
- [28] MCSHERRY F D. Privacy Integrated Queries: An Extensible Platform for Privacy-Preserving Data Analysis [C]// 2009 ACM SIGMOD International Conference on Management of Data. New York:ACM, 2009:19-30.

(编辑: 单能飞)